



AI 相关人类存在性风险的承受主体

从物种生存到人类文明条件下的主体性实现

坤元

TrantorLabs

kunyuan@trantorlabs.sg

www.trantorlabs.sg

摘要

本文是一项关于 AI 相关人类存在性风险之风险承受主体的概念工程研究，同时具有社会认识论、技术哲学和 AI 风险治理意义。既有讨论通常将“人类”理解为 *Homo sapiens* 这一生物物种，因此风险被界定为物种灭绝、永久失能或未来剥夺。本文保留这一框架的底线地位，但提出范式扩展：在风险承受主体始终为人类这一具身物种的前提下，将其可能受到存在性损害的方式，从单一生物存续层面上的毁灭或永久失能，扩展到人类在文明条件中实现主体性之基础条件的不可逆或难以逆转的削弱。

本文的核心问题是：当我们说 AI 可能威胁“人类”时，处于风险之中的“人类”究竟是什么？本文区分人类这一风险承受主体的两个基本受损层面：生物存续层面与文明条件层面。前者关注人类作为具身物种的存续；后者关注人类在跨代际共同世界中实现认识、判断、责任、制度参与和意义创造的能力。在文明条件层面内部，本文进一步标出范畴校准机制，即真实、证据、责任、主体性、价值和意义等基础范畴的澄清、维护与调整机制。哲学内核不是独立实体，而是文明条件内部维持基础范畴可运行性的范畴校准机制。

AI 可能通过**替代性剥夺**或**中介性重构**，削弱人类在文明功能系统中的实质参与，或使基础范畴失去稳定校准。本文提出的扩展定义是：AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌

入或失控所引发的，可能不可逆地毁灭人类物种；或使人类永久失能，或以其他方式永久剥夺人类未来；或不可逆或难以逆转地削弱人类这一具身物种在文明中实现其主体性之基础条件的风险。其中，文明条件层面的人类主体性实现风险受**四个门槛**约束：作用于文明基础条件、具有跨领域扩散能力、可能造成不可逆或难以逆转的结构性损害、并使前三项损害汇聚为对人类未来主体能力的整体性损害。

本文提供的不是完整风险分类，也不是技术控制方案或政策清单，而是 AI 安全、AI 风险分析与 AI 治理在风险识别层面所需要的**本体论坐标系**：在讨论具体风险类型、治理路径或技术方案之前，必须先澄清“人类”这一风险承受主体及其可能受损方式。

关键词

人工智能；AI 安全；AI 风险；AI 治理；人类存在性风险；风险承受主体；概念工程；社会认识论；技术哲学；人类文明；文明条件；人类主体性；文明功能系统；哲学内核；基础范畴；范畴校准；主体性实现

1 | 引言：AI 重新打开了人类存在性风险的承受主体问题

1.1 问题的提出：技术背景与哲学追问

人工智能正在重新打开人类存在性风险问题。本文讨论的风险以 **AGI 时代** [注 1] 为背景——这里所说的“AGI 时代”，是指 AI 系统正在变得更通用、更自主、更具行动能力并更深嵌入制度的历史转变，而非预设某个公认的 AGI 阈值已被跨越。许多风险机制在此转变的早期阶段——即当前高级 AI、生成式 AI 与行动型 AI 的应用中——就已经可以被观察到。

当前 AI 的特殊性在于，它的能力扩张正在进入人类用来认识世界、形成判断、组织行动、分配责任、治理制度和理解自身的基础结构之中。AI 不再只是扩展外部能力的工具，而正在成为人类知识、制度、行动和意义结构的中介。[注 2] 它生成代码、整理证据、起草报告、辅助研究、组织工作流、推荐决策，并参与企业、教育、科研、法律、医疗、行政和公共服务等制度流程；它也开始参与 AI 系统自身的发展过程，包括辅助编码、模型评估、研究自动化和技术迭代。

这也是为什么当前 AI 风险问题不仅是技术问题，也是哲学问题。技术问题关心系统是否可靠、安全、可控、合规；哲学问题则追问：什么是真实，谁是主体，什么是责任，什么有价值，人类为何仍然需要自己判断和行动。当 AI 中介知识、行动、制度、判断与意义时，它影响的不只是人类做什么，也包括人类如何理解自身、如何承担责任、如何组织共同世界。

1.2 风险承受主体的概念滑动：不同领域对“人类”的隐含定义

然而，当前关于 AI 风险的讨论隐含了不同的风险承受主体，却鲜少有人先澄清“人类”究竟是什么。对齐研究通常默认保护的是**人类偏好** (preference)；生物安全研究默认保护的是**人类生命** (biology)；治理研究默认保护的是**人类社会秩序** (social order)；哲学讨论默认保护的是**人类价值与尊严** (value / dignity)；而存在性风险的经典框架，则主要关注**人类物种** (*Homo sapiens*)

是否灭绝。这些“人类”概念并不兼容。当它们在同一篇政策文件或技术路线图中混用时，风险识别就会在不同维度之间持续滑动：某一时刻在讨论认识论问题（模型是否输出真实），下一时刻转向生物安全问题（模型是否被恶意使用），再下一时刻又变成经济适应问题（就业是否被替代）。若风险承受主体尚未澄清，不同研究将永远缺乏可共享的本体论坐标。

许多关于 AI 存在性风险的讨论，仍然默认一种较窄的风险对象，主要指向 AI 是否可能毁灭人类物种、接管关键基础设施、永久剥夺人类未来，或以决定性方式使人类失去控制。这些风险当然是严肃的，物种灭绝、永久失能和不可逆灾难是存在性风险中最基础的形式。本文并不试图削弱这些风险的重要性。〔注 3〕

传统框架常预设一种极端情形：AI 系统可能发展出自主目标函数，并与人类利益发生决定性冲突。本文并不否定这一情形的严肃性，但也不依赖此前提。本文所讨论的风险机制，在 AI 尚未形成自主目标、仅作为人类知识、制度与意义结构的深度中介时，就已经可能发生。

1.3 本文的核心主张与方法论定位

本文要指出的是，AI 相关人类存在性风险的对象可能不止于此。当我们说 AI 可能威胁“人类”时，这里的“人类”是否只指 *Homo sapiens* 这一生物物种的延续？还是说，人类这一具身物种，也在文明条件中实现其认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义和面向未来行动的主体性能力？

如果人类只被理解为生物物种，那么 AI 相关人类存在性风险主要被限定为物理毁灭、物种灭绝、永久失能或未来控制权丧失。但如果人类也被理解为在文明条件中实现主体性的具身物种，那么 AI 可能造成的存在性损害还包括另一种形式：人类物种仍然存续，制度和技术系统仍然运行，社会仍然生产、消费和交流，但人类逐渐失去认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的能力。在这种情形中，人类并未生物学地灭绝，却可能作为未来主体受到深层削弱。

本文的核心主张是：AI 相关人类存在性风险的风险承受主体始终是人类这一具身物种；本文并不将风险承受主体扩展为文明、制度、哲学内核或 AI 系统。本文扩展的是人类这一主体可能受到存在性损害的方式：从单一生物层面上的毁灭、永久失能或未来剥夺，扩展到人类在文明条件中实现其主体性之基础条件的不可逆或难以逆转的削弱。

为此，本文建立一项概念工程〔注 4〕，区分人类这一风险承受主体的两个基本受损层面，并在文明条件层面内部单独标出范畴校准机制。生物存续层面说明人类作为具身生物种群的存续；文明条件层面说明人类如何在语言、知识、制度、责任结构、文明功能系统和意义叙事中实现主体性；范畴校准机制则说明真实、证据、责任、主体性、价值和意义等基础范畴如何在文明条件内部被澄清、维护与调整。哲学内核不是第三个平行主体，也不是独立实体，而是文明条件内部维持基础范畴可运行性的范畴校准机制。

本文因此提供的不是完整风险分类，也不是技术控制方案或政策清单。它是一项**风险识别层面的本体论坐标系**：在讨论具体风险类型、治理路径或技术方案之前，必须先澄清“人类”这一风险承受主体及其可能受损方式。只有在这一坐标系中，技术研究、政策讨论、哲学分析和社会观察才能被放置在同一个可比较、可连接、可批判的框架内。

1.4 论证安排

本文的论证安排如下。第二节给出人类这一具身物种的双维度工作定义，并说明为什么仅以生物存续层面理解人类是必要但不充分的。第三节界定人类文明作为主体性实现的跨代际条件。第四节论证哲学内核不是文明中的独立实体，而是文明条件内部的范畴校准机制。第五节使用功能性类比，帮助读者理解生物承载、范畴接口、文明运行环境和文明功能系统之间的关系。第六节说明 AI 为什么使这些条件成为存在性风险问题，并提出扩展定义与四个门槛。第七节总结全文，并说明这一概念重构对于 AI 安全、AI 风险分析和人类未来研究的意义。

2 | 人类这一具身物种：双维度工作定义

若“人类”只被理解为 *Homo sapiens* 这一生物物种，那么存在性风险将主要指向物种灭绝、永久失能和未来剥夺。这个理解抓住了最基础的风险形式，但并不足以穷尽 AI 时代的人类风险对象。本节的任务，是给出“人类”的工作定义，并说明为什么人类作为具身物种既是风险承受主体的底线，又不能压缩为单一生物存续层面。

2.1 人类的双维度工作定义

在本文中，“人类”首先指 *Homo sapiens* 这一具身生物种群。人类具有身体结构、神经系统、感知能力、认知能力、生殖机制、生理脆弱性、死亡性，以及对生态和物质环境的依赖。这个生物存续层面构成人类存在的物理前提。若人类物种灭绝，或永久失去延续、行动和塑造未来的能力，那么关于人类文明、制度、责任、价值和意义的一切讨论都将失去承载基础。

然而，人类并不只以生物存续层面存在。人类这一具身物种还在文明条件中实现其主体性：通过语言、知识、教育、制度、责任结构、公共理性、历史记忆和意义叙事，获得并维持认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的能力。

因此，本文关于“人类”的工作定义具有两个层面。第一，人类是具身生物物种；第二，人类是在文明条件中实现主体性的具身物种。前者说明人类存在的生物承载，后者说明人类为什么不只是一个生物种群，而是能够认识、判断、负责、传承、创造意义并面向未来行动的历史性存在。

这个双维度工作定义并不改变风险承受主体。风险承受主体始终是人类这一具身物种；文明、制度、文化、技术体系和哲学内核都不是与人类并列的风险承受主体。本文扩展的不是风险承受主体本身，而是人类这一主体可能受到存在性损害的方式。在本文框架中，人类的可能受损方式主要包括生物存续层面与文明条件层面；而范畴校准机制则是文明条件层面内部需要单独标出的机制，负责真实、证据、责任、主体性、价值和意义等基础范畴的澄清、维护与调整，这将在第 4 章展开。

2.2 物种灭绝作为底线风险

人类物种灭绝是人类存在性风险最直接、最严格的形式。若 *Homo sapiens* 在生物学意义上不复存在，或者人类永久失去繁衍、行动和塑造未来的能力，那么所有关于人类文明和人类未来的可能性都会随之关闭。没有具身的人类生命，就没有人类文明的持续展开，也没有人类主体性实现的承载者。

物种层风险是任何扩展定义都必须保留的底线。没有人类作为具身生命的延续，文明条件和主体性实现都无从谈起。本文所要指出的只是：物种存续是人类未来的必要条件，但不是充分条件。人类可以在生物学意义上继续存在，却在文明意义上逐渐失去某些使其作为认识者、判断者、责任者、制度参与者和意义创造者而继续存在的基础能力。

2.3 具身性：人类不是纯信息结构

强调人类作为具身物种，意味着不能将人类还原为纯粹信息结构、抽象理性主体或可任意迁移的计算模式。人类的认知、情感、判断、学习、关系、责任和意义，都与身体条件密切相关。感知世界依赖身体，语言学习依赖具身经验和社会互动，责任承担依赖行动能力和对后果的承受能力，意义形成也与出生、死亡、时间、痛苦、依赖、关系和有限性有关。

在 AI 语境下，这一点尤其需要被保留。随着 AI 系统越来越多地承担认知任务、生成文本、组织知识、提出方案和参与决策，人类很容易被理解作为一种可以被更高效信息处理系统替代的认知实体。然而，人类的存在并不只是信息处理。人类文明中的真实、责任、主体性和意义，都与具身有限性有关。一个会死亡、会受伤、会承诺、会后悔、会在时间中成长并承担后果的存在，与一个无身体、无死亡、无脆弱性的信息系统，并不处于同一存在结构中。

强调具身性，并不意味着人类文明排除非人技术成分。文字、工具、机器、城市、平台系统和 AI 系统，都可以成为人类文明的组成要素或中介结构。关键在于：即使技术深度进入文明，本文讨论的风险承受主体仍然是具身的人类，而不是技术系统、文明系统或 AI 系统本身。技术可以中介人类主体性实现，也可能削弱其条件，但它并不取代人类成为本文意义上的风险承受主体。

2.4 物种连续性不等于文明条件连续性

人类物种的连续性，主要通过生物繁殖、代际延续和种群稳定来维持。只要人类仍然能够繁衍、存活并保持基本生物结构，物种层意义上的延续就仍然存在。文明条件的连续性则不同。它依赖语言、记忆、教育、制度、知识、规范、技术、责任结构和意义叙事的传递。它不仅要求下一代人出生，也要求下一代人进入一个可理解、可继承、可批判和可更新的世界。

因此，物种连续性与文明条件连续性之间并不存在自动等价关系。一个社会可以在生物学意义上延续，却发生文明条件的严重断裂。人们仍然出生、劳动、消费和娱乐，但他们所进入的共同世界可能已经无法稳定维持知识、责任、判断和意义传承。如果这种退化不可逆或难以逆转，它就不只是普通社会变化，而可能成为人类主体性实现条件的结构性损害。

这意味着，某些风险可能不直接杀死人类，却使人类逐渐失去认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义和面向未来行动的能力。不能因为人类物种仍然存续，就断定人类未来仍然开放；也不能因为某种损害不表现为物理毁灭，就断定它不具有存在性意义。

2.5 小结

本节给出了“人类”的双维度工作定义。人类首先是 *Homo sapiens* 这一具身生物种群；物种灭绝、永久失能和未来剥夺仍然是人类存在性风险的底线形式。但人类并不只是生物种群，也不是纯信息结构。人类这一具身物种还在文明条件中实现认识、判断、责任、制度参与、意义创造和面向未来行动等主体性能力。

因此，仅以物种生存理解 AI 相关人类存在性风险，是必要的，但不充分。下一节将进一步分析人类主体性实现所依赖的文明条件：人类文明如何作为一个跨代际共同世界，使人类这一具身物种能够成为认识者、判断者、责任者、制度参与者、意义创造者和未来主体。

3 | 人类文明：主体性实现的跨代际条件

上一节给出了人类的双维度工作定义。本节将界定人类文明——人类主体性实现的跨代际条件。

3.1 文明与人类文明：本文的范围限定

本文不提出关于一切可能文明的一般理论。除非特别说明，本文所说的“文明”均指“人类文明”。所谓人类文明，是指人类这一具身物种在历史中通过语言、知识、制度、法律、教育、责任结构、技术实践和意义叙事形成的跨代际共同世界。它由可传递、可修正、可继承的符号—制度—技术结构构成，使个体能够进入大于其生物生命的历史—理解空间，并作为认识者、判断者、责任者、制度参与者和意义创造者而存在。

人类文明并不意味着一个只由人类个体组成、排除非人技术成分的封闭系统。文字、工具、机器、城市、法律文本、互联网、平台系统和 AI 系统，都可以成为人类文明的组成要素或中介结构。人类文明之所以是“人类”的，不在于其中没有非人元素，而在于它以人类这一具身物种为风险承受主体，并以人类主体性实现为其规范性焦点。

因此，人类文明不是人类之外的独立承受者，而是人类主体性实现的构成性条件。它不是人类物种的装饰，也不是人口、国家、文化或技术体系的简单总和，而是人类得以跨个体、跨制度、跨时代地认识、判断、负责、传承和创造意义的共同世界。

3.2 人类文明不是人口总和

人类文明不能被还原为人口数量。大量人类个体的同时存在，并不自动构成文明。人口提供文明的生物承载，但人口本身并不自动产生可传递的语言结构、知识体系、制度规范、责任机制和意义叙事。文明要求某种跨个体、跨群体和跨代际的结构，使知识、规范、制度、责任和意义能够被保存、传递、批判和更新。

一个人口规模庞大的社会，如果缺乏稳定的语言、记忆、教育、制度、责任结构和知识传承，就难以维持复杂文明条件。相反，某些文明传统即使在人口、地域或政治权力上经历巨大损失，仍可能通过语言、文本、教育、礼法、制度记忆、宗教、艺术和哲学传统继续影响后代。由此可见，文明条件的连续性与人口连续性之间并不存在自动等价关系。

3.3 人类文明不是国家

人类文明也不能等同于国家。国家是政治和法律组织形式，通常具有领土、主权、行政结构、法律体系、公共财政和强制权力。人类文明则是更深、更宽、更长时段的跨代际共同世界。一个文明传统可以跨越多个国家，一个国家也可以承载多个文明传统。现代国家还普遍嵌入全球科学体系、金融体系、国际法体系、技术标准、数字平台和跨国供应链之中，这些结构并不完全属于单一国家内部。

现代科学体系、大学制度、医学知识、工程标准、法治语言、市场机制、国际贸易、金融基础设施和互联网协议，都以不同方式跨越国家边界。国家可以组织、保护、调节或扭曲这些系统，但国家本身并不等同于文明整体。同样，任何一种具体文明传统也不能被简单压缩为某一个当代国家。

因此，国家可以被理解为文明条件在特定历史、地理、法律和政治环境中的具体组织形式。人类文明则是更上位、更持久、更复杂的跨代际共同世界。

3.4 人类文明不是文化的同义词

人类文明也不应被简化为文化。文化是文明的重要组成部分，尤其表现为语言、习俗、艺术、审美、仪式、故事、身份、风俗和生活方式。文化使文明中的记忆、价值和意义以可体验、可表达、可传承的方式进入日常生活。没有文化，文明会失去可生活的界面。

但是，文明不仅包括文化。它还包括科学、法律、制度、教育、经济、技术、公共理性、医学、工程、行政、基础设施和责任结构。若将文明仅仅理解为文化，就会低估文明中那些支撑真实、责任、制度和知识运行的结构。一个社会可以拥有丰富文化，却仍然在科学、法律、制度或责任结构上严重脆弱。反过来，一个高度技术化和制度化的社会，也可能在文化和意义层面出现深刻空洞。

因此，文化可以被理解为文明的意义表达层和日常生活界面，但文明还包括更深的知识、制度、责任和技术结构。

3.5 人类文明不是技术体系

人类文明同样不能被还原为技术体系。技术是文明的重要组成部分，并且常常深刻改变文明形态。从农业、冶金、航海、印刷、电力、计算机到人工智能，技术不断扩展人类行动能力和组织规模。然而，文明并不只是工具集合，也不是效率系统。文明还包含价值、规范、责任、公共理性、意义和人类对未来的理解。

现代技术社会容易将文明进步等同于能力增长、效率提高、信息扩张和自动化程度提升。然而，能力增长并不自动等于文明条件健康。一个系统可以越来越高效，却越来越难以分配责任；可以生成越来越多内容，却越来越难以验证真实；可以自动化越来越多流程，却越来越少培养人的判断能力；可以提供越来越多便利，却越来越难回答人为什么继续学习、创造、承担责任和保护未来。

因此，文明不能被定义为技术能力的总和。技术是文明中的强大系统，但技术本身不提供最终目的，不定义责任，不保证真实，也不自动生成意义。若没有更深的文明条件，技术增长可能带来能力扩张，却未必带来人类主体性实现的成熟。

3.6 人类文明整体：多重文明传统构成的共同生态

本文所说的人类文明，并不等同于某一个国家、某一种文化、某一个历史文明传统，也不是将某一具体文明形态普遍化为全人类。人类文明应被理解为由多重文明传统、共享制度接口、知识交换、技术基础设施、冲突经验和跨代际传承结构共同构成的总体性文明生态。不同文明传统可能拥有不同语言、宗教、制度、法律、知识传统、艺术形式和意义叙事，但它们共同构成人类这一具身物种在历史中形成的跨代际共同世界。

若人类文明被理解为某一种文明传统的扩大化，那么 AI 相关人类存在性风险就容易被误读为某个

文化、国家或地区的内部问题。若人类文明被理解为多重文明传统的机械相加，那么不同传统之间的共享结构、交叉依赖和共同脆弱性又会被低估。更准确地说，人类文明整体既包含差异，也包含共同接口；既保留多样性，也具有某些现代全球运行条件。

现代全球文明生态已经使不同文明传统之间形成前所未有的相互嵌入。现代科学体系、大学制度、国际法、公共卫生系统、全球贸易、金融网络、互联网协议、数字平台、标准化技术系统和 AI 基础设施，都不再完全属于某一个文明传统、国家或文化内部。它们构成了跨文明运行的共同接口，使不同传统在知识、技术、制度、经济和治理层面持续发生相互依赖。

这并不意味着人类文明已经成为一个同质整体。不同文明传统仍然保留不同的历史记忆、宗教结构、法律传统、家庭伦理、政治想象、教育方式和意义叙事。它们对真实、责任、主体性、价值和意义等基础范畴，也可能给出不同回答。因此，本文并不主张存在一个完全统一、无差异的人类文明。本文所说的人类文明整体，是一个由差异性传统和共同性接口共同构成的文明生态。

3.7 人类文明作为跨代际共同世界

更准确地说，人类文明是跨代际共同世界。它通过语言、记忆、制度和教育，使过去能够传递给未来，使个体生命能够进入一个大于自身的历史结构。个体生命是有限的。一个人出生时并不从零开始。他进入已经存在的语言，接受已有制度和知识，继承他未曾亲自创造的历史记忆、科学成果、法律结构、伦理规范和意义叙事。文明正是这种跨代际结构：它使人能够站在前人的基础上判断、创造和负责，也使一代人的行动能够对未来代际产生意义。

这种跨代际性使文明条件具有与物种连续性不同的脆弱性。物种延续主要依赖生物繁殖；文明条件延续则依赖传承、理解和更新。若下一代人只是生物学地出生，却没有进入能够培养判断、责任、真实和意义的共同世界，那么人类主体性实现条件就会被削弱。文明条件的真正延续并不只是“有人活着”，而是“有人能够理解、继承、批判和更新一个共同世界”。

因此，将文明理解为跨代际共同世界，有助于识别那些不以物理灾难形式出现、却可能改变人类未来主体能力的风险。文明条件的延续要求的不只是数据保存、内容生成和制度运行，而是人类仍然能够进入、理解、判断并更新这个共同世界。

3.8 文明功能系统与人类参与结构

人类文明并不是一个抽象整体，而是通过一组文明功能系统具体运行。经济、法律、教育、科学、国家治理、文化、媒体、医疗、行政、基础设施、宗教和艺术等系统，构成人类实际进入文明条件的主要路径。普通人通常不是直接面对“文明”这一抽象对象，而是通过学校、法院、实验室、市场、媒体、政府机构、平台系统、家庭、宗教传统、艺术实践和公共服务进入共同世界。

这些文明功能系统不是文明的外在附属物，而是人类主体性实现的重要承载结构。人类通过教育系统学习如何理解、判断和提问；通过科学系统参与知识生产和证据检验；通过法律系统理解责任、权利和义务；通过经济系统参与劳动、交换和资源组织；通过国家与治理系统参与公共决策和制度方向；通过文化与媒体系统表达意义、传承记忆和形成公共想象。人类主体性并不只在个体内部发生，也通过这些系统中的参与结构被实现。

所谓“参与结构”，是指人类在文明功能系统中作为劳动者、学习者、判断者、创造者、公民、责任承担者和未来主体参与共同世界运行的方式。若人类在这些系统中只保留形式性确认，而不再真正理解、判断、负责、创造或塑造方向，那么人类在文明条件中的主体性实现就会受到削弱。

3.9 人类文明作为认识、责任与意义结构

人类文明作为跨代际共同世界，至少包含三种功能性结构：认识结构、责任结构和意义结构。

首先，人类文明提供认识结构。人类不是单独面对世界并独立重新发明知识。人类通过语言、教育、科学方法、证据规则、文献系统、记录制度、同行评审和公共讨论来认识世界。文明条件使个体能够分享、批判、保存和修正知识。没有某种稳定的认识结构，人类就难以区分事实与传闻、证据与叙述、解释与伪造、知识与意见。

其次，人类文明提供责任结构。人类通过文明条件定义行动者、承诺、义务、过失、权利、惩罚、补偿和制度责任。没有责任结构，复杂社会无法维持信任，也无法处理伤害、错误、冲突和承诺。责任结构依赖行动可归因、主体可识别、规范可解释、证据可检验、程序可追踪等条件。

最后，人类文明提供意义结构。人类不只是一要活着，也要理解为什么学习、为什么工作、为什么创造、为什么承担责任、为什么保护未来。文明通过宗教、哲学、艺术、教育、家庭、传统、政治理想和公共叙事来组织意义。意义不是可有可无的心理装饰，而是使个体行动、责任、学习、创造、牺牲和未来承诺具有可理解性的结构。

认识结构、责任结构和意义结构共同说明，人类文明不是人口、国家、文化或技术体系的简单加总。它是使人类能够认识、判断、负责、传承和创造意义的共同世界。若这些结构被系统性削弱，人类主体性实现条件就会受到损害。

这些结构之所以能够稳定运行，还依赖更底层的基础范畴及其校准机制。下一节将进一步说明：文明功能系统运行时必须调用哪些基础范畴？这些范畴如何被澄清、维护和调整？本文将把这一机制称为哲学内核，即文明条件内部的范畴校准机制。

4 | 哲学内核：文明条件内部的范畴校准机制

上一节说明文明承载认识、责任与意义结构。这些结构之所以能够稳定运行，还依赖更底层的基础范畴及其校准机制。本节将追问：文明功能系统运行时必须调用哪些基础范畴？这些范畴如何被澄清、维护和调整？

4.1 哲学内核的定义与范围

本文所说的哲学内核，不是基础范畴本身的集合，而是文明条件内部维持基础范畴可运行性的范畴校准机制。它具有元机制属性：这里所谓“元”，并不是指它构成文明条件之外的更高实体，也不是指它成为第三个风险承受主体，而是指它所校准的不是某一个文明功能系统内部的局部规则，而是科学、法律、教育、政治、经济、文化等功能系统共同调用的基础范畴接口。这里的“哲学”并不首先指学院制度中的哲学学科，也不只是由专业哲学家写成的理论文本。更准确地说，哲学内核指基础范畴在历史中被显化、检验、澄清、批判、维护和调整的操作机制；真实、证据、责任、主体性、价值和意义等基础范畴，是其校准对象和概念接口。

哲学内核不是文明中的独立实体，也不是与科学、法律、政治、教育、经济、文化和艺术并列的普通部门，更不是风险承受主体。它作用于一组底层范畴接口：科学需要真实和证据的范畴，法律需要主体、意图、责任和归因的范畴，政治需要合法性、公共性和权力正当性的范畴，教育需要关于人、成长、知识和目的的范畴，经济需要价值、偏好、交换和分配正当性的范畴，文化与艺术需要

意义、表达和共同经验的范畴。若这些基础范畴失去稳定性，文明功能系统仍可能继续运转，但其运行将逐渐漂移到不可解释、不可追责、不可校准的状态之中。

在这个意义上，将哲学称为“内核”并不是修辞上的抬高，而是功能层级上的判断。内核并不意味着哲学在历史上总是先于文明，也不意味着文明由一套预先写好的哲学理论推导而来。它意味着：文明功能系统在运行时不可避免地依赖关于真实、证据、责任、主体性、价值和意义的基础范畴；当这些范畴无法被澄清、维护和调整时，文明并非只失去一个学科或一种文化传统，而是失去维持其基础范畴稳定性的底层机制。

因此，哲学内核的本体位置必须被明确限定：它是文明条件内部的范畴校准机制，不是与文明条件并置的独立维度，也不是第三个风险承受主体。风险承受主体始终是人类这一具身物种；文明条件是主体性实现的跨代际共同世界；哲学内核则是使基础范畴得以澄清、维护与调整的内部机制。

4.2 基础范畴与现代全球文明生态

基础范畴不是先验适用于一切可能文明的永恒框架，也不是某一文明传统独占的理论词汇。不同文明传统可以用不同语言、宗教、礼法、制度、政治想象和知识传统来组织真实、责任、主体性、价值和意义等问题。但只要一个文明能够区分真伪、积累知识、分配责任、组织行动、评判价值并解释意义，它就已经在调用某种基础范畴配置。

现代全球文明生态使这些范畴具有新的共同性。科学知识、法律责任、技术治理、公共决策、教育传承、数字平台、国际制度和跨国市场已经深度交织。一个国家或文明传统内部的知识制度，往往依赖全球科研网络、技术标准、数字基础设施和国际制度接口；一个地区的 AI 系统部署，也可能通过平台、供应链、数据生态和公共话语结构影响其他地区。正是在这一语境下，真实、证据、责任、主体性、价值和意义成为 AI 风险分析中不可回避的基础范畴。

这并不意味着不同文明传统对这些范畴有完全一致的理解。真实可以通过不同知识传统被组织，责任可以通过不同法律和伦理体系被分配，主体性可以通过不同人格、家庭、社群和政治观念被理解，价值和意义也可以通过不同宗教、哲学、文化和历史经验被解释。本文的论点并不是要抹平这种多样性，而是指出：无论这些范畴的具体回答如何不同，现代全球文明生态中的知识、制度、技术和治理系统都必须以某种方式调用这些接口。

因此，基础范畴既不是纯粹先验的，也不是任意相对的。它们具有功能必要性：若没有真实和证据，知识无法稳定积累；若没有责任，行动无法被归因；若没有主体性，判断、同意、授权和责任承担失去基础；若没有价值，技术优化失去目标；若没有意义，学习、创造、责任和未来承诺失去理由结构。

4.3 六组基础范畴的功能位置

本文重点讨论六组基础范畴：真实、证据、责任、主体性、价值和意义。它们不是人类文明的全部基础概念，但足以标示本文关心的范畴校准机制。

真实范畴使文明能够区分真实与虚假、事实与叙述、知识与意见、解释与伪造。没有真实范畴，知识生产会变成内容生产，公共讨论会失去共同指向，制度判断也会缺乏可检验的对象。

证据范畴回答什么可以支持某个判断，什么可以反驳某个判断，什么可以进入公共理由交换。没有证据范畴，科学、法律、教育、媒体和公共治理都难以稳定区分可靠与不可靠、可验证与不可验证、推断与猜测。

责任范畴将行动、主体、授权、意图、过失、后果和义务连接起来。没有责任范畴，社会仍可能产生结果和后果，但越来越难以追问谁行动、谁授权、谁知情、谁能够阻止、谁应当承担后果。

主体性范畴回答谁能够判断、同意、拒绝、授权、行动、担责和代表自身。没有主体性范畴，法律、政治、教育、伦理和制度参与都会失去基础，因为这些系统都需要某种关于主体能力与主体资格的理解。

价值范畴使文明能够在安全、自由、效率、真实、尊严、正义、创新、稳定、繁荣和意义之间进行排序。没有价值范畴，技术系统可以持续优化，但文明将难以说明优化究竟服务于什么。

意义范畴回答为什么学习、为什么创造、为什么承担责任、为什么保护未来、为什么人类仍然重要。没有意义范畴，社会可以继续生产、消费、娱乐和优化，但人类行动、责任和未来承诺将越来越难以获得共同解释。

这六组基础范畴共同构成文明功能系统运行时必须调用的底层接口。它们并不是彼此孤立的词语，而是相互支撑的范畴网络。真实需要证据来校准，责任需要主体性来承载，价值需要意义来解释，意义也需要真实、责任和价值来避免滑向任意叙事。哲学内核的功能，正是维持这些范畴之间的可区分性、可连接性和可修正性。

4.4 范畴校准机制如何工作

所谓范畴校准机制，是指基础范畴在历史中被显化、检验、批判、维护和调整的过程。它并不意味着有一个单一中心能够统一管理所有范畴，也不意味着某一学科可以垄断范畴解释权。它指的是：在文明条件中，基础范畴能够通过哲学、科学、法律、公共讨论、教育、制度改革、文化实践和历史经验不断被澄清和修正，从而避免功能系统长期运行在失准的范畴之上。

范畴校准不同于局部纠错。局部纠错可以处理某个模型错误、某个法律漏洞、某个政策失败或某个教育问题。范畴校准处理的是更基础的问题：什么算作错误，什么算作证据，谁能够承担责任，什么构成判断，什么值得优化，什么仍然有意义。若这些问题无法被提出和处理，文明功能系统可能仍然继续运行，但其运行将越来越依赖惯性、效率和自动化，而不是理解、判断和责任。

范畴校准也不同于单纯价值宣言。一个社会可以反复宣称自己重视真实、责任、尊严或意义，但如果这些范畴无法被制度化、教育化、公共化，并在实践中接受检验和修正，那么宣言就无法转化为稳定的文明条件。范畴校准要求基础范畴能够在具体社会机制中被持续调用、追问和更新。

因此，哲学内核不是抽象观念的储藏室，而是文明条件内部维持基础范畴可运行性的动态机制。它既存在于理论反思中，也存在于法律程序、科学规范、教育训练、公共争论、制度改革和文化实践中。它的作用不是让文明停留在某个固定答案上，而是使文明在面对新技术、新制度和新风险时，仍然能够重新澄清自己所调用的基本概念。

若基础范畴的校准机制失效，文明功能系统即使继续运行，也可能逐渐失去其可解释、可追责和可修正的基础。

4.5 基础范畴、文明基础条件与主体性能力的映射关系

为了避免概念漂移，需要区分三套相关但不相同的清单：基础范畴、文明基础条件和主体性能力。

第一，基础范畴是文明功能系统运行时必须调用的概念接口。本文重点讨论真实、证据、责任、主体性、价值和意义。它们回答的是文明系统在概念上如何区分和组织世界。

第二，文明基础条件是这些基础范畴在文明功能系统中维持可运行性的条件。本文重点关注五类：真实与证据的可校准性，责任与授权的可归因性，主体性与判断的可维持性，价值排序的可反思性，意义传承的可理解性与可延续性。它们回答的是：这些基础范畴是否仍能在文明实践中被稳定调用、检验和修正。

第三，主体性能力是人类在文明条件中实际行使的能力。本文重点关注六类：认识真实，形成判断，承担责任，参与并维持制度，传承并创造意义，面向未来行动。它们回答的是：人类是否仍能作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体而存在。

这三套清单并不是彼此独立的并列列表。更准确地说，基础范畴为文明基础条件提供概念接口；文明基础条件又支撑人类主体性能力的实际行使。若真实与证据无法被校准，人类就难以认识真实和形成判断；若责任与授权无法被归因，人类就难以承担责任和维持制度；若主体性与判断无法被维持，人类就难以作为行动者和未来主体参与共同世界；若价值排序无法被反思，技术和制度优化就可能脱离人类目的；若意义传承无法被理解和延续，人类就会失去学习、创造、负责和保护未来的理由结构。

这个映射关系也说明，本文并不是简单列举抽象概念，而是在说明人类主体性实现的条件结构。基础范畴是概念接口，文明基础条件是运行条件，主体性能力是人类在文明中的实际实现。

4.6 “主体性范畴”与“主体性实现”的消歧

本文多次使用“主体性”一词，因此必须明确它在两个层次上的不同含义。

作为基础范畴的主体性，指关于谁能够判断、同意、授权、行动、负责和代表自身的概念结构。它属于范畴校准机制的一部分。法律系统、政治系统、教育系统、伦理关系和公共治理都必须依赖某种主体性范畴，才能决定谁可以签署、谁可以负责、谁可以被授权、谁可以同意或拒绝、谁具有行动能力和责任能力。

作为人类主体性实现中的主体性，则指人类实际行使认识、判断、责任、制度参与、意义创造和未来塑造等能力。它不是一个抽象概念，而是人类在文明条件中展开自身存在方式的实际能力。人类之所以不只是生物种群，正是因为人类能够在文明条件中认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动。

这两个层次不能混淆。作为基础范畴的主体性，是人类主体性实现的范畴条件；作为实际能力的主体性实现，则是这些范畴条件在人类文明中的实际展开。前者不是后者的重复说法，而是后者得以被理解、制度化和维护的概念前提。

这一消歧对于 AI 风险分析非常重要。AI 既可能削弱人类主体性实现的实际能力，也可能使主体性范畴本身变得模糊。前者属于主体性能力的削弱，后者属于主体性范畴的失准。二者相互关联，但不能混为一谈。

4.7 本节小结

本节将哲学内核界定为文明条件内部的范畴校准机制。哲学内核不是文明中的独立实体，也不是与人类文明并列的第三个层面，更不是风险承受主体。风险承受主体始终是人类这一具身物种。哲学内核的作用，是说明人类文明如何维持真实、证据、责任、主体性、价值和意义等基础范畴的可解释性、可追责性和可修正性。

本节同时区分了基础范畴、文明基础条件和主体性能力三套清单。基础范畴为文明基础条件提供概念接口；文明基础条件支撑人类主体性能力的实际行使。通过这一映射关系，本文可以避免把哲学内核实体化，也可以避免把文明条件写成抽象背景。

下一节将使用功能性类比，将前文关于人类物种、人类文明、哲学内核和文明功能系统之间的关系转化为一个更直观的结构图。这个类比不是本体模型，而是帮助读者理解生物承载、范畴接口、文明运行环境 and 应用层功能系统之间的关系。

5 | 硬件—内核—发行版—应用层：理解结构关系的功能性类比

前文已分别说明人类物种、人类文明、哲学内核和文明功能系统的地位。这些关系较为抽象，本文引入一个功能性类比帮助理解。

5.1 类比的有限用途与边界

首先必须明确：人类不是机器，哲学不是代码，文明不是软件。本文使用硬件—内核—发行版—应用层的类比，并不是为了将人类文明技术化，也不是为了用计算机系统替代哲学分析。它只是一个有限的教学隐喻，用来说明四个功能关系。〔注 5〕

第一，人类文明需要具身生物承载，就像计算系统需要物理硬件。第二，文明功能系统需要基础范畴接口，就像应用程序需要底层系统服务。第三，人类实际生活在完整的文明运行环境中，而不是直接生活在抽象范畴中；这类似于普通用户通常进入完整发行版，而不是直接面对内核。第四，科学、法律、教育、经济、政治、文化、媒体、行政等文明功能系统，可以粗略类比为应用层，因为它们是人类日常实际进入共同世界的主要界面。

这个类比有助于避免两个误读。第一个误读，是以为人类物种存续就等于人类主体性实现条件完整。第二个误读，是以为文明功能系统仍然运行，就说明底层范畴仍然健康。事实上，一个系统可以在外观上持续运行，甚至运行得更快、更高效、更自动化，但底层接口已经变得不可解释、不可追责或不可校准。

因此，本节所有类比都必须服从一个限定：它们只解释功能关系，不决定本体关系。非类比地说，风险承受主体始终是人类这一具身物种；文明、哲学内核、功能系统和 AI 都不是与人类并列的风险承受主体。

5.2 人类物种作为硬件：生物承载

在人类存在的结构关系中，人类物种提供最基础的生物承载。以计算机系统作类比，它类似于硬件。硬件提供系统运行的物质基础。没有处理器、内存、存储、电源和输入输出设备，任何内核、发行版和应用程序都无法实际运行。类似地，没有人类身体、大脑、神经系统、感知能力、生殖机制、死亡性和生态依赖，人类文明也无从持续展开。

这个类比有助于说明物种层风险的底线地位。人类文明不是脱离身体而漂浮的信息云。语言学习、教育传承、情感发展、伦理关系、责任承担和意义形成，都依赖具身的人类生命。若人类物种灭绝，或永久失去延续和行动能力，那么文明条件、范畴校准机制和功能系统都将失去承载者。

但硬件并不等于完整运行环境。一台仅有硬件而没有内核、文件系统、用户环境和应用程序的计算机，并不是一个可用系统。类似地，人类作为生物物种存在，并不自动产生科学、法律、教育、制度、责任结构、历史记忆和意义叙事。物种存续是必要条件，但不是充分条件。

因此，人类物种作为“硬件”的类比，只说明生物承载功能，而不能将人类还原为机器部件。人类作为具身物种具有死亡性、脆弱性、历史性和关系性，这些都不能被计算机硬件概念充分表达。

5.3 哲学内核作为内核：范畴接口的校准

如果人类物种可以类比为硬件，那么哲学内核可以类比为内核。以内核为例，它不是用户日常直接操作的完整系统，却为上层系统提供底层接口：资源调度、权限边界、系统调用、进程管理和硬件抽象。应用程序通常不会直接面对硬件，而是通过内核提供的接口运行。若内核层接口发生严重失准，应用层仍可能启动，但系统稳定性、可控性和可靠性都会受到影响。

对应到人类文明中，哲学内核并不是指某套固定哲学理论支配文明，也不是指学院哲学在制度上高于科学、法律、政治、教育、经济或文化。它指的是文明条件内部维持基础范畴可运行性的校准机制，而不是基础范畴本身的集合。科学需要真实和证据的接口，法律需要主体、责任和归因的接口，政治需要合法性和公共性的接口，教育需要知识、成长和目的的接口，经济需要价值、偏好和分配正当性的接口，文化与艺术需要意义、表达和共同经验的接口。

将哲学内核类比为内核，有助于说明它的底层接口功能。它并不生产所有文明内容，却影响文明功能系统能否稳定调用基础范畴。若真实与证据的接口失准，科学和教育仍可继续生产内容，但知识与现实之间的连接会变得脆弱。若责任与授权的接口失准，法律和行政仍可继续运行程序，但行动与后果之间的归因会变得不稳定。

不过，这个类比不能被过度实体化。哲学内核不是代码，也不是一个可单独安装、替换或重启的模块。真实、证据、责任、主体性、价值和意义等基础范畴，存在于语言、制度、教育、法律、科学、公共争论和历史经验之中。哲学内核之所以被称为“内核”，只是因为它在功能上承担基础范畴接口的校准作用，而不是因为它具有计算机内核那样的物理或程序结构。

5.4 人类文明作为发行版：完整运行环境

在计算机系统中，发行版围绕内核提供的接口，组织系统工具、库、配置、权限结构、用户界面和维护生态，从而形成一个可实际使用的运行环境。这个类比并不要求我们把“发行版—内核”关系理解为严格的本体包含关系；它只说明：上层运行环境需要调用底层接口，而底层接口也只有通过具体运行环境 and 应用层实践，才成为用户可实际进入的系统。

对应到本文，人类文明可以类比为完整运行环境。人类文明不是基础范畴本身，也不是某一制度或某一技术系统，而是由语言、知识、法律、教育、经济、政治、文化、技术、责任结构、历史记忆和意义叙事共同构成的跨代际共同世界。哲学内核则作为文明条件内部的范畴校准机制，维持文明功能系统所调用的基础范畴接口。这个类比只说明调用、依赖和接口关系，不规定本体包含关系。人类个体进入文明，不是直接进入抽象范畴，而是进入家庭、学校、法律、媒体、科学共同体、工作组织、文化传统、技术平台和公共制度构成的具体环境。

这个类比有助于说明人类文明与哲学内核之间的关系。人类文明并不是哲学内核的容器，而是调用基础范畴接口的完整运行环境。哲学内核校准文明功能系统所调用的基础范畴接口；人类文明则是

这些接口、制度、实践、技术、记忆和意义叙事共同形成的历史性运行环境。人类不是在抽象范畴中生活，而是在这个完整运行环境中学习、判断、负责、创造意义并面向未来行动。

发行版类比还说明，运行环境可以看似完整，却在底层接口上出现失准。一个发行版可能仍然启动，界面仍然响应，应用仍然运行，但底层权限、资源调度或系统调用若出现严重问题，系统就会逐渐变得不可靠。类似地，一个社会可能仍然有学校、法院、媒体、市场、政府和文化生产，甚至这些系统运行得更高效，但如果真实、证据、责任、主体性、价值和意义等基础接口失准，人类主体性实现条件仍可能受到结构性削弱。

因此，人类文明作为发行版的类比，不是为了把文明软件化，而是为了说明：人类实际生活在一个由多重系统、制度、实践和意义结构构成的运行环境中。这个环境既依赖具身人类，也依赖基础范畴接口，还依赖具体文明功能系统的运作。

5.5 文明功能系统作为应用层

在这一类比中，科学、法律、政治、教育、经济、文化、媒体、行政、医疗、宗教和艺术等系统，可以粗略类比为应用层。应用层直接处理具体任务：生产知识、裁决争议、组织权力、培养下一代、分配资源、表达意义、治疗疾病、提供服务、传播信息、维持仪式和解释生活。人类日常生活中接触最多的，往往不是基础范畴本身，也不是“文明”这一抽象整体，而是这些功能系统。

普通人通常不是通过阅读哲学定义进入文明，而是通过学校学习知识，通过家庭学习关系和责任，通过法院理解权利和义务，通过市场参与劳动和交换，通过科学系统理解证据和方法，通过媒体接触公共叙事，通过国家与治理系统参与公共事务，通过文化、宗教和艺术理解意义。文明功能系统是主体性实现的应用层界面。

应用层的特点是可见、可评估、可优化。一个系统是否运行，任务是否完成，流程是否加快，用户是否满意，这些通常比较容易观察。现代 AI 也最容易在应用层显示其价值：提高生产率、降低成本、辅助写作、自动分析、加速流程、个性化服务、降低知识门槛。

但是，应用层繁荣并不等于系统整体健康。一个社会可以产生更多报告、更多图像、更多分析、更多建议、更多评价和更多决策，却同时越来越难以确认这些输出与真实、责任、判断和意义之间的关系。一个文明功能系统也可以继续运行，甚至更高效运行，但如果它逐渐不再需要人类理解、判断、劳动、创造、公共参与和责任承担，那么人类在其中的主体性实现条件就会被削弱。

因此，文明功能系统作为应用层的类比，为后文的 AI 风险分析提供了中间桥梁。人类并不只是文明功能系统的用户、消费者或被服务对象，还应当是劳动者、学习者、判断者、创造者、公民、责任承担者和未来主体。后文将进一步说明，AI 如何可能改变应用层中人类的参与结构，或使人类对基础范畴的校准失去稳定把握。

5.6 非类比地说明结构关系

非类比地说，人类物种、人类文明、哲学内核和文明功能系统不是四个并列实体，也不是四个风险承受主体。它们分别说明同一风险承受主体——人类这一具身物种——得以存在和实现主体性的不同条件。

人类物种提供生物承载。没有具身的人类生命，就没有人类文明、主体性实现或未来承诺。人类文明提供主体性实现的跨代际共同世界。没有语言、知识、制度、责任结构、历史记忆和意义叙事，

人类就难以作为认识者、判断者、责任者和意义创造者而存在。哲学内核作为文明条件内部的范畴校准机制，维持真实、证据、责任、主体性、价值和意义等基础范畴的可解释、可追责和可修正。文明功能系统则是人类实际参与这些条件的应用层，使人类通过科学、法律、教育、经济、文化、治理和公共服务进入共同世界。

因此，AI 相关人类存在性风险不能只被理解为某个技术系统是否伤害人类身体，也不能只被理解为某个社会应用是否带来局部问题。AI 可能作用于生物承载，可能改变文明运行环境，可能削弱人类在功能系统中的参与结构，也可能扰动基础范畴的校准机制。所有这些风险最终都必须回到同一个问题：人类这一具身物种是否仍能在文明条件中实现其主体性。

本节类比的最终目的，就是帮助读者理解这一结构关系。硬件—内核—发行版—应用层不是新的本体框架，而是一个说明工具。它让我们看到：人类主体性实现既需要身体承载，也需要底层范畴接口，还需要完整文明运行环境和具体功能系统。任何一层被系统性削弱，都可能影响人类作为未来主体的能力；但风险承受主体始终不是这些层本身，而是人类这一具身物种。

下一节将转向本文的核心定义问题：AI 为什么使这些条件成为存在性风险问题？AI 如何可能作用于生物存续、文明条件和范畴校准机制？在什么门槛下，这些作用才构成 AI 相关人类存在性风险？

6 | AI 为什么使这些条件成为存在性风险问题：扩展定义与门槛

前文已说明，AI 相关人类存在性风险的承受主体始终是人类这一具身物种；人类的可能受损方式，不仅包括生物存续层面的毁灭或永久失能，也包括文明条件层面中主体性实现基础的不可逆或难以逆转的削弱；在文明条件层面内部，AI 还可能扰动真实、证据、责任、主体性、价值和意义等基础范畴的校准机制。本节将在此基础上回答：AI 的发展、部署和深度嵌入，如何可能作用于这些受损面和机制？又在什么门槛下，这些作用才不只是普通社会风险，而是进入 AI 相关人类存在性风险的范围？

6.1 本节边界：不是完整风险分类

本节不是 AI 风险类型的完整分类，也不是后续治理方案的展开。本节的任务更窄：说明 AI 为什么可能触及人类存在性风险的基础条件，并给出本文的扩展定义与判断门槛。

本节不把“AI 与生物存续”“AI 与文明条件”“AI 与范畴校准”当作三个独立风险类型。它们只是说明同一个风险承受主体——人类这一具身物种——可能在不同层面或机制上受到损害。同样，本节也不把任何 AI 引发的社会变化都直接称为存在性风险。〔注 6〕只有当某种变化作用于人类主体性实现的基础条件，并具有跨领域、结构性、不可逆或难以逆转的后果时，它才进入本文的扩展存在性风险范围。

6.2 AI 与生物存续层面

首先，AI 可能作用于人类生物存续层面。这是既有 AI 存在性风险讨论最熟悉的部分，也是本文始终保留的底线风险形式。若 AI 系统通过失控、误用、竞争压力、武器化、高后果技术链条或关键基础设施风险，导致人类物种灭绝、永久失能或未来不可逆封闭，那么它直接构成人类存在性风险。

这种风险可能通过多种路径出现。足够强大的 AI 系统可能辅助危险生物技术研发，增强网络攻击能力，影响能源、通信、金融、交通和供应链等关键基础设施，参与自动化武器系统，或在复杂社会系统中放大人类难以及时理解和控制的连锁后果。本文不在此处展开这些具体路径，因为本文不是风险类型学。但这些可能性足以说明：物种层风险仍然是 AI 相关人类存在性风险的核心组成部分。

生物存续层面的重要性还在于，它是所有其他层面与机制的承载前提。没有具身的人类生命，没有身体、神经系统、死亡性、生殖机制和代际延续，人类文明、哲学内核、责任结构和意义叙事都无从持续。因此，本文对文明条件和范畴校准的强调，并不削弱物种层风险。相反，它以物种层风险为底线，并在此基础上进一步说明：人类的未来不仅取决于身体是否存续，也取决于人类是否仍能在文明条件中作为未来主体而存在。

更进一步，文明条件和范畴校准机制本身也影响人类处理物种层风险的能力。一个无法稳定区分真实与虚假、证据与叙述的社会，难以可靠评估高后果技术风险；一个责任结构不清的社会，难以治理危险行动链条；一个主体判断能力弱化的社会，难以形成长期公共行动；一个意义结构贫乏的社会，可能缺乏保护未来世代的理由。因此，物种层风险与主体性实现条件风险不是竞争关系，而是相互依赖关系。前者提供底线，后者说明底线之上的人类未来何以仍然是人类的未来。

6.3 AI 与文明条件层面：替代性剥夺

AI 对文明条件层面的影响，不只表现为某个工具更高效，也不只表现为某个行业被自动化。更深的问题在于，AI 正在进入文明功能系统，改变人类参与共同世界的方式。

如第 3 章和第 5 章所述，经济、法律、教育、科学、国家治理、文化、媒体、行政和公共服务等系统，是人类主体性实现的重要承载层。人类通过这些系统学习、劳动、判断、创造、负责、治理和面向未来行动。AI 作为更高效、更可复制、更可规模化的替代者，可能逐渐取代人类在这些系统中的劳动、认知、创造、治理和判断角色，使人类被系统挤出或边缘化。本文将这一机制称为**替代性剥夺**。〔注 7〕

经济系统可能越来越少依赖人类劳动和专业判断；文化系统可能越来越少依赖人类创作和解释；治理系统可能越来越少依赖人类公共判断和政治参与；教育与科研系统也可能越来越多地依赖自动生成、自动评估和自动筛选。此时，文明功能系统仍然运行，甚至可能运行得更高效，但人类作为系统参与者和方向塑造者的地位被削弱。

这种风险并不必然表现为人类立即失去所有权利或资源。更常见的形式可能是**相对失权**：人类仍然消费、投票、确认和被服务，但越来越少真正影响资源分配、制度方向、知识生产和文化叙事。人类仍然在系统中，却不再是系统运行所必需的参与者。若这种趋势跨越经济、文化、国家治理、教育和媒体等多个功能系统，并通过相互反馈不断强化，它就可能削弱人类作为未来主体塑造共同世界的能力。

因此，替代性剥夺的核心问题是：人类是否仍然能够作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体，实质性地参与共同世界的形成与更新？若答案逐渐变成否定，那么 AI 对文明条件的影响就不只是社会适应问题，而可能触及人类主体性实现的基础条件。

6.4 AI 与文明条件中的中介性重构

AI 对文明条件的影响，并不只表现为人类被文明功能系统逐渐替代或挤出。另一种更隐蔽的机制，是人类仍然留在系统之中，仍然保留选择、审批、签署、学习、创作和参与等形式，但这些活动的

前提条件已经被 AI 深度中介。本文将这一机制称为 **中介性重构**。

中介性重构首先发生在文明功能系统中。教育系统仍然培养学生，但学习路径、问题生成、答案评估和知识组织越来越多地由 AI 中介；法律和行政系统仍然保留程序，但证据筛选、文本生成、风险排序和决策建议越来越多地由 AI 参与；科学和知识生产系统仍然发表研究、生成解释和组织文献，但假设提出、材料筛选、论证写作和可信度判断越来越多地依赖模型输出；文化和媒体系统仍然生产意义、叙事和公共想象，但表达形式、注意力分配和意义评价越来越多地被生成式系统塑形。

在这些情形中，人类并未被完全排除在系统之外。人类仍然阅读、确认、投票、签署、学习、创作、管理和承担责任。但问题在于，人类参与的结构已经发生改变。人类仍在获取信息，但信息入口、摘要结构和解释框架可能由系统预先组织；人类仍在作出决策，但可见选项、风险排序和理由生成可能由 AI 塑形；人类仍在承担责任，但判断形成过程越来越难以理解和追踪；人类仍在学习和创造，但学习过程、创作标准和意义评价越来越依赖系统输出。〔注 8〕此时，主体性不是被直接取消，而是在持续参与的表面之下被重新组织。〔注 9〕

中介性重构的更深层后果，是文明功能系统调用基础范畴的方式发生变化。它不只是改变某个任务如何完成，也可能改变真实、证据、责任、主体性、价值和意义等基础范畴在实践中如何被理解、调用和校准。更准确地说，中介性重构可以从五类范畴接口压力及其整体联动来理解。

第一，真实与证据的接口压力。生成式系统能够产生流畅、连贯、表面可信的内容，但流畅性不等于真实性，解释性不等于证据性，相关性不等于可靠性。若人类越来越以生成内容作为认识起点，而不是以来源、证据和验证过程作为认识基础，那么真实与证据之间的校准关系就会变得脆弱。问题不只是某个模型偶尔出错，而是人类共同体维持可验证知识结构的条件可能被改变。〔注 10〕

第二，责任与授权的接口压力。当 AI 参与建议生成、证据筛选、风险评估、方案比较和行动触发时，人类签署最终文件，并不必然意味着人类理解了判断形成过程；制度保留审批和审计流程，也不必然意味着它能够追踪行动如何形成。责任结构因此不能只依赖形式化签字、流程节点或日志记录，而必须重新澄清行动、授权、理解、过失和归因之间的关系。这里的“授权”不是新增的基础范畴，而是责任范畴在制度实践中的关键接口。

第三，主体性与判断的接口压力。主体性不能被简单等同于最后一次点击、确认或选择。若 AI 系统预先组织问题、筛选信息、生成理由、排序选项并推荐行动，人类即使保留选择形式，也可能越来越少参与判断形成的核心过程。这里的“判断”不是新增的基础范畴，而是主体性在实践中的核心能力。问题不在于人类是否还在使用工具，而在于工具是否开始替代人类形成理由、理解问题和承担判断的过程。〔注 11〕

第四，价值排序的接口压力。AI 往往以优化问题的形式运行，但优化本身并不说明目标是否正当，也不说明被优化的指标是否真正代表人类价值。一个系统可以优化参与度，却削弱公共理性；优化生产率，却损害主体性；优化便利性，却降低判断能力；优化满意度，却掩盖意义贫乏。若文明功能系统越来越依赖可度量指标来组织行动，价值排序就可能被技术指标替代，价值反思则可能被优化逻辑压缩。

第五，意义生成的接口压力。AI 可以生成作品、陪伴、研究、设计和方案，使人类重新追问创造、学习、劳动、尊严、贡献和意义的基础。若文明条件无法重新说明人类为何仍应学习、创造、承担责任和保护未来，那么主体性实现就会失去重要的意义支撑。这里的风险不是 AI 能否生成有价值的内容，而是人类是否仍能在生成内容大量存在的条件下，理解自身创造、责任和未来承诺的意义。

这些接口压力并不是彼此孤立的。真实需要证据来校准，责任需要主体性来承载，主体性需要判断能力来实现，价值需要意义来解释，意义也需要真实、责任和价值来避免滑向任意叙事。当 AI 同时改变多类范畴接口的实践条件时，文明功能系统可能仍然继续运行，甚至更高效地运行，但其运

行将越来越依赖自动化、预测、排序和优化，而不是理解、判断、责任和意义。本文将这种多接口联动的后果称为 **范畴网络的整体漂移**。

替代性剥夺与中介性重构并不互相排斥。人类可能在某些文明功能系统中被逐渐替代，在另一些系统中仍然参与但被深度中介。前者削弱的是人类作为共同世界参与者的地位，后者削弱的是人类在参与过程中的理解、判断、责任和意义创造能力。二者共同指向同一个问题：人类是否仍能在文明条件中实现其主体性。

6.5 扩展定义及其必要性

基于上述分析，本文提出如下扩展定义：

AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的，可能不可逆地毁灭人类物种；或使人类永久失能，或以其他方式永久剥夺人类未来；或不可逆或难以逆转地削弱人类这一具身物种在文明中实现其主体性之基础条件的风险。

这三个选言项不是互斥分类，而是按“何者存续”组织的覆盖结构。第一项指承受主体本身的生物性终结；第二项指承受主体仍然存续，但其未来被永久封闭，永久失能是其中的核心形式；第三项指承受主体与名义上的未来仍然存续，但其在文明中实现主体性的基础条件被不可逆或难以逆转地削弱。选言项之间允许蕴含与重叠，因为本定义追求的是对人类可能受损方式的联合覆盖，而不是形式上的互斥划分。

这个定义保留了物种层存在性风险的核心地位，同时将风险分析从单一生物存续层面扩展到文明条件中的主体性实现。它不要求所有 AI 引发的社会变化都被纳入存在性风险，也不要求每一种文明扰动都被视为存在性损害。它只主张：当 AI 的影响触及人类在文明中实现主体性继续成立的基础条件，并具有不可逆或难以逆转的结构后果时，存在性风险理论就不能只以生物学存续为判断对象。

这种风险不一定表现为突然崩溃。它可能表现为正常运行中的能力转移：人类仍然获得信息，却越来越少验证来源；仍然作出选择，却越来越少参与问题定义；仍然承担责任，却越来越少理解判断形成过程；仍然生产内容，却越来越难维持真实与证据之间的关系；仍然拥有制度，却越来越难追踪行动和后果之间的责任链条。此时，社会可能更高效、更便利、更自动化，但人类主体性实现条件却可能被逐步削弱。

因此，如果存在性风险理论只关注生物毁灭，就会错过一种 AI 时代特有的风险形态：人类物种仍然存续，但其作为认识者、判断者、责任者、制度参与者和意义创造者继续存在的文明条件被系统性弱化。本文的扩展定义正是为了给这种风险提供概念位置。

6.6 人类主体性实现风险的四个门槛

一个风险若要进入人类主体性实现层面的存在性风险范围，至少应满足四个条件。不满足这些门槛的严重社会问题，仍然可以是重要风险，但不必然是存在性风险。同时需要限定：以下四个门槛主要适用于文明条件层面的人类主体性实现风险。生物存续层面的底线风险，例如物种灭绝、永久失能或人类未来的永久封闭，依其自身性质直接构成存在性风险，不需要、也不适用这四个门槛。四门槛的作用，是判断那些不直接表现为物种毁灭、却可能不可逆或难以逆转地削弱人类主体性实现条件的 AI 风险。

第一，它必须作用于文明基础条件，而不是局部功能。某个职业被替代、某个行业被重组、某个制度流程被自动化，并不自动构成存在性风险。只有当这些变化系统性影响人类认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的能力时，它们才可能进入人类主体性实现层面的存在性风险范围。

第二，它必须具有跨领域扩散能力。局部错误、单一事故或孤立误用通常不足以构成存在性风险。只有当某种机制能够跨越教育、科学、法律、媒体、企业、公共治理、文化生产和日常生活，并在多个系统中反复改变人类判断、责任、参与或意义结构时，它才具有人类主体性实现的风险特征。

第三，它必须可能造成不可逆或难以逆转的结构性损害。存在性风险关心的不只是规模，也关心可逆性。此处“不可逆或难以逆转”应被分层理解。在物种层，它主要指生物学或物理意义上的绝对不可逆，例如人类物种灭绝、繁殖链断裂或永久失能。在文明条件层，它主要指历史、制度和认知意义上的难以逆转。例如，长期制度路径依赖可能使某些自动化流程成为默认结构；代际能力训练断裂可能使后代不再掌握某些判断、验证和责任承担能力；认知习惯的深层重塑可能使人们不再将某些能力的缺失识别为损失。这种不可逆不同于物种灭绝的物理不可恢复，但在历史尺度上可能足以改变人类继续作为未来主体的能力。〔注 12〕

第四，它必须使前三项损害汇聚为对人类未来主体能力的整体性损害。存在性风险不是任何重大损失，而是影响人类能否继续作为自身未来主体的风险。第四门槛并不重复第一门槛，而是检验前三项是否共同汇聚为整体性、跨代际的未来能力损害：如果某种 AI 嵌入方式不仅作用于文明基础条件、跨领域扩散，并造成不可逆或难以逆转的结构性损害，而且使人类越来越难以理解风险、修正制度、组织行动并塑造未来，那么它就不只是社会适应问题，而是人类主体性实现的基础条件受到损害的问题。

“人类作为未来主体”并不引入新的风险承受主体，也不是独立于主体性实现之外的新概念。它指的是主体性实现的时间性和能动性面向：人类不仅当下认识、判断和负责，也能够在跨代际过程中理解风险、修正制度、组织行动并塑造未来。因此，第四门槛是前三项门槛之后的聚合判据，检验局部能力受损是否已经汇聚为对人类整体未来指向性的损害。

这四个门槛共同限制了扩展定义的范围。它们确保本文不会把所有 AI 社会影响都升级为存在性风险，也不会把普通技术变迁误读为文明级损害。

6.7 风险识别优先于治理方案

本文提出的扩展定义，首先服务于风险识别，而不是直接提供治理方案。AI 安全、AI 风险分析和 AI 治理往往需要具体技术措施、制度安排、责任框架和政策设计。但这些工作之前还存在一个更前置的问题：我们究竟在保护什么？

如果“人类”只被理解为生物物种，那么治理目标主要围绕防止灭绝、失控、永久失能和未来封闭展开。如果“人类”还包括其在文明条件中实现主体性的层面，那么治理目标还必须关注知识、判断、责任、制度参与和意义条件是否被削弱。风险识别的任务，是在损害尚未以灾难形式显现时，给出可讨论、可比较、可审查的概念位置。许多 AI 风险之所以难以被识别，正是因为它们不表现为崩溃，而表现为便利；不表现为强制，而表现为辅助；不表现为毁灭，而表现为替代；不表现为灾难，而表现为正常化。

6.8 本节小结

本节说明了 AI 为什么使生物存续、文明条件和范畴校准成为存在性风险分析中不可避免的问题。AI 可能通过高后果技术体系威胁人类生物存续；可能通过替代性剥夺削弱人类在文明功能系统中的参与结构；也可能通过中介性重构扰动真实、证据、责任、主体性、价值和意义等基础范畴的校准机制。在此基础上，本文提出了扩展定义与四个门槛，既避免将所有 AI 社会影响都升级为存在性风险，也避免将人类存在性风险缩减为单一物种灭绝问题。

下一节将总结全文，并说明这一概念重构对于 AI 安全、AI 风险分析和人类未来研究的意义。

7 | 结论：从物种生存到主体性实现

本文从一个前置问题出发：当我们说 AI 可能对“人类”构成存在性风险时，处于风险之中的“人类”究竟是什么？本文的回答是：AI 相关人类存在性风险的承受主体始终是人类这一具身物种；文明、国家、文化、技术系统、哲学内核和 AI 系统，都不是与人类并列的风险承受主体。本文所扩展的不是风险承受主体本身，而是人类这一主体可能受到存在性损害的方式。

为此，本文建立了一项**概念工程**，区分风险承受主体的两个基本受损层面：生物存续层面与文明条件层面；同时，在文明条件层面内部，本文单独标出范畴校准机制，即哲学内核。生物存续层面说明人类作为具身物种是否继续存在；文明条件层面说明人类是否仍能通过跨代际共同世界实现主体性；范畴校准机制则说明真实、证据、责任、主体性、价值和意义等基础范畴是否仍能被澄清、维护和调整。哲学内核不是第三个平行主体，而是文明条件层面内部维持基础范畴可运行性的范畴校准机制。

本文因此提供的不是完整风险分类，也不是技术控制方案或政策清单，而是 AI 安全、AI 风险分析与 AI 治理在风险识别层面所需要的**本体论坐标系**。在讨论具体风险类型、治理路径或技术方案之前，必须先澄清“人类”这一风险承受主体及其可能受损方式。只有在这一坐标系中，技术研究、政策讨论、哲学分析和社会观察才能被放置在同一个可比较、可连接、可批判的框架内。

后续研究可以在这一主体框架之上，进一步展开 AI 相关人类存在性风险的具体类型学、发生机制与治理含义。本文的贡献在于，为这些后续工作提供一个更清楚的本体起点：从物种生存，推进到人类文明条件下的主体性实现。

附录 A | 核心概念词典

本附录汇总并定义本文使用的核心概念。其功能不是重复正文论证，而是为正文中的概念工程提供稳定的术语边界。每个概念均尽量说明其定义、边界和在本文论证中的作用。除非特别说明，本附录中的概念均服务于本文关于 AI 相关人类存在性风险之风险承受主体的分析。

一、本体核心概念

A.1 概念工程

概念工程，是指对某一概念的使用方式、边界条件、隐含前提和理论功能进行显化、评估、修正和重构的工作。它并不只是解释一个概念在既有语言中的通常含义，而是追问该概念在特定理论与实践场景中是否足够清楚、是否造成误导、是否需要被重新划界。

在本文中，概念工程的对象是 AI 相关人类存在性风险中的“人类”这一风险承受主体。本文并不试图重新定义所有 AI 风险，也不直接提出治理方案，而是追问：当我们说 AI 可能威胁“人类”时，这里的“人类”是否只能被理解为生物物种，还是也应包括人类这一具身物种在文明条件中实现主体性的基础条件。

本文的概念工程功能，是把“人类”从未经澄清的背景词，转化为风险识别中的核心分析对象。

A.2 AI 相关人类存在性风险

AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的，可能不可逆地毁灭人类物种；或使人类永久失能，或以其他方式永久剥夺人类未来；或不可逆或难以逆转地削弱人类这一具身物种在文明中实现其主体性之基础条件的风险。

这个定义包含三类受损方式。第一，人类作为生物物种被不可逆毁灭。第二，人类虽未灭绝，但永久失能或以其他方式永久失去开放未来。第三，人类物种与名义上的未来仍然存续，但其在文明条件中实现主体性的基础条件被不可逆或难以逆转地削弱。

这三类受损方式不是互斥分类，而是覆盖结构。物种灭绝通常也意味着未来剥夺；永久失能是未来剥夺的核心形式之一；主体性实现条件的不可逆削弱则说明，即使人类仍然生物学地存在，也可能失去作为未来主体继续成立的条件。

A.3 风险承受主体

风险承受主体，是指在某一风险分析中，被视为可能遭受根本性、不可逆或难以逆转损害的对象。它回答的是：风险最终落在谁或什么之上。

在本文中，AI 相关人类存在性风险的风险承受主体始终是人类这一具身物种。文明、国家、文化、制度、技术系统、哲学内核和 AI 系统，都可能成为风险发生、传导、放大或中介的结构，但它们不是本文中的风险承受主体。

这个概念用于防止一种常见混淆：把风险发生的系统误认为风险承受主体。AI 可能作用于经济系统、法律制度、教育结构、知识系统或范畴校准机制，但这些作用最终之所以具有存在性风险意义，是因为它们可能损害人类这一具身物种的生物存续或主体性实现条件。

A.4 人类

本文所说的人类，首先指 *Homo sapiens* 这一具身生物种群。人类具有身体结构、神经系统、感知能力、生殖机制、生理脆弱性、死亡性，以及对生态和物质环境的依赖。

但人类并不只以生物存续层面存在。人类这一具身物种还在文明条件中实现主体性，即通过语言、知识、制度、责任结构、公共理性、历史记忆、意义叙事和文明功能系统，获得并维持认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的能力。

因此，本文中的“人类”具有两个基本分析层面：生物存续层面与文明条件中的主体性实现层面。前者说明人类作为具身物种的存在承载，后者说明人类为何不只是生物种群，而是能够成为认识者、判断者、责任者、制度参与者、意义创造者和未来主体的历史性存在。

A.5 具身物种

具身物种，是指人类不是纯粹信息结构、抽象理性主体或可任意迁移的计算模式，而是由身体、神经系统、感知、情感、脆弱性、死亡性、依赖关系和代际延续所构成的生物种群。

具身性不是人类主体性的外在附加属性，而是人类文明、责任、意义和未来得以承载的生物前提。人类的判断、学习、责任承担和意义形成，都与身体、有限性、时间性和对后果的承受能力有关。

在 AI 风险分析中，具身物种概念用于抵抗一种还原倾向：把人类理解为可被更高效信息处理系统替代的认知模式。本文认为，即使 AI 能够执行大量认知任务，人类仍不能被还原为信息处理结构，因为人类作为责任者、行动者和意义创造者的存在，依赖其具身有限性。

A.6 生物存续层面

生物存续层面，是指人类作为 *Homo sapiens* 这一具身生物种群的存续状态，包括身体结构、神经系统、感知能力、生殖能力、生理脆弱性、死亡性和生态依赖。

生物存续层面构成人类存在的物理承载。若人类物种灭绝，或永久失去繁衍、行动和塑造未来的能力，则人类文明、责任结构、意义叙事和主体性实现都将失去承载者。

在本文中，生物存续层面对应传统存在性风险中的底线风险形式，包括物种灭绝、永久失能和未来剥夺。本文扩展存在性风险概念，并不是削弱生物存续层面的核心地位，而是在其基础上进一步分析文明条件层面的受损方式。

A.7 文明条件层面

文明条件层面，是指人类这一具身物种在文明中实现主体性所依赖的结构性条件。它包括语言、知识系统、教育结构、法律制度、责任机制、公共理性、科学共同体、历史记忆、技术实践、意义叙事和文明功能系统等。

文明条件层面不是与人类并列的主体，也不是独立于人类之外的承受者。它是人类主体性实现的构成性条件。若这些条件受到不可逆或难以逆转的削弱，受损的不是“文明本身”作为主体，而是人类这一具身物种在文明中实现其主体性的能力。

该概念用于说明：人类存在性风险并不只表现为身体毁灭或物种灭绝，也可能表现为人类继续活着，却逐渐失去认识真实、形成判断、承担责任、参与制度、传承意义和面向未来行动的条件。

A.8 人类文明

人类文明，是人类这一具身物种在历史中通过语言、知识、制度、法律、教育、责任结构、技术实践、文明功能系统和意义叙事形成的跨代际共同世界。

人类文明不是人口总和，不等同于国家，不只是文化，也不能被还原为技术体系。人口提供生物承载，国家提供政治法律组织，文化提供意义表达和生活界面，技术提供行动能力；但人类文明是这些要素在跨代际传递、制度化组织、知识积累和意义生成中形成的共同世界。

本文不提出一般文明理论。除非特别说明，正文中所说的“文明”均指人类文明。人类文明之所以是“人类”的，不在于其中没有非人技术成分，而在于它以人类这一具身物种为风险承受主体，并以人类主体性实现为规范性焦点。

A.9 现代全球文明生态

现代全球文明生态，是指当代人类社会由多重文明传统、科学体系、技术基础设施、法律制度、市场、国家、国际组织、数字平台、教育系统、媒体系统和公共理性共同构成的高度互联文明环境。

该概念强调两点。第一，人类文明整体不是某一种文明传统的普遍化，也不是某一国家或文化的扩大版。第二，现代全球文明已经形成若干共享接口，例如科学体系、国际法、公共卫生系统、互联网协议、金融网络、数字平台和 AI 基础设施。

在本文中，现代全球文明生态用于说明 AI 风险并不只作用于局部国家、文化或平台，而可能作用于多重文明传统共同依赖的知识、制度、技术和意义接口。

二、文明条件与主体性实现概念

A.10 构成性条件

构成性条件，是指某种能力、身份或存在方式得以成立的必要条件，而不是外在、可替换的辅助工具。

工具性条件帮助主体完成某项任务；构成性条件则参与形成主体能够完成该任务的能力本身。例如，语言不只是表达思想的工具，也是复杂思维、理由交换和规范承诺得以展开的条件。类似地，教育、责任结构、公共理性、文明功能系统和意义叙事，也不只是人类主体性的外部辅助，而是人类作为认识者、判断者、责任者和意义创造者而存在的构成性条件。

本文使用该概念，是为了说明文明条件不是人类主体性之外的装饰，而是人类主体性实现本身的组成条件。

A.11 文明功能系统

文明功能系统，是指人类文明中具体承载知识生产、制度行动、责任分配、教育传承、经济组织、文化表达、公共治理、医疗照护、媒体传播和意义创造的功能性系统。

典型文明功能系统包括经济系统、国家与治理系统、法律系统、教育系统、科学与知识生产系统、文化与媒体系统、医疗系统、行政系统、基础设施系统、宗教系统和艺术系统等。

文明功能系统是连接抽象文明条件与具体社会机制的中间承载层。人类通常不是直接面对“文明”这一抽象整体，而是通过学校、法院、实验室、市场、媒体、政府机构、平台系统、家庭、宗教传统、艺术实践和公共服务进入文明条件。

A.12 人类参与结构

人类参与结构，是指人类在文明功能系统中作为劳动者、学习者、判断者、创造者、公民、责任承担者和未来主体，参与共同世界运行、维护和更新的方式。

人类参与结构并不只是形式上的在场。它要求人类能够理解过程、形成判断、承担责任、创造意义，并对制度方向和公共未来产生实质影响。若人类在文明功能系统中只保留形式性确认，而不再真正理解、判断、负责、创造或塑造方向，那么人类在文明条件中的主体性实现就会受到削弱。

该概念为“替代性剥夺”提供基础：当 AI 使文明功能系统逐渐不再依赖人类参与时，受损的正是人类参与结构。

A.13 人类在文明中的主体性实现

人类在文明中的主体性实现，是指人类这一具身物种在文明条件中实际获得并维持认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动等能力的过程。

它既不是人类物种的单纯生物属性，也不是文明本身的独立属性，而是人类主体性在文明条件中的实现形态。人类之所以不只是生物种群，正是因为人类能够在文明中进入知识、责任、制度、意义和未来行动的结构。

在本文中，主体性实现是文明条件层面风险的核心对象。AI 若系统性削弱这些能力，并造成不可逆或难以逆转的结构性后果，就可能构成人类主体性实现层面的存在性风险。

A.14 主体性能力

主体性能力，是指人类在文明条件中作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体而实际行使的能力集合。

本文重点关注六项主体性能力：

1. 认识真实；
2. 形成判断；
3. 承担责任；

4. 参与并维持制度；
5. 传承并创造意义；
6. 面向未来行动。

这六项能力并非互相孤立。认识真实支撑判断，判断支撑责任，责任与制度参与相互依赖，意义为学习、创造和未来承诺提供理由结构。主体性能力的系统性削弱，是本文扩展存在性风险分析的核心对象。

A.15 文明基础条件

文明基础条件，是指人类在文明中实现主体性时不可缺少的最低限度运行条件。它们不是人类文明的全部内容，而是使人类能够作为未来主体继续存在的基础接口。

本文重点关注五类文明基础条件：

1. 真实与证据的可校准性；
2. 责任与授权的可归因性；
3. 主体性与判断的可维持性；
4. 价值排序的可反思性；
5. 意义传承的可理解性与可延续性。

这些条件用于判断文明条件层面的风险是否触及主体性实现基础。若这些条件被系统性削弱，人类可能仍然生活在高度运行的社会中，却越来越难以认识真实、形成判断、承担责任、参与制度、传承意义和塑造未来。

三、范畴校准概念

A.16 基础范畴

基础范畴，是文明功能系统运行时必须共享和调用的基本概念接口。它们使文明能够区分真实与虚假、证据与叙述、责任与免责、主体与工具、价值与指标、意义与任意表达。

本文重点讨论六组基础范畴：

1. 真实；
2. 证据；
3. 责任；
4. 主体性；
5. 价值；
6. 意义。

基础范畴不是某一文明传统独占的理论词汇，而是现代全球文明生态赖以运行的关键操作接口。不同传统可以对这些范畴给出不同理解，但只要文明系统需要知识、制度、责任、行动和意义，它就必须以某种方式调用这些范畴。

A.17 哲学内核

哲学内核，是指文明条件层面内部维持基础范畴可运行性的范畴校准机制。由于它校准的是各文明功能系统共同调用的基础范畴，而不是某一功能系统内部的局部规则，因此也可称为一种范畴校准元机制。具体而言，它指真实、证据、责任、主体性、价值和意义等基础范畴被显化、检验、澄清、维护和调整的机制。

哲学内核不是学院哲学学科本身，不是文明中的独立实体，也不是与人类文明并列的风险承受主体。它也不是可被单独安装、替换或重启的模块。它之所以被称为“内核”，是因为它在功能上承担基础范畴接口的校准作用。

在本文中，哲学内核用于说明：文明功能系统即使继续运行，也可能因为底层范畴失准而失去可解释性、可追责性和可修正性。

A.18 范畴校准机制

范畴校准机制，是指基础范畴在历史中被显化、检验、批判、维护和调整的过程。它不是某一单一机构的功能，而是分散在科学、法律、教育、公共讨论、制度改革、文化实践和历史经验中的持续校准过程。

范畴校准机制关注的问题包括：什么算作真实，什么算作证据，谁能够承担责任，什么构成主体，什么值得优化，什么仍然有意义。

当范畴校准机制失效时，现实中表现为：科学、法律、教育、治理、媒体和文化等系统仍可能继续运行，但越来越难以稳定区分真实与伪造、证据与叙述、责任与免责、主体判断与形式确认、价值目标与优化指标、意义创造与内容生成。

A.19 主体性范畴

主体性范畴，是关于谁能够判断、同意、授权、行动、负责和代表自身的概念结构。它属于基础范畴之一，服务于法律、政治、教育、伦理和公共治理等文明功能系统。

主体性范畴不同于主体性实现。主体性范畴是理解和制度化主体能力的概念接口；主体性实现则是人类实际行使认识、判断、责任、制度参与、意义创造和未来塑造等能力的过程。

该区分用于避免循环：主体性实现的条件之一是主体性范畴的清晰，而不是说“主体性依赖主体性”这一同义反复。

A.20 范畴网络

范畴网络，是指真实、证据、责任、主体性、价值和意义等基础范畴之间的相互支撑关系。

真实需要证据来校准，责任需要主体性来承载，主体性需要判断能力来实现，价值需要意义来解释，意义也需要真实、责任和价值来避免滑向任意叙事。任何一组基础范畴的失准，都可能牵动其他范畴的理解和运行。

范畴网络概念用于说明：AI 对基础范畴的影响往往不是单点扰动，而可能表现为多类范畴接口之间的联动性漂移。

A.21 范畴网络的整体漂移

范畴网络的整体漂移，是指当 AI 或其他结构性力量同时改变多类范畴接口的实践条件时，真实、证据、责任、主体性、价值和意义之间的关系发生联动性失准。

在这种情况下，文明功能系统可能仍然运行，甚至更高效运行，但其运行越来越依赖自动化、预测、排序和优化，而不是理解、判断、责任和意义。

该概念用于描述中介性重构的深层后果：风险不只是某个系统出错，而是文明功能系统调用基础范畴的方式整体发生漂移。

A.22 基础范畴、文明基础条件与主体性能力的映射关系

基础范畴、文明基础条件与主体性能力的映射关系，是指本文中三个层级之间的功能连接：

1. 基础范畴提供概念接口；
2. 文明基础条件提供运行条件；
3. 主体性能力是人类在文明中的实际行使。

这个映射关系可简化为：基础范畴支撑文明基础条件，文明基础条件支撑主体性能力。

该概念用于防止三套清单彼此漂移。它说明本文不是随意列举抽象概念，而是在构建一个从概念接口到文明运行条件，再到人类实际能力的层级关系。

四、AI 风险机制与判定概念

A.23 AI 作为文明中介

AI 作为文明中介，是指 AI 不只是外部工具，而是可能进入人类文明的知识、证据、责任、判断、制度和意义结构，成为影响人类主体性实现条件的中介力量。

AI 可以成为人类文明中的工具、平台、基础设施或中介结构，但不因此成为本文中的风险承受主体。AI 的风险意义不只在于它可能造成外部灾难，也在于它可能改变人类如何认识真实、形成判断、承担责任、参与制度和创造意义。

A.24 替代性剥夺

替代性剥夺，是指 AI 作为更高效、更可复制、更可规模化的替代者，逐渐取代人类在文明功能系统中的劳动、认知、创造、治理和判断角色，使人类被共同世界的关键功能系统边缘化或挤出。

替代性剥夺主要削弱的是人类作为共同世界参与者和方向塑造者的地位。其典型形式不是人类立即消失，而是人类仍然消费、确认、投票或被服务，却越来越少实质性地影响资源分配、制度方向、知识生产和文化叙事。

该概念对应文明条件层面中人类参与结构的受损。

A.25 中介性重构

中介性重构，是指人类仍然留在文明功能系统之中，仍然保留选择、审批、签署、学习、创作和参与等形式，但这些活动的前提条件已经被 AI 深度中介。

在中介性重构中，人类仍在获取信息，但信息入口、摘要结构和解释框架可能由系统预先组织；人类仍在作出决策，但可见选项、风险排序和理由生成可能由 AI 塑形；人类仍在承担责任，但判断形成过程越来越难以理解和追踪；人类仍在学习和创造，但学习过程、创作标准和意义评价越来越依赖系统输出。

中介性重构主要削弱的是人类在参与过程中的理解、判断、责任和意义创造能力，并可能进一步扰动基础范畴的校准机制。

A.26 不可逆或难以逆转

不可逆或难以逆转，是本文用于区分存在性风险与普通重大风险的关键时间性标准。

在生物存续层面，不可逆主要指物种灭绝、繁殖链断裂或永久失能等物理 / 生物学意义上的绝对不可恢复。

在文明条件层面，不可逆或难以逆转主要指历史、制度和认知意义上的难以恢复，例如制度路径依赖、代际能力训练断裂、关键判断能力消退，以及相关能力的缺失不再被社会识别为损失。

本文不把“难以逆转”量化为固定年限或单一指标。它是概念识别标准，具体操作化仍需后续实证研究和治理研究进一步展开。

A.27 人类作为未来主体

人类作为未来主体，是指人类不仅被动地进入未来，而且能够在跨代际过程中理解风险、形成判断、承担责任、组织行动、修正制度并塑造未来。

它不是新的风险承受主体，也不是独立于主体性实现之外的新概念，而是主体性实现的时间性和能动性面向。换言之，人类作为未来主体，意味着人类能够把认识、判断、责任、制度参与和意义创造投向未来，并据此保护或更新共同世界。

该概念用于第四个存在性风险门槛：风险必须使前三项损害汇聚为对人类未来主体能力的整体性损害，才具有存在性风险意义。

A.28 存在性风险门槛

存在性风险门槛，是指本文用于判断文明条件层面的人类主体性实现风险是否达到存在性风险级别的四项标准。

一个风险若要进入本文所说的人类主体性实现层面的存在性风险范围，至少应满足：

1. 作用于文明基础条件，而不是局部功能；
2. 具有跨领域扩散能力，而不是孤立事故或单一误用；
3. 可能造成不可逆或难以逆转的结构性损害；
4. 使前三项损害汇聚为对人类作为未来主体之能力的整体性、跨代际损害。

这些门槛主要适用于文明条件层面的主体性实现风险。物种灭绝、永久失能或人类未来的永久封闭，依其自身性质直接构成存在性风险，不需要适用这四个门槛。

A.29 普通社会风险

普通社会风险，是指影响某一局部社会功能、制度过程、行业结构或技术应用的风险。它可以非常严重，但通常具有相对明确的治理对象和修复路径。

例如，某个职业被替代、某个行业被重组、某个制度流程被自动化、某个信息系统产生错误，都可能构成严重社会风险，但不必然构成人类存在性风险。

普通社会风险与人类主体性实现风险的区别，不在于严重程度本身，而在于它是否作用于人类作为未来主体继续成立的基础条件。

A.30 人类主体性实现风险

人类主体性实现风险，是指作用于人类在文明条件中实现认识、判断、责任、制度参与、意义创造和未来行动之基础条件的风险。

它不同于普通社会风险。普通社会风险通常作用于局部功能；人类主体性实现风险则作用于更基础的文明条件，可能影响人类是否仍能作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体而存在。

当这种风险作用于文明基础条件，并具有跨领域扩散能力、可能造成不可逆或难以逆转的结构性损害，且使这些损害汇聚为对人类未来主体能力的整体性、跨代际损害时，它可能进入 AI 相关人类存在性风险的范围。

A.31 范式扩展

范式扩展，是指在保留既有存在性风险框架核心地位的基础上，扩展风险识别的对象范围或受损方式。

本文的范式扩展不是范式替代。它不否定物种灭绝、永久失能和未来剥夺作为存在性风险的底线形式，而是进一步主张：AI 也可能通过不可逆或难以逆转地削弱人类在文明中实现主体性的基础条件，构成人类存在性风险。

A.32 风险识别框架

风险识别框架，是指在具体风险分类、治理方案或技术控制之前，用来确定风险对象、受损方式、判断门槛和概念边界的分析框架。

本文提供的是风险识别框架，不是完整风险分类，也不是技术治理方案。它回答的是更前置的问题：AI 风险分析究竟在保护什么？本文的回答是：不仅要保护人类作为生物物种的存续，也要保护人类在文明条件中实现主体性继续成立的基础条件。

A.33 AGI 时代

AGI 时代，在本文中并不指真正意义上的 AGI 已经实现，也不依赖某个普遍接受的 AGI 阈值已经被跨越。

它指的是一个正在展开的历史转变：AI 系统正在变得更通用、更自主、更具行动能力，并越来越深入地嵌入知识生产、制度流程、判断形成、技术研发和意义生成之中。

本文使用该概念，是为了标示一种历史条件：即使在真正 AGI 尚未出现之前，AI 也已经开始改变人类主体性实现的文明条件。

A.34 本体论坐标系

本体论坐标系，是指本文为 AI 相关人类存在性风险提供的风险识别框架。它通过澄清风险承受主体、受损层面、范畴校准机制、文明功能系统和风险门槛，为不同 AI 风险讨论提供一个可比较、可连接、可批判的位置结构。

在本文中，本体论坐标系包括：

1. 一个风险承受主体：人类这一具身物种；
2. 两个基本受损层面：生物存续层面与文明条件层面；
3. 一个内部机制：范畴校准机制；
4. 一个中间承载层：文明功能系统与人类参与结构；
5. 两类 AI 作用机制：替代性剥夺与中介性重构；
6. 一组存在性风险门槛。

该概念用于说明本文与风险分类、技术治理和政策方案的关系：本文不直接替代这些工作，而是为它们提供前置的概念坐标。

注释

[注 1]

本文所说的“AGI 时代”并不预设真正意义上的 AGI 已经实现，也不依赖某个普遍接受的 AGI 阈值已经被跨越。它指的是一个正在展开的历史转变：AI 系统正在变得更通用、更自主、更具行动能

力，并越来越深地嵌入知识生产、制度流程、判断形成、技术研发和意义生成之中。本文讨论的若干风险机制，在真正 AGI 出现之前，已经可能以高级 AI、生成式 AI、行动型 AI 和自动化系统的形式出现。

[注 2]

本文将 AI 视为可能重组人类知识、行动、责任和意义结构的文明中介，这一问题意识与技术哲学和后现象学中的技术中介传统相邻。相关背景可参见 Heidegger (1977)、Arendt (1958)、Jonas (1984)、Winner (1980) 与 Verbeek (2011)。Pezzano 与 Pavanini (2025) 近期进一步区分了 technological support、technological mediation 与 technological constitution，可作为理解技术如何从外部支持转向中介乃至构成条件的当代理论背景。本文并不主张技术具有单一决定论方向，而是关注 AI 作为技术中介如何改变人类主体性实现的文明条件。

[注 3]

既有存在性风险和 AI 风险讨论通常强调物种灭绝、永久失能、未来剥夺、失控、控制问题和长期未来潜能的不可逆损失，可参见 Bostrom (2013, 2014)、Ord (2020)、Russell (2019) 与 Carlsmith (2022)。近期哲学和法律学术也开始系统整理 AI 存在性风险：Cappelen、Goldstein 与 Hawthorne (2025) 从 AI survival stories 的角度提出 AI 存在性风险类型学；Tokson 与 Arbel (2026) 则从法律治理角度区分 human-directed risks、accident risks 与 loss-of-control risks，并讨论法律制度如何在不确定性下识别和回应这些风险。本文与这些研究相邻，但不提出新的风险类型学或监管方案，而是更前置地澄清这些风险中的“人类”这一承受主体及其可能受损方式。

[注 4]

本文的“概念工程”取向，可参见 Cappelen (2018)、Chalmers (2025) 与 Haslanger (2000) 对概念修正、概念设计和规范性概念分析的相关讨论。本文借用概念工程的问题意识，但具体对象不是语言哲学内部争论，而是 AI 风险理论中的风险承受主体问题：当我们说 AI 威胁“人类”时，这里的“人类”究竟是什么。本文并不重新定义所有 AI 风险，而是澄清 AI 相关人类存在性风险中“人类”这一承受主体的概念边界。

[注 5]

“硬件—内核—发行版—应用层”类比仅作为功能性说明使用，不是本体模型。它不意味着人类文明可以像计算机系统那样被模块化拆解、替换、重装或迁移，也不意味着哲学内核是一个可单独安装、替换或重启的实体模块。该类比只用于说明四种功能关系：人类物种提供生物承载，哲学内核校准基础范畴接口，人类文明提供完整运行环境，文明功能系统提供人类实际进入共同世界的应用层界面。

[注 6]

本文并不主张 AI 必然削弱人类主体性实现条件。AI 也可能增强教育、科学研究、公共服务、医疗诊断、无障碍支持、知识获取、制度透明度和公共协作。本文关注的是另一类可能性：当 AI 的嵌入方式系统性削弱人类认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的条件，并具有跨领域、结构性和难以逆转的后果时，它才进入本文所说的人类主体性实现层面的存在性风险范围。

[注 7]

关于 AI 风险可能通过渐进式削弱人类对经济、文化和国家等大规模社会系统的影响力而发生，可参见 Kulveit 等人（2025）的“Gradual Disempowerment: Systemic Existential Risks from Incremental AI Development”。在本文坐标系中，这类研究可安置于文明条件层面中的文明功能系统与人类参与结构问题，尤其接近本文所说的替代性剥夺：AI 逐渐替代人类在劳动、认知、文化生产、治理参与和社会协调中的角色，从而削弱人类对共同世界的实质影响。本文吸收其风险直觉，但不将其作为本文的主框架。

[注 8]

关于生成式 AI 使用与批判性思维、认知努力和任务监管方式之间的关系，可参见 Lee 等人（2025）对知识工作者的调查研究。关于学生对 AI 对话系统过度依赖及其对认知能力影响的系统综述，可参见 Zhai、Wibowo 与 Li（2024）。这些研究不能直接证明存在性风险，但为本文所说的中介性重构提供经验背景：当生成式 AI 或 AI 对话系统被嵌入知识工作与学习流程时，人类批判性思维实践、认知努力、判断负担和任务监管方式可能发生重新分配。

[注 9]

关于 AI 可能通过削弱人类自主性、决策能力和技能实践而带来深层风险，可参见 Prunkl（2022）关于 AI 时代人类自主性的讨论，以及 Krook（2025）关于自主性衰退和技能退化的存在性风险分析。在本文坐标系中，这类讨论可安置于文明条件层面中的主体性能力弱化问题，并与替代性剥夺和中介性重构均有交叉。本文的主轴不是自主性理论本身，而是风险承受主体及其主体性实现条件。

[注 10]

本文关于真实、证据、知识共同体、公共判断和信息生态的讨论，与社会认识论传统具有问题关联。相关背景可参见 Goldman（1999）、Longino（1990）、Fricker（2007）、O'Connor 与 Weatherall（2019）以及 Nguyen（2020）。更直接地，Ortmann（2025）在 *Synthese* 中讨论了科学中对 AI 的认识依赖，并主张 AI 工具的不透明性并不必然给社会认识论带来全新问题。本文与这一讨论相邻，但问题层级不同：本文关注的不是 AI 不透明性是否构成社会认识论中的新问题，而是当 AI 深度进入文明功能系统并改变真实、证据、责任、主体性、价值与意义等范畴接口时，这种中介性重构是否可能触及人类主体性实现的基础条件。

[注 11]

关于大语言模型是否可被理解为扩展心智的一部分，可参见 Smart、Clowes 与 Clark（2025）在 *Synthese* 中关于 LLM 与 *extended mind* 的讨论。该文将 LLM 放入扩展心智框架中考察，并涉及外部认知资源、能动性和认知控制等问题。本文与这一讨论相邻，但并不以“LLM 是否构成扩展心智”为中心问题；本文关注的是，当 AI 系统组织信息入口、理由生成、选项排序和判断环境时，人类是否仍然保有形成判断、承担责任和实现主体性的实质条件。

[注 12]

本文所说“不可逆或难以逆转”，在文明条件层面主要指历史、制度和认知意义上的难以恢复，而不是单一物理不可逆。相关讨论可与路径依赖、制度持续和能力形成研究对话，例如 Arthur（1989）关于技术锁定和递增收益的研究，Pierson（2000）关于政治中的路径依赖，North（1990）关于制度变迁，以及 Cunha 与 Heckman（2007）关于技能形成技术的研究。本文不把“难以逆转”量化为固定年限或单一指标，而将其作为风险识别中的概念标准。

参考文献

Arendt, Hannah. 1958. *The Human Condition*. Chicago: University of Chicago Press.

Arthur, W. Brian. 1989. “Competing Technologies, Increasing Returns, and Lock-In by Historical Events.” *The Economic Journal* 99 (394): 116–131.

Bostrom, Nick. 2013. “Existential Risk Prevention as Global Priority.” *Global Policy* 4 (1): 15–31.

Bostrom, Nick. 2014. *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.

Cappelen, Herman. 2018. *Fixing Language: An Essay on Conceptual Engineering*. Oxford: Oxford University Press.

Cappelen, Herman, Simon Goldstein, and John Hawthorne. 2025. “AI Survival Stories: A Taxonomic Analysis of AI Existential Risk.” *Philosophy of AI* 1: 1–19. doi:10.18716/ojs/phai/2025.2801.

Carlsmith, Joseph. 2022. “Is Power-Seeking AI an Existential Risk?” arXiv:2206.13353.

Chalmers, David J. 2025. “What Is Conceptual Engineering and What Should It Be?” *Inquiry: An Interdisciplinary Journal of Philosophy* 68 (9): 2902–2919. doi:10.1080/0020174X.2020.1817141.

Cunha, Flavio, and James J. Heckman. 2007. “The Technology of Skill Formation.” *American Economic Review* 97 (2): 31–47.

Fricker, Miranda. 2007. *Epistemic Injustice: Power and the Ethics of Knowing*. Oxford: Oxford University Press.

Goldman, Alvin I. 1999. *Knowledge in a Social World*. Oxford: Oxford University Press.

Haslanger, Sally. 2000. "Gender and Race: (What) Are They? (What) Do We Want Them To Be?" *Noûs* 34 (1): 31–55.

Heidegger, Martin. 1977. "The Question Concerning Technology." In *The Question Concerning Technology and Other Essays*, translated by William Lovitt, 3–35. New York: Harper & Row.

Jonas, Hans. 1984. *The Imperative of Responsibility: In Search of an Ethics for the Technological Age*. Chicago: University of Chicago Press.

Krook, Joshua. 2025. "When Autonomy Breaks: The Hidden Existential Risk of AI." arXiv:2503.22151.

Kulveit, Jan, Raymond Douglas, Nora Ammann, Deger Turan, David Krueger, and David Duvenaud. 2025. "Gradual Disempowerment: Systemic Existential Risks from Incremental AI Development." arXiv:2501.16946v2. doi:10.48550/arXiv.2501.16946.

Lee, Hao-Ping (Hank), Advait Sarkar, Lev Tankelevitch, Ian Drosos, Sean Rintel, Richard Banks, and Nicholas Wilson. 2025. "The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers." In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems* (CHI '25), Article 1121, 1–22. New York: Association for Computing Machinery. doi:10.1145/3706598.3713778.

Longino, Helen E. 1990. *Science as Social Knowledge: Values and Objectivity in Scientific Inquiry*. Princeton: Princeton University Press.

Nguyen, C. Thi. 2020. "Echo Chambers and Epistemic Bubbles." *Episteme* 17 (2): 141–161.

North, Douglass C. 1990. *Institutions, Institutional Change and Economic Performance*. Cambridge: Cambridge University Press.

O'Connor, Cailin, and James Owen Weatherall. 2019. *The Misinformation Age: How False Beliefs Spread*. New Haven: Yale University Press.

Ord, Toby. 2020. *The Precipice: Existential Risk and the Future of Humanity*. New York: Hachette Books.

Ortmann, Jakob. 2025. "Of Opaque Oracles: Epistemic Dependence on AI in Science Poses No Novel Problems for Social Epistemology." *Synthese* 205: Article 80. doi:10.1007/s11229-025-04930-x.

Pezzano, Giacomo, and Marco Pavanini. 2025. "Understanding Philosophical Media: From Philosophy of Technology to 'Technologies of Philosophy.'" *Philosophy & Technology* 38: Article 107. doi:10.1007/s13347-025-00937-x.

Pierson, Paul. 2000. "Increasing Returns, Path Dependence, and the Study of Politics." *American Political Science Review* 94 (2): 251–267.

Prunkl, Carina. 2022. "Human Autonomy in the Age of Artificial Intelligence." *Nature Machine Intelligence* 4 (2): 99–101. doi:10.1038/s42256-022-00449-9.

Russell, Stuart. 2019. *Human Compatible: Artificial Intelligence and the Problem of Control*. New York: Viking.

Smart, Paul, Robert Clowes, and Andy Clark. 2025. "ChatGPT, Extended: Large Language Models and the Extended Mind." *Synthese* 205: Article 242. doi:10.1007/s11229-025-05046-y.

Tokson, Matthew J., and Yonathan A. Arbel. 2026. "Artificial Intelligence and Existential Risk." SSRN Working Paper. Forthcoming in *Connecticut Law Review* 59 (2027). doi:10.2139/ssrn.6288138.

Verbeek, Peter-Paul. 2011. *Moralizing Technology: Understanding and Designing the Morality of Things*. Chicago: University of Chicago Press.

Winner, Langdon. 1980. "Do Artifacts Have Politics?" *Daedalus* 109 (1): 121–136.

Zhai, Chunpeng, Santoso Wibowo, and Lily D. Li. 2024. "The Effects of Over-Reliance on AI Dialogue Systems on Students' Cognitive Abilities: A Systematic Review." *Smart Learning Environments* 11: Article 28. doi:10.1186/s40561-024-00316-7.