



AI 与人类存在性风险：从物种生存到文明主体

AGI 时代的物种、文明与哲学

坤元

TrantorLabs

kunyuan@trantorlabs.sg

摘要

本文提出一个理解 AI 相关人类存在性风险的本体论与概念工程框架。随着 AI 系统变得更强大、更通用、更具行动能力，并越来越深入地进入人类知识生产、制度流程、判断形成与技术研发过程，AI 风险已经不再只是模型性能、产品安全或工程治理问题。在前沿技术语境中，AI 正在被用于辅助代码生成、模型评估、研究自动化和 AI 系统自身的发展；在公共伦理语境中，AI 也正在被视为对人类尊严、责任、自由、共同善和社会自我理解的范畴性挑战。这些变化共同表明，AI 重新打开了人类存在性风险问题。然而，在许多关于 AI 风险的讨论中，一个更前置的问题尚未被充分澄清：当我们说 AI 可能对人类构成存在性风险时，处于风险之中的“人类”到底是什么？

本文主张，AI 相关人类存在性风险不应只通过 *Homo sapiens* 这一生物物种是否被物理毁灭、永久失能或剥夺未来来评估。人类当然作为生物物种存在，但人类也作为文明主体存在：一个由语言、知识、制度、责任、真实、主体性、价值与意义构成的跨代际共同世界。若 AI 不直接毁灭人类物种，却不可逆地削弱人类作为文明主体继续成立的基础条件，那么这种风险也应进入 AI 相关人类存在性风险的扩展理解之中。

为论证这一点，本文区分三个嵌套层级：人类物种作为文明的生物学基底，人类文明作为物种形成的跨代际共同运行环境，哲学作为文明定义和修正自身基础范畴的反思性内核。人类物种提供文明的物理承载；人类文明使物种成为能够认识、判断、负责、传承和创造意义的共同主体；哲学内核则为文明中的科学、法律、政治、教育、经济、文化和艺术等系统提供真实、证据、责任、主体性、价值与意义等基础范畴。

本文使用“硬件—内核—发行版”的功能性类比来说明三者之间的关系。人类物种可以类比为硬件，哲学可以类比为内核，人类文明则可以类比为运行在生物基底之上、以哲学内核为底层范畴结构的发行版或完整操作环境。这个类比不是字面等同，也不是历史发生顺序，而是为了揭示人类存在的层级结构：硬件仍在，不等于系统运行良好；发行版仍能启动，不等于内核没有损坏；应用层仍然繁荣，不等于底层范畴仍然健康。

本文最后提出一个扩展定义：AI 相关人类存在性风险，不仅发生在 AI 威胁人类生物学存续时，也发生在 AI 不可逆地削弱人类作为真实、责任、主体性与意义主体继续成立的文明条件时。这个定义并不试图将所有 AI 引发的社会变化都纳入存在性风险，而是为进一步分析 AI / AGI 时代人类存在性风险的主要维度提供概念基础。

关键词

人工智能；AGI；人类存在性风险；文明主体；人类物种；人类文明；哲学内核；概念工程；AI 哲学；技术哲学；文明级风险

1 | 引言：AI 重新打开了人类存在性风险的主体问题

人工智能正在重新打开人类存在性风险问题。这里的“重新打开”，并不只是指 AI 系统在能力上变得更强大。人类历史中曾多次出现能够深刻改变文明结构的技术力量，例如文字、印刷术、蒸汽机、电力、核能、互联网和生物技术。强大技术并不自动构成存在性风险。当前 AI 的特殊性在于，它的能力扩张正在进入人类用来认识世界、形成判断、组织行动、分配责任、治理制度和理解自身的基础结构之中。AI 不再只是扩展外部能力的工具，而正在成为人类知识、制度、行动和意义结构的中介。

当前 AI 系统已经不再局限于对孤立问题给出文本回答。它们可以生成代码、整理证据、起草报告、辅助研究、组织工作流、推荐决策、调用工具、协调任务，并参与企业、教育、科研、法律、医疗、行政和公共服务等制度流程。在前沿研究语境中，AI 也开始越来越多地参与 AI 系统自身的发展过程，包括辅助编码、模型评估、研究自动化和技术迭代。[注 1] 这并不意味着真正意义上的 AGI 已经实现，也不意味着某个普遍接受的 AGI 阈值已经被跨越。本文不依赖这种判断。本文所说的“AGI 时代”，更准确地说，是指一个正在展开的历史转变：AI 系统正在变得更通用、更自主、更具行动能力、更深度嵌入制度，并越来越多地中介人类知识、判断、行动与意义。

因此，本文讨论的风险以 AGI 时代为背景，但并不依赖“真正 AGI 已经到来”这一前提。许多风险机制并不需要等待某个公认的 AGI 定义被满足之后才会出现。只要 AI 系统已经足够强、足够广泛、足够深地进入人类知识、制度、判断和行动结构，它就已经开始改变人类作为文明主体存在的条件。未来更强、更通用、更自主的系统可能会放大、泛化甚至不可逆化这些风险，但早期机制已经可以在当前高级 AI、生成式 AI、行动型 AI 与制度化 AI 应用中被观察到。

这也是为什么当前 AI 风险问题不仅是技术问题，也是哲学问题。技术问题通常关心系统是否可靠、是否安全、是否可控、是否合规；哲学问题则进一步追问：什么是真实，谁是主体，什么是责任，什么有价值，人类为何仍然需要自己判断和行动。当 AI 成为知识接口时，它影响的不只是人类知道什么，也影响人类如何知道；当 AI 成为行动系统时，它影响的不只是任务是否完成，也影响行动

如何形成、如何归因、如何被审计；当 AI 进入制度流程时，它影响的不只是效率，也影响责任、信任和治理；当 AI 参与人类判断时，它影响的不只是选择结果，也影响人类是否仍然保留形成判断的能力；当 AI 能够生成艺术、论证、研究、设计、陪伴和战略建议时，它影响的不只是劳动市场，也影响人类贡献、创造与意义的理解方式。

这种变化已经使 AI 风险超出了单纯工程性能或产品安全的范围。AI 正在进入人类尊严、责任、自由、真实和共同善等公共伦理领域。[注 2] 无论人们是否接受某一种宗教、哲学或伦理传统的具体前提，这一公共讨论本身都说明：AI 已经不只是一个工具治理问题，而是关于人类如何继续成为人类的问题。

然而，许多关于 AI 存在性风险的讨论仍然默认一种较窄的风险对象。按照这种理解，人类存在性风险主要指向 AI 是否可能在未来某个时刻毁灭人类物种、接管关键基础设施、永久剥夺人类未来，或以某种决定性方式使人类失去控制。这些风险当然是严肃的。人类物种灭绝、永久失能、不可逆灾难和决定性失控，是存在性风险中最直接、最基础、也最不可轻视的形式（Bostrom, 2014; Russell, 2019）。本文并不试图削弱这些风险的重要性。

本文要指出的是，AI 相关人类存在性风险的对象可能不止于此。真正需要澄清的问题是：当我们说 AI 可能威胁“人类”时，这里的“人类”到底指什么？它是否只指 *Homo sapiens* 这一生物物种的延续？是否只指人类身体、繁殖能力和生物学未来？还是说，人类也作为一种文明主体存在，即作为一个由语言、知识、制度、责任、真实、主体性、价值与意义构成的跨代际共同世界而存在？

这个区分并不是抽象语义问题，而是 AI 风险理论必须处理的本体问题。如果人类只被理解为生物物种，那么 AI 相关人类存在性风险主要被限定为物理毁灭、物种灭绝、永久失能或未来控制权丧失。但如果人类也作为文明主体存在，那么 AI 可能造成的存在性损害还包括另一种形式：人类物种仍然存续，制度和技术系统仍然运行，社会仍然生产、消费和交流，但人类逐渐失去认识真实、承担责任、形成判断、维持制度和创造意义的能力。在这种情形中，人类并未生物学地灭绝，却可能作为文明主体受到深层削弱。

这一可能性要求我们在讨论 AI 风险之前，先重新界定风险承受主体。理性分析的第一步，不应立即断言 AI 会不会毁灭人类，而应澄清“人类”这一对象的结构。若风险主体尚未清楚，风险分类就会失去根基。某些风险会被误认为信息质量问题，某些风险会被误认为监管滞后问题，某些风险会被误认为普通工具依赖问题，某些风险会被误认为文化焦虑或就业不安。只有先说明人类不仅是物种，也是文明主体，关于这些风险是否具有存在性意义的讨论才有可能获得本体基础。

为此，本文将区分三个嵌套层级。第一层是人类物种，即 *Homo sapiens* 作为具身生物种群的存在。它包括身体、基因、神经系统、感知能力、繁殖机制、生理脆弱性和物质依赖。人类物种是人类文明的生物学基底。没有这一基底，人类文明无从延续。第二层是人类文明，即人类物种在跨代际历史中形成的共同运行环境。它包括语言、知识、法律、制度、科学、教育、经济、文化、技术、公共理性、责任结构、历史记忆和意义叙事。文明使人类物种不仅能够存活，而且能够判断、协作、负责、传承和创造意义。第三层是哲学内核。这里的哲学不是狭义学院学科，而是文明用来定义和修正自身基础范畴的反思性结构，包括真实、证据、责任、主体性、价值与意义等。科学、法律、政治、教育、经济和文化等文明系统都必须调用这些基础范畴才能运行。

本文将使用“硬件—内核—发行版”的功能性类比来说明这三层关系。人类物种可以类比为硬件，哲学可以类比为内核，人类文明则可以类比为运行在生物基底之上、以哲学内核为底层范畴结构的发行版或完整操作环境。这个类比的目的是不是将人类文明技术化，也不是将人类还原为机器，而是帮助澄清不同层级之间的依赖关系。硬件存在不等于系统完整运行；发行版运行不等于内核稳定；应用层繁荣不等于底层范畴健康。类似地，人类身体仍然存在，不等于人类文明主体仍然完整；制度仍然运行，不等于责任和判断仍然真实成立；内容仍然生成，不等于真实仍然可验证。

这一三层结构也为碎片化的 AI 风险讨论提供了一个本体论坐标。当前关于 AI 的讨论常常在不同层级之间滑动：技术研究关注模型对齐、能力控制和系统安全；政策讨论关注监管、竞争和制度承接；哲学讨论关注意识、主体性和价值；社会分析则关注就业、教育、权力和文化变化。这些讨论并非彼此无关，但它们经常隐含不同的风险承受主体。物种—文明—哲学内核的区分，能够迫使我们先澄清：某一论点究竟指向人类生物学存续、文明共同世界的运行条件，还是文明基础范畴的稳定性。只有在这一坐标中，不同 AI 风险讨论才更可能被放置在同一个可比较、可连接、可批判的框架内。

本文的论证安排如下。第二节讨论仅以物种为中心理解人类存在性风险的边界，说明物种灭绝虽是存在性风险的基础形式，但不足以穷尽 AI 时代的人类风险对象。第三节分析人类物种作为文明的生物学基底。第四节定义人类文明作为物种的跨代际共同世界，并区分文明与人口总和、国家、文化和技术体系。第五节论证哲学为什么是文明自我理解与自我修正的范畴内核。第六节解释“硬件—内核—发行版”类比及其边界。第七节说明 AI 为什么使这一三层结构成为存在性风险问题。第八节提出 AI 相关人类存在性风险的扩展定义。第九节总结全文，并说明这一概念重构对于 AI 风险理论、AI 治理和人类未来研究的意义。

2 | 仅以物种为中心理解人类存在性风险的边界

既有存在性风险理论通常将重点放在人类灭绝、永久失能、未来封闭或长期未来潜能的丧失上 (Bostrom, 2013; Ord, 2020)。人类存在性风险最直接的理解方式，也因此常被界定为人类物种的灭绝风险，或人类作为生物种群永久失去未来延续能力的风险。这种理解具有不可替代的基础地位。若 *Homo sapiens* 在生物学意义上不复存在，或者人类永久失去繁衍、行动和塑造未来的能力，那么关于人类文明、制度、责任、价值和意义的一切讨论都将失去物理承载。因此，任何试图扩展人类存在性风险概念的理论，都不能绕开物种层面的毁灭风险。[注 3]

然而，必要性并不等于充分性。人类物种的延续是人类文明延续的必要条件，但它并不自动保证人类仍然作为文明主体延续。人类并不只作为一个生物种群存在。人类也通过语言、记忆、知识、制度、法律、伦理、教育、艺术、技术、责任和意义结构，形成了一个跨越个体生命和单一世代的共同世界。如果存在性风险只被限定为人类物种的生物学终结，那么许多可能使人类仍然存活、却不可逆地削弱人类作为文明主体之能力的风险，将被系统性地排除在核心讨论之外。

这种排除在一般技术风险语境中或许尚不明显，但在 AI 条件下会变得尤其重要。当前 AI 系统及其后续更高能力形态，并不一定首先以肉体毁灭的方式威胁人类。相反，它们已经开始进入人类文明的知识形成、判断生成、制度执行、责任分配和意义生产结构。由此产生的问题，不只是“AI 是否会杀死人类”，也包括“AI 是否会改变那些使人类能够作为人类而存在的文明条件”。

2.1 物种灭绝作为存在性风险的基础形式

人类物种的毁灭构成存在性风险的基础形式，是因为它同时具有不可逆性、总体性和未来封闭性。不可逆性意味着，一旦人类物种灭绝，人类文明所依赖的生物学承载就不复存在。总体性意味着，这种风险不是某个地区、某个国家、某种制度或某一代人的失败，而是人类作为生物种群整体的终结。未来封闭性则意味着，所有未来人类经验、知识、制度、创造和价值可能性都随之关闭。

因此，物种层面的存在性风险不是一种可以被替代或边缘化的风险类别。它是任何更广义存在性风险理论都必须保留的底线。若没有人类身体、神经系统、繁殖能力和代际延续，便不存在人类文明

的持续展开。文明不是脱离生物基底而独立漂浮的实体。人类文明的任何形式，都需要某种具身的人类生命作为承载。

但是，将物种灭绝视为存在性风险的基础形式，并不等于将其视为存在性风险的唯一形式。这里需要区分必要条件与充分条件。人类物种的存续是人类文明存续的必要条件，但它并不自动保证人类文明作为主体性共同世界的完整延续。人类可以在生物学意义上继续存在，却在文明意义上丧失某些构成共同世界的基础能力。

这一点构成本文对仅以物种为中心的存在性风险理解的基本修正：如果只以人类物种是否继续存在来判定人类存在性风险，就会将“人类的生物学延续”误认为“人类作为文明主体的延续”。在面对 AI 这样一种能够中介知识、判断、制度、行动和意义的技术力量时，这种缩减会遮蔽更深层的风险对象。

2.2 人类作为文明主体

人类当然是一个生物物种。作为 *Homo sapiens*，人类具有特定的身体结构、神经系统、感知能力、繁殖机制和生物脆弱性。这个层面的定义在生物学上不可或缺。然而，如果只在这一层级上理解人类，便无法解释人类为何不仅仅是一个生物种群。

人类之所以能够作为“人类”而存在，不仅因为个体具备某些生理结构，也因为人类在历史中形成了一个超越个体生命周期的共同世界。这个共同世界包括语言、文字、制度、法律、科学、技术、教育、伦理、艺术、宗教、哲学、公共理性和历史记忆。它使个体不只是活着，而且能够进入一个已经被前代人组织、解释和传递的世界，并在其中学习、判断、承诺、创造、负责和追问意义。

因此，人类文明不是人类物种的外在装饰，而是人类物种成为文明主体的展开方式。一个人类个体在生物学意义上属于人类物种，但他只有通过语言、关系、规范、教育和共同记忆，才进入完整的人类世界。类似地，人类物种可以在最低限度上继续生存，但如果其知识系统、制度系统、责任结构、主体性能力和意义结构被系统性削弱，那么人类作为文明主体的存在也会受到深层损害。

这一点对于 AI 风险理论具有直接意义。AI 对人类的威胁并不必然首先表现为对身体的攻击。它可能首先表现为对文明中介结构的重组：改变人类如何获得知识、如何定义事实、如何分配责任、如何执行制度、如何形成判断、如何理解劳动、创造和尊严。若这些结构发生不可逆或难以逆转的退化，那么即使人类物种没有灭绝，人类作为文明主体也可能已经被深度削弱。

2.3 物种存续与文明主体存续的非等价性

“人类仍然活着”并不等于“人类文明主体仍然完整存在”。二者之间存在重要差异。一个社会可以保持基本人口延续、物质生产和制度外壳，却同时逐渐失去判断真实、分配责任和形成自主行动的能力。法院可以继续运作，但其事实依据可能越来越依赖不可验证的生成内容。学校可以继续授课，但教育可能越来越少培养判断能力，而更多训练人与自动化系统协作。政府可以继续发布政策，但政策形成过程中人类判断与机器生成分析之间的边界可能变得越来越模糊。企业可以继续决策，但决策依据、风险排序和方案比较可能已经由系统预先组织。个体可以继续选择，但选择空间、理由结构和问题定义可能已经被技术系统深度中介。

在这些情形中，社会并未停止运转。它甚至可能显得更高效、更便捷、更流畅、更自动化。然而，文明主体性的损害往往不以外部崩溃的形式出现，而以基础能力的转移、弱化和空心化形式出现。人

类仍然在行动，但越来越少形成行动的理由；人类仍然在确认，但越来越少完成判断；制度仍然保留程序，但越来越难以追踪责任；知识仍然被生产，但真实与可验证性之间的关系逐渐松动。

这类风险不能简单归入“社会变化”或“文化不适”。它触及的是文明主体的基础能力。一个文明之所以能够延续，不只是因为其成员活着，也因为它能够维持一套可传承、可修正、可追责、可验证、可反思的共同世界。如果这些能力被不可逆削弱，那么人类存在性风险就已经超出物种层面，进入文明主体层面。

2.4 扩展存在性风险概念的边界

将存在性风险从物种层扩展到文明主体层，并不意味着所有社会问题都应被称为存在性风险。这个扩展必须保持严格门槛，否则概念会失去区分力。并不是所有制度摩擦、文化变迁、职业替代、技术适应或心理不安，都构成人类存在性风险。只有当某种风险作用于人类文明的基础条件，并可能造成不可逆或难以逆转的结构性损害时，它才进入本文所说的文明主体性风险范围。

一个风险若要构成文明主体层面的存在性风险，至少应满足四个条件。

第一，它必须作用于文明的基础条件，而不是局部功能。某个职业被替代、某个行业被重组、某个制度流程被自动化，并不自动构成存在性风险。只有当这些变化系统性影响人类认识真实、分配责任、形成判断、维持制度或创造意义的能力时，它们才可能进入存在性风险的范围。

第二，它必须具有跨领域扩散能力。局部错误或孤立事件通常不足以构成存在性风险。只有当某种机制能够跨越教育、法律、科学、媒体、企业、公共治理和日常生活，并在多个系统中重复改变人类判断、责任或意义结构时，它才具有文明主体层面的风险特征。

第三，它必须可能造成不可逆或难以逆转的结构性损害。存在性风险关心的不只是规模，也关心可逆性。若某种技术结构在长期使用中重塑了人类教育、认知习惯、制度程序和主体能力，使若干代人逐渐丧失某些基础能力，那么即使没有发生物理毁灭，它也可能构成深层存在性风险。

第四，它必须影响人类作为未来主体的能力。存在性风险不是任何重大损失，而是影响人类能否继续作为自身未来主体的风险。如果某种 AI 嵌入方式使人类越来越难以认识真实、共同治理、形成自主判断、承担责任和创造意义，那么它就不只是社会适应问题，而是文明主体条件受到损害的问题。

因此，文明主体性风险并不是把所有社会困难都升级为存在性风险，而是将存在性风险的判断对象从生物延续扩展到人类作为文明主体的基础能力。这个扩展既不否认物种层风险的中心地位，也不放弃存在性风险概念应有的高门槛。

2.5 本节小结

仅以人类物种为中心理解存在性风险，是必要的，但不充分。它必要，是因为人类文明依赖人类物种这一生物学基底。没有人类物种，就没有人类文明。它不充分，是因为人类不只是生物物种，也作为文明主体存在。人类通过语言、制度、科学、法律、教育、文化、责任、主体性和意义结构，形成了一个跨代际共同世界。这个共同世界不是物种的附属装饰，而是使人类成为“人类”的核心条件。

AI 时代使这一点变得不可回避。AI 不仅可能在未来威胁人类生物学存续，也已经开始进入人类文明的知识、制度、判断和意义结构。因而，AI 相关人类存在性风险需要从物种生存扩展到文明主体。下一节将进一步分析第一层：人类物种作为文明的生物学基底。

3 | 人类物种：文明的生物学基底

如果要扩展 AI 相关人类存在性风险的概念，首先必须避免另一个方向的误解：强调人类作为文明主体，并不意味着可以忽视人类作为生物物种的基础性。文明不是脱离身体、神经系统、生态条件和代际延续而独立存在的抽象实体。任何人类文明都必须由具身的人类生命承载。正因如此，人类物种仍然是讨论人类存在性风险时不可绕开的第一层对象。

本文将人类物种理解为 *Homo sapiens* 作为生物种群的存在。它包含人类身体结构、神经系统、感知能力、认知能力、生殖能力、生理脆弱性、死亡性，以及对生态和物质环境的依赖。这个层级构成人类文明的生物学基底。它不是文明的全部，但它是文明得以发生和延续的物理前提。

这种基底性具有双重含义。一方面，若人类物种被毁灭，文明将失去其承载者。另一方面，物种本身并不自动生成文明。一个物种可以具有复杂神经系统、社会性和学习能力，却不必然形成科学、法律、制度、哲学、历史记忆和公共理性。人类文明之所以可能，必须以人类物种为承载；但人类物种之所以成为“人类”意义上的历史主体，又必须通过文明结构展开。

因此，在本文框架中，人类物种既不是可以被跳过的低级层，也不是足以穷尽人类存在的全部层级。它是必要但不充分的基础。

3.1 生物学基底与具身性

人类作为物种首先是具身存在。人类并不是纯粹信息模式、抽象理性主体或任意可迁移的计算结构。人类的认知、情感、判断、学习、关系和责任，都与身体条件密切相关。感知世界依赖身体，语言学习依赖社会化的具身经验，责任承担依赖行动能力和受后果影响的脆弱性，意义形成也与出生、死亡、时间、痛苦、关系和有限性有关。

这意味着，人类文明并不是单纯的信息系统。文明包含信息，但不等于信息；包含知识，但不等于知识库；包含制度，但不等于制度文本；包含技术，但不等于工具集合。文明需要能够学习、判断、记忆、承诺、行动、受伤、死亡和传承的人。没有具身的人类生命，文明就会失去其经验基础、责任结构和代际连续性。

因此，任何将人类完全还原为信息模式的理解，都无法充分解释人类文明的基底。人类作为文明主体，仍然依赖人类作为具身物种。物种层风险并不会因为我们引入文明主体层分析而失去重要性。相反，文明主体之所以可能，正是因为它始终由具身的人类生命承载。

在 AI 语境下，这一点尤其需要被保留。随着 AI 系统越来越多地承担认知任务、生成文本、组织知识和参与决策，人类很容易被理解成一种可以被更高效信息处理系统替代的认知实体。然而，人类的存在并不只是信息处理。人类文明中的真实、责任、主体性和意义，都与具身有限性有关。一个会死亡、会受伤、会承诺、会后悔、会在时间中成长并承担后果的存在，与一个无身体、无死亡、无脆弱性的信息系统，并不处于同一存在结构中。

这并不是说 AI 无法参与人类文明，也不是说智能必须以人类具身方式存在才具有价值。本文的论点更有限：若要理解“人类”这一风险承受主体，就不能跳过其生物学和具身基础。

3.2 物种连续性与文明连续性

人类物种的连续性，主要通过生物繁殖、代际延续和种群稳定来维持。只要人类仍然能够繁衍、存活并保持基本生物结构，物种层意义上的延续就仍然存在。文明连续性则不同。文明依赖语言、记忆、教育、制度、知识、规范、技术、价值和意义的传递。它不仅要求下一代人出生，也要求下一代人进入一个可理解、可继承、可批判和可更新的世界。

因此，物种连续性与文明连续性之间并不存在自动等价关系。一个社会可以在生物学意义上延续，却发生文明断裂。历史上，不同文明形态曾出现过知识断层、制度瓦解、语言消亡、技术失传、文化毁灭和意义结构崩溃。即使人类物种整体仍然延续，特定文明传统也可能消失。更深一层，如果这种断裂发生在现代全球文明赖以运行的基本接口上，例如真实判定、制度责任、主体判断和跨代际意义传承，那么它就不只是某个局部传统的消亡，而可能成为人类文明整体的结构性损害。

这一点使得“存在性风险”的讨论不能只关注种群数量和生物存续。一个生物学上存续的人类世界，仍可能是一个文明上严重退化的世界。人们仍然出生、劳动、消费、娱乐，但他们所进入的共同世界可能已经无法维持可靠的知识、责任和意义传承。如果这种退化不可逆或难以逆转，它就应被纳入人类存在性风险的更广义分析。

在 AI 条件下，这种区分更加重要。AI 系统不一定通过直接破坏人类生殖或生命系统来威胁人类。它们更可能首先改变文明连续性的机制：知识如何被生成和验证，教育如何培养判断能力，制度如何形成决策，公共讨论如何区分事实与叙事，个体如何理解学习、工作和创造的意义。若这些机制被系统性重组，人类物种仍然可能延续，而文明连续性却可能发生质变。

3.3 物种层风险的真实性和文明主体层风险

强调文明主体层风险，并不意味着物种层风险只是次要问题。相反，AI 可能在未来以多种形式进入物种层风险。若足够强大的 AI 系统能够影响生物技术、关键基础设施、自动化武器、网络系统、能源系统、供应链或其他高后果技术体系，那么它可能间接或直接威胁人类生物学存续。此类风险仍然属于最严格意义上的人类存在性风险。

关键在于，物种层风险的真实性和文明主体层风险的独立重要性并不冲突。二者是不同层级的风险对象，前者关注人类是否继续作为生物物种存在，后者关注人类是否继续作为文明主体存在。二者可以相互影响，但不能相互替代。

更进一步，文明主体层能力往往影响人类处理物种层风险的能力。一个缺乏真实判断能力的文明，难以可靠评估高后果技术风险；一个责任结构不清的文明，难以归因和治理危险行为；一个主体性退化的文明，难以形成长期公共行动；一个意义结构动摇的文明，可能失去保护未来世代的动机。因此，保护人类生物学存续本身，也依赖文明层和内核层能力。

这说明，文明主体层风险并不是对物种风险的弱化，而是对其条件的补充。若人类文明的认知、制度、责任和主体能力被削弱，人类也会更难避免真正的生物学灾难。物种层风险和文明主体层风险之间应被理解为嵌套和互馈关系，而不是竞争关系。

3.4 生物物种并不等于完整人类

人类作为物种的定义，无法单独回答什么使人类生命具有完整意义。生物学可以描述人类身体、神经系统、演化历史和繁殖结构，但它不能独自解释法律责任、科学真理、道德承诺、政治正当性、

艺术意义或教育目的。这些对象属于文明层和哲学内核层。

一个人之所以成为完整意义上的人，并不只是因为他具有某种基因或身体结构。他还必须进入语言、关系、规范、教育、记忆和意义世界。类似地，一个种群之所以构成人类文明，也不只是因为其成员属于 *Homo sapiens*，而是因为他们共同维持某种可传承、可解释、可反思、可更新的文明世界。

这一点对于 AI 风险非常重要。如果 AI 系统只威胁生物身体，我们可以用传统物种风险语言来描述。如果 AI 系统影响的是语言、判断、责任、真实和意义的条件，那么仅使用物种语言就不够了。我们需要一个更高层的概念，来描述人类作为文明主体的风险。

因此，本节的结论可以表述为：人类物种是人类文明的生物学基底，但不是人类存在的全部本体。若要充分理解 AI 相关人类存在性风险，必须进一步分析人类文明这一层级。

4 | 人类文明：物种的跨代际共同世界

如果说人类物种是人类存在的生物学基底，那么人类文明就是这一物种在历史中形成的跨代际共同世界 [注 4]。这里的“共同世界”并不是一个抽象修辞，而是指人类个体得以进入语言、规范、知识、制度、责任和意义结构的共有环境。没有这一共同世界，人类个体仍然可以作为生物体存活，却无法成为完整意义上的历史主体、制度主体、认识主体和意义主体。

人类文明不是人类个体的简单集合。它也不是国家、文化、技术或经济系统的同义词。文明是人类物种通过长期历史积累形成的稳定而可变的结构，它使个体能够继承前人的语言、记忆、科学、法律、伦理、艺术、技术、教育和意义叙事，并在这些结构中继续行动、判断、创造和负责。文明因此是一种跨个体、跨群体、跨代际的共同环境。它不仅保存过去，也组织现在，并使未来能够被想象、承诺和塑造。

这一点对于 AI 相关人类存在性风险具有基础意义。若文明只是人口总和，那么只要人类数量仍然存在，文明就没有根本风险。若文明只是国家制度，那么风险主要表现为国家失败或政治失序。若文明只是文化表达，那么风险主要表现为生活方式和意义叙事的变化。若文明只是技术体系，那么风险主要表现为技术能力的控制与分配。然而，人类文明比这些概念都更深也更宽。它是这些系统共同构成的跨代际运行环境，也是人类物种成为文明主体的展开方式。

4.1 文明不是人口总和

文明不能被还原为人口数量。大量人类个体的同时存在，并不自动构成文明。文明要求某种跨个体和跨代际的结构，使知识、规范、制度、责任和意义能够被保存、传递、批判和更新。人口提供文明的载体，但人口本身并不自动产生文明连续性。

一个人口规模庞大的社会，如果缺乏稳定的语言、记忆、教育、制度、责任结构和知识传承，就难以构成复杂文明。相反，某些文明传统即使在人口、地域或政治权力上经历巨大损失，仍可能通过语言、文本、教育、礼法、制度记忆、宗教、艺术和哲学传统继续存在。由此可见，文明连续性与人口连续性之间并不存在自动等价关系。

这一区分在 AI 时代尤其重要。AI 对人类文明的影响未必首先表现为人口减少。它可能在不显著影响人口数量的情况下，改变文明连续性的条件。例如，如果教育系统越来越少培养理解、判断和质疑能力，而越来越多训练人适应自动化系统；如果知识系统越来越依赖生成内容，而来源、证据和

验证过程被边缘化；如果制度流程越来越依赖机器排序、风险评估和文本生成，而责任主体不再清楚，那么人口仍然存在，但文明的运行条件已经发生改变。

因此，文明风险不能被误认为人口风险。文明风险关注的是共同世界的可持续性，而不仅是共同世界中人口数量的延续。人类作为物种可以继续繁衍，但若其知识、责任、判断和意义结构无法被稳定传承，人类作为文明主体的延续就会受到损害。

4.2 文明不是国家

文明也不能等同于国家。国家是政治和法律组织形式，通常具有领土、主权、行政结构、法律体系、公共财政和强制权力。文明则是更深、更宽、更长时段的世界。一个文明传统可以跨越多个国家，一个国家也可以承载多个文明传统。现代国家还普遍嵌入全球科学体系、金融体系、国际法体系、技术标准、数字平台和跨国供应链之中，这些结构并不完全属于单一国家内部。

例如，现代科学体系并不属于某一个国家。现代大学制度、医学知识、工程标准、法治语言、市场机制、国际贸易、金融基础设施和互联网协议，也都以不同方式跨越国家边界。国家可以组织、调节、保护或扭曲这些系统，但国家本身并不等同于文明整体。同样，中华文明、印度文明、伊斯兰文明、西方现代文明以及其他文明传统，也都不能被简单压缩为某一个当代国家。

这一区分对于 AI 风险尤其重要。AI 风险常常被国家安全、产业竞争、监管政策或地缘政治语言吸收。这些语言当然重要，因为国家是现代世界中最重要治理主体之一。但是，如果只以国家为单位理解 AI 风险，就会遮蔽 AI 对人类文明共同环境的更深影响。AI 影响的不仅是某个国家的竞争力或监管能力，也包括跨国知识生产、全球信息生态、数字平台、公共理性、科学共同体、制度信任和人类意义结构。

因此，国家可以被理解为文明配置在特定历史、地理、法律和政治条件下的具体部署实例。文明则是更上位、更持久、更复杂的世界。AI 对国家治理的影响，是 AI 对文明影响的一个重要维度，但不是全部维度。

4.3 文明不是文化的同义词

文明也不应被简化为文化。文化是文明的重要组成部分，尤其表现为语言、习俗、艺术、审美、仪式、故事、身份、风俗和生活方式。文化使文明的深层价值、记忆和意义以可体验、可表达、可传承的方式进入日常生活。没有文化，文明会失去可生活的界面。

但是，文明不仅包括文化。它还包括科学、法律、制度、教育、经济、技术、公共理性、医学、工程、行政、基础设施和责任结构。若将文明仅仅理解为文化，就会低估文明中那些支撑真实、责任、制度和知识运行的结构。一个文明可以拥有丰富文化，却仍然可能在科学、法律、制度或责任结构上严重脆弱。反过来，一个高度技术化和制度化的社会，也可能在文化和意义层面出现深刻空洞。

AI 对文明的影响也不能被简化为文化变化。AI 当然会改变文化生产，例如文本、图像、音乐、视频、游戏、社交表达和身份叙事。但它同时也进入知识生成、事实验证、法律责任、行政流程、组织决策、教育目标、劳动分工和意义生产等多个层面。因此，AI 对文明的影响不是“文化风格发生变化”这么简单，而是人类共同世界的基础接口正在被重新组织。

更准确地说，文化可以被理解为文明的意义表达层和日常生活界面，但文明还包括更深的知识、制度、责任和技术结构。强调这一点，是为了避免将 AI 对真实、责任、主体性和意义条件的影响误解为单纯文化焦虑。

4.4 文明不是技术体系

文明同样不能被还原为技术体系。技术是文明的重要组成部分，并且常常深刻改变文明形态。从农业、冶金、航海、印刷、电力、计算机到人工智能，技术不断扩展人类行动能力和组织规模。然而，文明并不只是工具集合，也不是效率系统。文明还包含价值、规范、责任、公共理性、意义和自我理解。

现代技术社会容易将文明进步等同于能力增长、效率提高、信息扩张和自动化程度提升。然而，能力增长并不自动等于文明健康。一个系统可以越来越高效，却越来越难以分配责任；可以生成越来越多内容，却越来越难以验证真实；可以自动化越来越多流程，却越来越少培养人的判断能力；可以提供越来越多娱乐和便利，却越来越难回答人为什么继续创造、学习和承担责任。

AI 时代尤其要求我们避免技术还原论。AI 的重要性不只是它扩展了某一种外部工具能力，而是它进入了知识、行动、制度、主体性和意义等多重结构。如果文明被理解为技术能力总和，那么 AI 风险就会被误解为“能力是否可控”的单一问题。但如果文明被理解为跨代际共同世界，AI 风险就还包括共同世界的真实、责任、主体性和意义是否仍然成立。

因此，文明不能被定义为技术能力的总和。技术是文明中的强大系统，但技术本身不提供最终目的，不定义责任，不保证真实，也不自动生成意义。若没有更深的文明和哲学结构，技术增长可能带来能力扩张，却未必带来文明主体的成熟。

4.5 文明作为跨代际共同世界

更准确地说，人类文明是跨代际共同世界。它通过语言、记忆、制度和教育，使过去能够传递给未来，使个体生命能够进入一个大于自身的历史结构。个体生命是有限的。一个人出生时并不从零开始。他进入已经存在的语言，接受已有制度和知识，继承他未曾亲自创造的历史记忆、科学成果、法律结构、伦理规范和意义叙事。文明正是这种跨代际结构：它使人能够站在前人的基础上判断、创造和负责，也使一代人的行动能够对未来代际产生意义。

这种跨代际性使文明具有与物种不同的脆弱性。物种延续主要依赖生物繁殖；文明延续则依赖传承、理解和更新。若下一代人只是生物学地出生，却没有进入能够培养判断、责任、真实和意义的共同世界，那么文明连续性就会被削弱。文明的真正延续并不只是“有人活着”，而是“有人能够理解、继承、批判和更新一个共同世界”。

AI 对跨代际性的影响，不在于阻止下一代出生，而在于改变下一代进入共同世界的路径。若知识获取、写作训练、问题提出和初步判断越来越多地由生成式系统中介，下一代人与传统、文本、证据和责任之间的关系也会发生变化。他们仍然可能获得大量内容，甚至获得更高效的学习支持，但进入共同世界的方式已经不同：理解可能被答案替代，求证可能被摘要替代，判断训练可能被结果评估替代，传统中的摸索、误读、失败和顿悟也可能被压缩为即时生成的解释。这种变化不必然是负面的，但它说明 AI 触及的是文明传承方式，而不只是学习工具。

因此，将文明理解为跨代际共同世界，有助于我们识别 AI 风险中那些不以物理灾难形式出现、却可能改变人类未来主体能力的部分。文明的延续要求的不只是数据保存、内容生成和制度运行，而是人类仍然能够进入、理解、判断并更新这个共同世界。

4.6 文明作为责任结构

文明不仅是知识和文化的传承系统，也是责任结构。人类通过文明定义行动者、承诺、义务、过失、权利、惩罚、补偿和制度责任。没有责任结构，复杂社会无法维持信任，也无法处理伤害、错误、冲突和承诺。

责任结构依赖许多前提：行动必须可归因，主体必须可识别，规范必须可解释，证据必须可检验，程序必须可追踪。如果这些前提不成立，责任就会漂移。责任漂移并不意味着没有后果，而是意味着后果无法被稳定地归属于某个行动者、机构或过程。

AI 进入制度和行动流程后，文明的责任结构面临新的压力。当模型生成建议、平台提供工具、组织采纳输出、人类签字确认、制度执行结果时，责任不再容易落在单一主体上。若文明无法维持或重构责任结构，它可能仍然保留形式化问责，却无法真正追踪行动形成过程。

这说明，文明之所以超出人口、国家、文化和技术，是因为它还组织责任。一个没有稳定责任结构的社会，可能仍然有技术、文化和经济活动，却难以作为成熟文明主体持续行动。

4.7 文明作为认识结构

文明还提供认识结构。人类不是单独面对世界并独立重新发明知识。人类通过语言、教育、科学方法、证据规则、文献系统、同行评审、记录制度和公共讨论来认识世界。文明使个体能够分享、批判、保存和修正知识。

这种认识结构的核心不只是信息量，而是可验证性。一个文明能够积累知识，是因为它拥有某些机制来区分较可靠与不可靠、事实与假说、证据与传闻、解释与伪造。若这些机制失效，知识生产并不会停止；相反，内容可能更多，表达可能更流畅，但知识与真实之间的关系会变得不稳定。

AI 正在进入这种认识结构。它可以帮助整理知识，也可以生成看似知识的内容。它可以降低获取信息的成本，也可能降低验证的动力。它可以让更多人表达，也可能让内容生态被生成物充满。由此，文明的认识结构正在面对新的中介条件。因此，AI 对认识结构的影响，不只是信息工具变化，而是人类共同世界如何维持对真实的共同把握的问题。

4.8 文明作为意义结构

最后，文明也是意义结构。人类不只是一要活着，也要理解为什么活着，为什么学习，为什么创造，为什么承担责任，为什么保护未来。文明通过宗教、哲学、艺术、教育、家庭、传统、政治理想和公共叙事来组织意义。

意义不是可有可无的心理装饰。它影响个体是否愿意承担责任，也影响社会是否愿意保护真实、维持制度和面向未来行动。一个没有意义结构的文明，可能仍然有物质生产和技术效率，但会缺乏维系主体性的深层动机。

AI 对意义结构的影响正在逐渐显现。当 AI 能够生成艺术、文本、陪伴、研究、设计和决策建议时，人类会重新追问什么是创造，什么是劳动，什么是学习，什么是贡献，什么是独特性。若这些问题无法被重新理解，人类可能在物质更丰富、系统更便利的条件下，陷入更深的意义空洞。这说明，意义结构不是文明的附属心理层，而是文明主体持续行动的理由结构。

4.9 本节小结

本节将人类文明定义为人类物种形成的跨代际共同世界。文明不是人口总和，不等同于国家，也不只是文化或技术。它包含知识、制度、责任、公共理性、教育、艺术、经济、法律、历史记忆和意义结构。它使人类物种从单纯生物种群展开为文明主体。

这一定义为本文后续论证奠定基础。既然人类文明是物种的共同运行环境，那么 AI 对人类的风险就不能只看它是否威胁人类身体或繁殖能力。AI 若进入知识、制度、责任、主体性和意义结构，也可能威胁人类作为文明主体的存在条件。

下一节将进一步分析：为什么哲学不是文明中的一个普通组成部分，而是文明能够定义和修正自身基础范畴的内核。

5 | 哲学内核：文明自我理解与自我修正的范畴结构

上一节将人类文明理解为人類物种形成的跨代际共同世界。文明使人类不只是作为生物种群延续，而是作为能够认识、判断、负责、传承和创造意义的共同主体而存在。然而，文明本身并不是一个无前提运行的系统。科学、法律、政治、教育、经济、文化、宗教和艺术等文明系统之所以能够运行，是因为它们都预设了一组更基础的范畴：什么是真实，什么是证据，谁是主体，什么是责任，什么有价值，什么值得追求，以及人类为何继续存在。

本文将这一组基础范畴及其反思、澄清和修正机制称为文明的 **哲学内核**。这里的“哲学”并不首先指学院制度中的哲学学科，也不只是由专业哲学家写成的理论文本。本文所说的哲学，指的是文明用来理解自身、定义自身基础对象、修正自身规范结构的反思性机制。[注 5] 一个文明即使没有现代意义上的哲学系，也必然隐含某种关于真实、主体、责任、价值和意义的基础理解。它可能以宗教、礼法、神话、宇宙论、伦理传统、政治理论、科学理性或公共法理的形式存在，但只要一个文明能够区分真伪、分配责任、组织行动、评判价值并解释意义，它就已经在调用某种哲学内核。

因此，哲学不是文明中的一个普通应用系统。科学、法律、经济、政治、教育、文化和艺术可以被看作文明的功能系统；它们各自处理特定对象，形成特定实践，并拥有自己的制度化规则。哲学则处理这些系统运行所必须预设的基础范畴。科学需要真实和证据的概念；法律需要主体、意图和责任的概念；政治需要合法性、权力和公共性的概念；经济需要价值、偏好和交换正当性的概念；教育需要关于人、成长和知识目的的概念；文化与艺术需要意义、表达和共同经验的概念。若这些基础范畴出现混乱，文明的功能系统仍可能继续运转，但其输出将逐渐失去稳定解释和自我修正的基础。

在这个意义上，将哲学称为文明的“内核”并不是修辞上的抬高，而是功能层级上的判断。内核并不意味着哲学在历史上总是先于文明，也不意味着文明由一套预先写好的哲学理论推导而来。内核意味着：文明中的其他系统在运行时不可避免地依赖某些关于存在、真实、责任、主体性、价值和意义的底层范畴；当这些范畴失效时，文明并非只失去一个学科或一种文化传统，而是失去理解、治理和更新自身的基础接口。

5.1 哲学作为真实范畴的基础

任何文明都必须具有某种真实范畴。所谓真实范畴，是指一个文明用来区分真实与虚假、证据与传闻、知识与意见、解释与伪造、可验证与不可验证的基础结构。没有这一结构，文明无法稳定积累

知识，也无法维持科学、法律、教育、历史记忆和公共讨论。

科学系统显然依赖真实范畴。科学不只是生成解释，也不只是提出模型；它必须能够说明什么构成证据，什么算作观察，什么是可复现，什么是假说，什么是反驳，什么是因果解释。若没有这些认识论前提，科学活动会退化为符号生产或技术操作，而不再是面向真实的公共知识实践。

法律系统同样依赖真实范畴。法律裁判必须区分事实与主张、证据与叙述、记录与伪造、证词与推测。一个法律系统可以拥有完整程序、法院建筑、法官和判决格式，但如果事实基础被污染，证据结构无法维持，法律的程序形式就可能继续存在，而实质正义逐渐失去认识论基础。

教育系统也依赖真实范畴。教育并不只是信息传递，而是使下一代进入一个可理解、可检验、可批判的知识世界。如果教育变成对内容的被动消费，学生获得的可能是流畅解释，而不是判断真实的能力。此时，知识的形式仍然存在，但认识能力可能被削弱。

因此，真实范畴是文明的基础范畴之一。哲学在这里的作用，是澄清真实、证据、知识、逻辑、因果、解释和验证之间的关系。它不仅服务科学，也服务整个文明对现实的共同把握。真实不是某个应用系统的内部功能，而是文明系统共同调用的底层范畴。

5.2 哲学作为责任范畴的基础

文明不仅需要判断真实，还需要分配责任。责任不是自然事实，而是一套由行动、主体、意图、后果、规范和制度共同构成的文明结构。一个事件发生之后，文明必须能够追问：谁在行动，谁授权，谁知情，谁应当预见，谁能够阻止，谁承担后果，谁应当被惩罚或补偿。

这些问题不只是法律技术问题，而是哲学问题。法律能够制度化责任，但法律本身必须依赖更基础的责任概念。若没有行动者、意图、过失、因果归属、可责备性和义务的概念，法律程序就无法稳定运行。

在简单情境中，责任相对容易分配。某个人实施某个行动，产生某种后果，制度据此判断其责任。然而，现代复杂系统已经使责任分配变得困难。组织、平台、算法、外包流程、专业系统和制度程序共同参与行动结果，导致责任越来越分散。AI 进一步加剧了这一困难，因为 AI 系统能够参与建议生成、证据筛选、方案比较、风险评估和行动触发，却不具备与人类相同的道德主体地位。

责任因此不是一个可以完全由法律文本或技术日志自身解决的对象。法律文本可以规定责任，技术日志可以记录过程，但“什么构成行动”“什么构成授权”“谁可以被归因”“何种理解足以承担责任”这些问题，仍然依赖更深的行动哲学、法哲学和伦理学前提。若文明无法说明这些前提，再复杂的制度程序也可能只保留形式，而失去责任的实质基础。

因此，哲学作为责任范畴的基础，使文明能够将行动、后果和主体连接起来。没有这一连接，文明就无法稳定处理错误、伤害、承诺、义务和问责。

5.3 哲学作为主体性范畴的基础

文明还必须定义什么是主体。主体不是单纯的生物个体，也不是任何能够产生输出的系统。主体意味着某种能够形成判断、承担责任、参与行动、拥有立场并被纳入规范关系的存在。不同文明对主体的定义并不相同，但任何文明都必须有某种主体性范畴，否则法律、政治、教育、伦理和责任都无法运行。

主体性范畴回答一组基础问题：谁能够判断？谁能够同意？谁能够拒绝？谁能够授权？谁能够承担责任？谁能够代表自身？谁只是工具？谁是行动的真正来源？这些问题在现代文明中表现为人格、权利、责任能力、自由意志、法律主体性、政治主体性和道德主体性等概念。

AI 时代之所以使主体性范畴变得紧张，是因为 AI 系统越来越多地参与人类判断形成之前的过程。它们帮助人类定义问题、整理资料、比较选项、生成理由、模拟后果并提出建议。此时，人类表面上仍然在选择，但选择的条件、理由和可见选项可能已经被系统中介。

这并不意味着所有 AI 辅助都会削弱主体性。使用工具本身是人类文明的一部分。问题在于，当工具不只是扩展行动，而是开始预组织判断时，文明就需要重新区分辅助与替代、建议与判断、使用与依赖、确认与主体性之间的边界。哲学作为主体性范畴的基础，正是帮助文明提出这些区分。

主体性并不是自然给定、无需定义的对象。人类之所以能在文明中被理解为责任主体、行动主体和意义主体，是因为文明已经拥有一套关于主体性的范畴结构。AI 对判断过程的中介作用，使这套结构必须重新被审视。

5.4 哲学作为价值范畴的基础

文明不只是处理事实和责任，也必须在多个价值之间进行排序。任何复杂社会都同时追求安全、自由、效率、真实、尊严、正义、创新、稳定、繁荣和意义。这些价值之间经常存在冲突。一个文明必须决定，在何种情境下什么价值优先，什么价值不可被牺牲，什么目标只是工具，什么目标具有内在重要性。

这种价值排序不能由科学或技术单独完成。科学可以提供关于后果的知识，技术可以提供实现目标的手段，经济可以衡量成本和激励，但它们不能独自决定什么值得追求。决定“什么应当优先”本身就是价值哲学和伦理学问题。

AI 系统在此处带来新的压力。AI 往往以优化问题的形式运行。给定目标、指标、奖励函数、用户反馈或组织绩效，它可以极大提升效率。然而，优化本身并不说明目标是否正当，也不说明被优化的指标是否真正代表人类价值。一个系统可以优化参与度，却削弱公共理性；优化生产率，却损害主体性；优化便利性，却降低人类判断能力；优化满意度，却掩盖意义贫乏。

文明需要某种价值范畴来判断技术能力应该服务什么目的。若文明缺乏这种价值调度能力，它就容易把可度量性误认为重要性，把效率误认为善，把便利误认为进步，把用户偏好误认为人类价值。哲学的作用不是替代科学和技术，而是为文明提供判断目标正当性的能力。

5.5 哲学作为意义范畴的基础

文明还必须回答意义问题。意义不是个人心理感受的附属物，而是文明能够使个体行动、责任、牺牲、学习、创造和未来承诺具有可理解性的结构。人类并不只是追求生存和效率。人类还追问为什么学习，为什么工作，为什么创造，为什么承担责任，为什么保护未来，为什么追求真实，为什么人类仍然重要。

这些问题不能被技术能力本身回答。即使 AI 能够帮助人类完成更多工作、生成更多内容、提供更多娱乐、优化更多流程，它也不能自动回答人类为什么继续承担责任和创造意义。相反，正因为 AI 能够接近或替代越来越多人类能力，意义问题会变得更加尖锐。

如果劳动不再是大多数人价值感的来源，教育不再主要是知识传递，创作不再体现人类独有能力，

判断越来越多由系统辅助或预组织，那么人类需要重新理解自身价值。这个问题不是就业政策能够完全解决的，也不是心理健康服务能够单独吸收的。它属于文明意义结构的重建。

哲学作为意义范畴的基础，使文明能够在能力结构变化时重新追问人类价值的基础。人类价值是否依赖能力？尊严是否依赖效率？创造是否必须不可替代才有意义？责任是否可以外包？教育的目的是否只是获得可用知识？如果这些问题无人追问，文明可能在物质上更便利，却在意义上更贫乏。

意义因此是文明基础范畴之一，而不是个人主观感受的附属结果。文明若无法维持意义范畴，就会削弱个体承担责任、追求真实、参与制度和面向未来的理由结构。

5.6 哲学作为文明的自我修正机制

文明不仅需要运行，还需要自我修正。任何文明都会犯错。科学理论会被推翻，法律制度会滞后，政治秩序会腐化，文化传统会僵化，经济系统会失衡，技术路线会带来未预见的副作用。文明若要延续，就必须拥有某种反思和修正自身的能力。

哲学在这里不是提供某套固定答案，而是提供文明反思自身前提的能力。它允许文明追问：我们如何知道自己知道？我们的制度是否正当？我们的责任概念是否足以处理新的行动结构？我们的价值排序是否已经被工具理性劫持？我们对人的理解是否过于狭窄？我们是否把生成误认为真实，把选择形式误认为主体性，把能力增长误认为文明进步？

这种反思能力不同于局部纠错。局部纠错可以由技术优化、政策调整或制度改革完成。哲学反思则指向更基础的前提：什么算错误，什么算证据，谁有权判断，为什么需要责任，什么值得被保护。文明的深层危机往往不是应用层错误，而是这些基础范畴失去稳定性。

AI 时代正是这样一种情境。AI 不仅带来新的工具，也改变文明判断工具、主体、责任和意义的方式。如果文明无法反思这些基础范畴，它可能用旧概念解释新现实，结果是既无法准确诊断风险，也无法形成有效回应。

因此，哲学是文明自我理解、自我调试和自我更新的内核机制。没有这一机制，文明可能继续运行，但它将越来越依赖惯性、效率和自动化，而不是理解和反思。这样的文明也许更快，却不一定更清醒。

5.7 哲学内核与 AI 存在性风险的关系

将哲学理解为文明内核，有助于解释为什么 AI 相关人类存在性风险不能只在应用层或工具层被理解。AI 若只改变某个工具的效率，那么它主要是技术风险。AI 若只影响某个行业的工作流程，那么它主要是产业风险。AI 若只造成某类内容质量问题，那么它主要是信息治理风险。然而，如果 AI 开始改变文明如何定义真实、责任、主体性、价值和意义，那么它就触及文明内核层。

这并不意味着任何 AI 应用都构成内核层风险。一个概念若被过度泛化，就会失去解释力。关键在于 AI 的嵌入是否使文明基础范畴变得不稳定，或者使人类越来越难以维持这些范畴的反思性修正能力。此时，风险对象不只是某个系统是否表现良好，而是文明是否仍能理解自己、修正自己，并维持那些使人类作为文明主体继续存在的基础范畴。

若人类文明由真实、责任、主体性、价值与意义等基础范畴支撑，那么 AI 对这些范畴的系统性扰动就不能被简单归为应用层问题。它要求我们在讨论技术性能、产品安全、制度治理或社会影响之

前，先澄清这些变化是否正在触及人类作为文明主体继续成立的条件。换言之，哲学内核不是外在解释层，而是 AI 风险分析本身必须面对的概念基础。

5.8 本节小结

本节论证了哲学作为文明内核的意义。这里的哲学不是狭义学科，而是文明定义和修正自身基础范畴的反思结构。文明中的科学、法律、政治、经济、教育、文化和艺术等系统，都必须调用关于真实、责任、主体性、价值和意义的底层范畴。哲学正是这些范畴的显化、澄清和修正机制。

将哲学理解为文明内核，有助于解释为什么 AI 风险不能只在应用层或工具层被理解。AI 若只改变工具效率，那么它主要是技术风险；AI 若进入真实、责任、主体性、价值和意义范畴，那么它就可能成为文明内核层风险。如果人类作为文明主体而存在，那么那些支撑文明主体的基础范畴，就构成人类存在性风险分析不可绕开的对象。

下一节将使用“硬件—内核—发行版”的功能性类比，进一步澄清人类物种、哲学内核、人类文明以及文明功能系统之间的层级关系。

6 | 硬件—内核—发行版：一个功能性类比及其边界

前文已经区分了人类物种、人类文明与哲学内核三个层级。人类物种是文明得以发生的生物学基底；人类文明是人类物种形成的跨代际共同运行环境；哲学则是文明用来定义真实、责任、主体性、价值与意义等基础范畴的反思性内核。为了进一步澄清这三者之间的关系，本文引入一个功能性类比：硬件、内核与发行版。

需要提前说明的是，这一类比不是字面等同。人类不是机器，文明不是软件，哲学也不是代码。本文使用这一类比，不是为了将人类文明技术化，也不是为了用工程语言替代哲学分析，而是为了更清楚地表达不同层级之间的功能关系：某些层级提供物理承载，某些层级提供基础范畴与规则接口，某些层级则构成可被历史性部署、更新、继承和本地化的完整运行环境。

在计算机系统中，单纯说“操作系统”往往不够精确。它有时指内核，有时指完整用户环境，有时指某个具体发行版。在这一类比中，内核指底层基础接口，发行版指围绕内核组织出来的完整用户环境。为了避免概念混乱，本文使用更细的类比：人类物种类似硬件；哲学内核类似 **Linux kernel**；人类文明则更接近 Ubuntu、Debian 或 Red Hat Enterprise Linux 这样的发行版，即一个包含内核、系统工具、库、权限设置、软件生态、用户界面、默认配置和实践习惯的完整操作环境。[注 6]

这个类比的价值在于，它能帮助我们避免两种混淆。第一，硬件存在不等于系统完整运行。第二，发行版能够启动不等于内核没有问题。类似地，人类身体仍然存在，不等于人类文明主体仍然完整；社会系统仍然运行，不等于其底层范畴仍然稳定；科学、法律、经济、教育、文化等功能系统仍然产生输出，不等于真实、责任、主体性、价值和意义这些基础接口仍然健康。

6.1 人类物种作为硬件

在人类存在的三层结构中，人类物种对应于物理承载层。以计算机系统类比，它类似于硬件。硬件提供计算系统得以运行的物质基础。没有处理器、内存、存储、电源、总线和输入输出设备，任何

内核、发行版和应用程序都无法实际运行。类似地，没有人类身体、大脑、神经系统、感知能力、繁殖机制和物质环境依赖，人类文明也无从发生。

这一类比有助于说明物种层的基础性。人类文明并不是脱离人类身体而独立存在的信息云。文明依赖具身的人类生命。语言学习、情感发展、教育传承、伦理关系、责任承担和意义形成，都与人类的身体条件、时间性、有限性和脆弱性有关。因此，人类物种作为生物基底，不是可以被文明层分析替代的对象。

然而，硬件并不等于完整系统。一台没有内核、没有发行版、没有文件系统、没有用户环境和应用程序的计算机，并不构成一个可用的计算环境。类似地，人类物种本身也不自动构成完整人类文明。生物身体提供承载，但文明还需要语言、制度、知识、规范、记忆和意义结构。物种层是必要条件，但不是充分条件。

这一点对于 AI 相关人类存在性风险的分析尤为重要。如果 AI 直接威胁人类身体、生态条件或繁衍能力，那么它威胁的是物种层。此类风险当然是最基础意义上的存在性风险。但如果 AI 不直接破坏人类身体，而是改变文明如何判断真实、分配责任、形成主体性和理解意义，那么它威胁的是更高层的系统结构。硬件仍然存在，并不意味着系统仍然健康运行。

6.2 哲学作为 Linux kernel

如果人类物种可以类比为硬件，那么哲学更适合被类比为内核。以 Linux 系统为例，**Linux kernel** 并不是用户日常直接操作的完整系统，却是系统运行的基础层。它管理硬件资源，提供系统调用接口，维持权限边界，协调进程与资源，并使上层工具和应用能够以稳定方式运行。用户通常不是直接面对内核，而是通过 Ubuntu、Debian、Red Hat Enterprise Linux 等发行版进入一个完整操作环境；但如果内核层出现严重问题，整个系统的稳定性都会受到影响。

对应到文明中，哲学作为内核，并不是指某套固定哲学理论支配所有文明，也不是指学院哲学在制度上高于科学、法律、政治或文化。它指的是：任何文明在运行时都必须隐含一套基础范畴，用来定义真实、证据、责任、主体性、价值与意义。这些范畴不是应用层可以自行完全决定的，因为应用层系统本身必须调用它们才能成立。

科学必须调用真实和证据的接口。法律必须调用主体和责任的接口。政治必须调用合法性和公共性的接口。经济必须调用价值和偏好的接口。教育必须调用关于人、知识和成长的接口。文化必须调用意义和表达的接口。若这些底层接口发生混乱，文明的功能系统仍可能继续运作，但其输出会变得不可解释、不可归责或不可修正。

从这一角度看，哲学之所以可以被称为文明内核，是因为它处理的是文明最底层的范畴结构。一个文明可以没有显性的哲学学科，却不可能没有关于真实、责任、主体性、价值和意义的隐性规定。哲学是这些规定被反思、显化、批判和修正的机制。

6.3 人类文明作为 Ubuntu 式发行版

如果哲学是内核，那么人类文明不能被简单称为“操作系统”而不作进一步区分。因为“操作系统”在日常语言中有时指内核，有时指发行版，有时指整个用户环境。为了避免概念坍缩，本文更倾向于将人类文明类比为发行版或完整操作环境。

以 Linux 生态为例，Ubuntu、Debian 和 Red Hat Enterprise Linux 等发行版并不只是 Linux kernel。它们包含系统工具、库、包管理器、文件系统组织、默认权限设置、用户界面、网络配置、

驱动、文档、应用生态和使用习惯。不同发行版可能共享某些内核机制，却呈现出不同的用户体验、治理方式、软件生态和默认价值取向。

人类文明也类似。文明并不只是哲学内核，也不只是科学、法律或技术应用。文明是一个完整运行环境，包括语言、制度、法律、科学、教育、经济、技术、艺术、宗教、公共理性、历史记忆、意义叙事和实践传统。它将底层哲学范畴转化为可生活、可制度化、可教育、可传承、可争论、可修正的共同世界。

这一类比还有助于理解文明多样性。不同文明传统可以在某些基础范畴上共享相似问题，例如真实、责任、主体性、价值和意义，却通过不同制度、语言、礼法、知识系统和文化形式加以组织。类似地，不同 Linux 发行版可以共享 Linux kernel，却形成不同的系统风格、默认配置和使用方式。文明之间的差异，不能简单还原为底层内核差异，也不能忽视底层范畴的共同压力。

因此，人类文明作为发行版或完整操作环境，是人类物种与哲学内核之间的历史性展开。它一方面依赖人类物种这一硬件层，另一方面调用哲学内核所提供的底层范畴接口，并通过制度、知识、文化、技术和教育系统形成可运行的共同世界。

6.4 人类文明整体：多重文明传统构成的共同生态

这里还需要进一步澄清“人类文明”这一表达的尺度。本文所说的人类文明，并不等同于某一个国家、某一种文化、某一个历史文明传统，也不是将某一具体文明形态普遍化为全人类。人类文明应被理解为一个由多重文明传统共同构成的总体性文明生态。不同文明传统可能拥有不同语言、宗教、制度、法律、知识传统、艺术形式和意义叙事，但它们共同构成了人类物种在历史中形成的跨代际共同世界。

在前述工程类比中，具体文明传统可以被理解为不同的发行版或系统配置。它们可能共享某些底层范畴问题，例如真实、责任、主体性、价值与意义，也可能以不同方式回答这些问题。中华文明、印度文明、伊斯兰文明、西方现代文明以及其他文明传统，并不是同一个发行版的简单复制，而是在不同历史条件下形成的文明运行环境。它们各自拥有自己的制度配置、知识结构、文化界面和意义系统。

但是，人类文明整体并不是这些文明传统的机械相加。它更接近一个由多重发行版、共享协议、交叉依赖、历史记忆、知识交换、冲突经验和制度接口共同构成的文明生态。现代科学体系、国际法、全球贸易、金融网络、大学制度、公共卫生系统、互联网协议、数字平台和 AI 基础设施，已经使不同文明传统之间形成前所未有的相互嵌入。人类文明整体因此既包含差异，也包含共同结构；既保留多样性，也拥有某些全球性的运行条件。

这一点对于 AI 相关人类存在性风险至关重要。AI 对文明的影响并不只作用于某一个文明传统内部，也可能作用于人类文明整体的共同接口：知识如何被生产和验证，制度如何分配责任，技术如何进入治理，公共讨论如何维持共同现实，人类如何理解自身价值和未来。这些接口一旦受到系统性扰动，影响就可能跨越国家、文化和地区，成为人类文明整体层面的风险。

因此，本文所说的人类文明主体，不是某一文化共同体、国家主体或单一文明传统，而是人类作为跨代际、跨制度、跨知识系统和跨意义结构的总体文明主体。它包括多重文明传统的差异性，也包括这些传统共同构成的人类文明整体。AI 相关人类存在性风险，正是在这一整体尺度上，要求我们重新理解“人类”这一风险承受主体。

6.5 文明功能系统作为应用层

在明确人类文明整体由多重文明传统共同构成之后，还需要进一步说明文明中的功能系统。科学、法律、政治、经济、教育、艺术、宗教、媒体和技术系统，可以被理解为文明发行版中的功能系统或应用层。它们各自执行特定任务：科学生产知识，法律分配责任，政治组织权力，经济协调资源，教育传递能力，艺术表达意义，宗教维持终极关怀，媒体组织公共注意力，技术扩展行动能力。

这些功能系统并非次要。恰恰相反，文明的实际运行主要通过这些系统展开。普通人通常不是直接面对“哲学内核”，而是通过学校、法院、实验室、市场、媒体、家庭、宗教、艺术、企业和政府进入文明。就像用户通常不是直接操作 Linux kernel，而是通过 Ubuntu、Debian 或 Red Hat Enterprise Linux 这样的发行版，使用其中的界面、工具、权限设置和应用生态。

在具体文明传统内部，这些功能系统会呈现出不同配置。不同文明可以拥有不同的法律传统、教育目标、宗教结构、艺术形式、政治组织和意义叙事。它们就像不同发行版中预装的工具、默认配置和用户习惯，体现出各自的历史路径与价值排序。因此，文明功能系统并不是抽象地漂浮在全人类之上，而是在具体历史、语言、制度和文化中配置出来。

但是，在现代条件下，许多文明功能系统也已经形成跨文明、全球化的接口。现代科学共同体、国际法体系、全球金融网络、大学制度、公共卫生系统、互联网协议、供应链结构、数字平台和 AI 基础设施，已经不完全属于某一个国家或某一种文明传统。它们在不同文明传统之间流动、连接、冲突和融合，成为人类文明整体的功能层。正因如此，对这些系统的扰动也可能不再停留在地方性范围内，而会通过全球接口扩散到人类文明整体。

然而，应用层系统不能脱离底层范畴独立运行。科学若失去真实和证据接口，就会退化为符号生产。法律若失去主体和责任接口，就会保留程序而失去问责能力。教育若失去关于人和成长的范畴，就会变成技能分发或系统适配。经济若失去价值判断，就会把可度量性误认为重要性。艺术若失去意义结构，就会变成内容生产。技术若失去目的边界，就会把能力增长误认为文明进步。

因此，文明功能系统的健康，不仅取决于它们自身是否高效，也取决于它们是否仍然能够稳定调用底层范畴。应用层繁荣并不等于内核层健康。内容可以更多，知识却更不可靠；流程可以更快，责任却更不清楚；选择可以更多，主体性却更薄弱；娱乐可以更丰富，意义却更贫乏。

在这一意义上，应用层的繁荣并不自动证明文明系统健康。内容可以更多，流程可以更快，界面可以更顺畅，用户满意度可以更高，但这些都不能单独说明真实、责任、主体性、价值和意义等底层接口仍然稳定。AI 时代尤其需要警惕一种情形：文明功能系统在效率上持续增强，而其底层范畴承受的压力却变得更难被感知。一个系统越流畅，用户越可能相信它健康；一个文明越便利，人类越可能忽视自己是否仍然保留判断、责任和意义形成的能力。

AI 对文明功能系统的影响，也必须在这一尺度上理解。AI 不只是进入某个产品、某个行业或某个国家制度，而是正在进入科学写作、法律文书、教育训练、企业决策、媒体传播、艺术创作、行政流程和公共讨论等多个功能系统。它可能提高这些系统的效率，也可能改变这些系统调用真实、责任、主体性、价值和意义等底层范畴的方式。由此，AI 的影响不只是应用层变化，也可能通过应用层反向施压于文明内核。

6.6 AI 对三层结构的不同压力

在上述类比中，AI 并不是只进入某一个应用场景，也不是只影响某一个文明传统内部的局部系统。它正在通过科学、法律、教育、经济、媒体、行政、企业和日常生活等功能系统，进入人类文明整

体的运行环境。正因如此，AI 对人类存在的压力需要分层理解：它可以作用于物种层，也可以作用于文明层，还可以作用于内核层。不同层级的风险不能相互替代，也不能混为一谈。

当 AI 进入生物技术、关键基础设施、自动化武器、网络系统或其他高后果现实行动链条时，它可能作用于物种层，影响人类的生物学存续与未来开放性。此时，风险指向硬件层，即人类作为具身物种是否存在。

当 AI 进入教育、法律、科研、行政、企业、媒体、公共服务和日常生活时，它作用于文明层。它可能改变知识如何被组织，制度如何形成判断，责任如何被分配，公共理性如何维持，文化与意义如何被生产。此时，风险不是直接破坏身体，而是重组文明发行版的运行环境。

当 AI 改变真实、证据、责任、主体性、价值和意义这些基础范畴的稳定性时，它作用于内核层。此时问题不只是某个制度流程是否出错，也不只是某个模型输出是否可靠，而是文明是否仍能理解自己、修正自己，并维持那些使人类作为文明主体继续存在的底层概念接口。

这一层级区分解释了为什么 AI 相关人类存在性风险不能只被理解为物种灭绝风险，也不能只被理解为产品安全或制度合规问题。AI 可能并不首先破坏硬件，却改变发行版；也可能并不立刻摧毁发行版，却污染或扰动内核接口。若内核层范畴失效，应用层系统仍可能继续运行，但它们将越来越难以解释自己的输出、归属自己的责任、理解自己的目的。

6.7 类比的边界

任何类比都有边界。硬件—内核—发行版的类比不是为了把人类文明还原为计算机系统，也不是为了暗示文明有一个单一、封闭、完全可设计的内核。人类文明比计算机系统更开放、更历史化、更冲突、更不可预测。哲学内核也不是一个中央控制模块，而是一组在历史中被不断争论、解释、修正和制度化的基础范畴。

此外，计算机内核通常由有限工程团队维护，而文明的哲学内核没有单一维护者。它分散在宗教、法律、哲学、科学、教育、政治、艺术和公共讨论之中。它通过争论而不是编译更新，通过实践而不是命令生效，通过代际传承而不是版本发布延续。因此，类比不能被推到字面层面。

这一类比真正要表达的，只是三个功能关系。第一，文明需要生物学承载，就像系统需要硬件。第二，文明功能系统需要底层范畴接口，就像应用需要内核服务。第三，完整文明生活不是内核本身，而是由内核、工具、制度、实践和用户环境共同构成的历史性运行环境，就像 Ubuntu 这样的发行版不是 Linux kernel 本身，而是围绕内核形成的完整系统世界。

在这个有限意义上，类比是有用的。它帮助我们看见：人类存在性风险不只可能发生在硬件层，也可能发生在发行版层和内核层。人类物种仍然存在，不等于文明发行版仍然健康；文明功能系统仍然运行，不等于哲学内核仍然稳定。AI 时代迫使我们同时关注这三个层级。

6.8 本节小结

本节通过硬件—内核—发行版的功能性类比，进一步澄清了人类物种、哲学内核与人类文明之间的关系。人类物种类似硬件，是文明的生物学承载；哲学内核类似 Linux kernel，是文明基础范畴的底层接口；具体文明传统可以被理解为不同发行版或系统配置；人类文明整体则是由多重文明传统、共享协议、跨文明功能系统和全球接口共同构成的总体性文明生态。

这个类比的目的是不是将人类技术化，而是帮助理解层级差异。硬件仍在，不等于系统运行良好；发

行版仍能启动，不等于内核没有损坏；应用仍然繁荣，不等于底层接口稳定。类似地，人类物种仍然存续，不等于人类文明主体仍然完整；制度和技术系统仍然运行，不等于真实、责任、主体性、价值和意义这些基础范畴仍然健康。

下一节将进一步说明，为什么 AI 的发展使这一三层结构不再只是哲学分析，而成为 AI 相关人类存在性风险理论必须面对的问题。

7 | AI 为什么使这一三层结构成为存在性风险问题

前文区分了人类物种、人类文明与哲学内核三个层级，并通过硬件—内核—发行版的功能性类比说明了它们之间的关系。这个结构并不是为了建立一套抽象的人类学图式，而是为了澄清 AI 时代的人类存在性风险究竟可能作用于什么对象。AI 之所以使这一三层结构变得重要，是因为它并不只影响某个工具、行业或应用场景，而是正在进入人类物种、文明运行环境与基础范畴结构之间的连接处。

如果 AI 只是一种外部工具，它的风险主要可以通过产品安全、使用规范、行业监管或工程可靠性来分析。但当前 AI 系统正在越来越多地中介人类获取知识、形成判断、组织行动、执行制度和理解自身的方式。它不是简单地增加一个工具，而是进入人类文明的运行环境；不是只影响某个应用层，而是可能反向改变文明功能系统调用真实、责任、主体性、价值与意义等底层范畴的方式。正因如此，AI 风险不能只在单一层级被理解。

7.1 AI 与物种层

在物种层，AI 相关风险最容易被传统存在性风险语言捕捉。若足够强大的 AI 系统能够影响生物技术、关键基础设施、自动化武器、网络系统、能源系统、供应链或其他高后果现实行动链条，那么它可能间接或直接威胁人类的生物学存续和未来开放性。此类风险指向人类作为具身物种是否继续存在，因此属于最直接意义上的人类存在性风险。

这一点必须被保留。强调文明主体层风险，并不意味着物种层风险变得次要。相反，人类物种是文明的生物学承载。若物种层被摧毁，文明无从延续。任何扩展性风险框架，都必须承认物种灭绝、永久失能和未来封闭的基础地位。

然而，AI 对人类的影响并不必然首先以这一形式出现。许多 AI 系统在当前阶段并不直接作用于人类身体或繁衍能力，而是先进入信息、判断、制度和行动环境。它们通过改变人类如何认识、如何组织、如何授权和如何行动，间接影响人类处理高后果技术风险的能力。因此，物种层风险虽然最基础，却不能穷尽 AI 时代的人类风险对象。

7.2 AI 与文明层

在文明层，AI 的影响表现为对人类共同运行环境的重组。AI 系统正在进入教育、科研、法律、医疗、行政、企业、媒体、艺术、公共服务和日常生活等文明功能系统。它们可以帮助整理信息、生成文本、比较方案、筛选证据、辅助判断、自动化流程和组织行动。这些功能具有真实价值，也能极大扩展人类能力。

但正因为 AI 有用，它才会被广泛吸收进文明系统。一个工具若只是外部附加物，其影响通常局限于局部使用场景；一个工具若成为知识入口、制度流程、组织判断和日常行动的中介，它就开始改变文明运行环境本身。此时，风险不再只是“某个系统输出是否正确”，而是人类共同世界中的知识、制度、责任和判断结构是否正在被重新组织。

在这一层面，AI 可能使文明仍然保持表面运行，却逐渐改变其内部条件。学校仍然教学，法院仍然裁判，企业仍然决策，政府仍然发布政策，媒体仍然生产内容，个体仍然做出选择。但这些过程中的问题定义、资料整理、证据筛选、理由生成、风险排序和行动路径，可能越来越多地由 AI 系统预先组织。文明并未停止运行，却可能在运行方式上发生深层变化。

这里的关键不只是自动化程度，而是人类在行动形成过程中的位置。如果人类逐渐从定义问题、搜集证据、比较理由和形成判断的完整链条中，退到确认、批准或消费结果的末端节点，那么文明主体性已经发生结构性变化。这样的变化不需要恶意设计，也可能由效率、便利和用户体验优化自然推动。它并不表现为人类被排除在流程之外，而是表现为人类仍在流程中，却越来越少参与判断形成的前端过程。

这说明，AI 对文明层的影响不能被简化为效率提升或产业变革。效率提高本身并不构成存在性风险；问题在于，当效率提升伴随知识验证、责任分配、判断形成和意义传承方式的结构性变化时，AI 就开始触及人类作为文明主体继续成立的条件。人类文明不只是任务完成系统，而是一个使人能够理解、判断、负责、传承和创造意义的共同世界。

7.3 AI 与内核层

在内核层，AI 的影响更加深层。这里的问题不只是某个制度流程是否采用了 AI，也不只是某类任务是否被自动化，而是文明用来定义真实、责任、主体性、价值和意义的基础范畴是否受到压力。

当 AI 生成的内容越来越像知识，文明需要重新区分生成、解释、证据和真实。一个系统能够给出流畅解释，并不意味着它提供了可验证知识。若人类越来越以生成内容作为认识起点，而不是以来源、证据和验证过程作为认识基础，那么真实范畴就会受到压力。

当 AI 参与建议生成、证据筛选、风险评估和行动触发，文明需要重新理解责任和授权。一个人类主体签署了最终文件，并不必然意味着他理解了判断形成过程。一个制度保留审批和审计流程，并不必然意味着它能够追踪行动如何形成。责任范畴因此面临新的结构条件。

当 AI 替人类预组织问题、方案、理由和行动路径，文明需要重新理解主体性。主体性不能被简单等同于最后一次点击、确认或选择。若人类保留选择形式，却越来越少参与问题定义、证据判断和理由形成，那么主体性范畴就需要重新澄清。

当 AI 能够生成作品、研究、设计、陪伴和决策建议，文明也需要重新理解价值与意义。若能力、效率和产出不再稳定区分人类与机器，人类必须重新追问创造、学习、劳动、责任和尊严的基础。意义范畴因此不再只是个人心理问题，而成为文明自我理解的一部分。

这些变化说明，AI 可能触及文明内核层。它不只是改变应用层输出，也可能改变文明功能系统调用底层范畴的方式。一旦这些范畴变得不稳定，文明仍可能保持制度和技术运行，却越来越难以解释自己的知识、责任、主体性和目的。

7.4 三层结构的相互依赖

物种层、文明层和内核层并不是彼此孤立的三个对象。它们之间存在嵌套和相互依赖关系。物种层提供生物学承载；文明层提供跨代际共同运行环境；内核层提供文明理解、修正和更新自身的基础范畴。任一层级出现深层损害，都可能影响其他层级。

物种层风险会终止文明的生物承载，这是最直接的存在性损害。文明层风险会削弱人类共同组织知识、制度、责任和意义的能力，从而影响人类作为集体主体的行动能力。内核层风险则会削弱文明理解自己、修正自己和定义自身目标的能力，使文明即使继续运行，也难以判断自己是否仍然健康。

这种相互依赖在 AI 条件下尤其重要。一个缺乏真实判断能力的文明，难以识别高后果技术风险；一个责任结构不清的文明，难以治理复杂行动链条；一个主体性弱化的文明，难以长期保持自主判断；一个意义结构动摇的文明，可能缺乏保护未来的理由。因此，保护人类物种本身，也依赖文明层和内核层能力；保护文明主体，也不能脱离物种层承载。

由此可见，AI 相关人类存在性风险不能被压缩为单一层级的问题。它可能同时涉及物种存续、文明连续性和基础范畴稳定性。一个只关注物种层的风险框架，会低估文明主体条件的损害；一个只关注社会适应的框架，则会低估物种层风险和内核层范畴压力。完整分析需要同时看见这三个层级。

7.5 从三层结构到风险承受主体

这一三层结构最终指向本文的核心问题：AI 相关人类存在性风险的承受主体是什么？如果风险承受主体只是 *Homo sapiens* 这一生物物种，那么风险分析将主要关注人类是否灭绝、是否永久失能、是否失去生物学未来。这个层级不可或缺，但并不充分。

如果风险承受主体还包括人类作为文明主体，那么风险分析就必须进一步关注人类是否仍然能够维持一个可传承、可验证、可追责、可反思、可更新、可赋予意义的共同世界。人类不只是活着的生物体，也是生活在语言、制度、责任、知识和意义结构中的历史主体。AI 若改变这些结构，便可能改变人类作为文明主体继续成立的条件。

因此，本文并不是将 AI 风险无限扩张为所有社会变化，而是在澄清风险承受主体的层级结构。物种层风险关注人类是否继续存在；文明层风险关注人类是否仍能作为共同世界的主体存在；内核层风险关注人类文明是否仍能理解、修正和更新自身基础范畴。三者共同构成 AI 相关人类存在性风险分析所需要的承受主体概念。

7.6 本节小结

本节说明了为什么人类物种、人类文明与哲学内核的三层结构，在 AI 时代成为存在性风险理论必须面对的问题。AI 可能作用于物种层，影响人类生物学存续与未来开放性；也可能作用于文明层，重组知识、制度、责任、判断和意义结构；还可能作用于内核层，使真实、责任、主体性、价值与意义等基础范畴承受压力。

这并不意味着任何 AI 应用都构成存在性风险，也不意味着所有社会变化都应被纳入存在性风险概念。关键在于，当 AI 的影响触及人类作为文明主体继续成立的基础条件，并可能造成不可逆或难以逆转的结构性损害时，风险分析就不能只停留在物种层或应用层。下一节将据此提出 AI 相关人类存在性风险的扩展定义。

8 | 重新定义 AI 相关人类存在性风险：从物种生存到文明主体

前文的论证可以收束为一个概念工程任务：重新界定 AI 相关人类存在性风险中的风险承受主体。就概念工程而言，问题不只是分析既有概念如何被使用，也包括在新的理论和实践压力下修正概念，使其更好地服务解释、判断和行动（Chalmers, 2025; Haslanger, 2005）。若“人类”只被理解为 *Homo sapiens* 这一生物物种，那么 AI 相关人类存在性风险就主要指向人类是否会被物理毁灭、永久失能、剥夺生物学未来，或在某种决定性意义上失去对自身未来的控制。这个理解抓住了存在性风险中最直接、最基础的形式，但不足以穷尽 AI 时代的风险对象。

人类也作为文明主体存在。人类通过语言、知识、制度、责任、真实、主体性、价值与意义，形成一个跨代际共同世界。这个共同世界不是物种之外的装饰，而是人类作为历史主体、认识主体、责任主体和意义主体存在的条件。AI 若只影响外部工具或局部行业，未必构成人类存在性风险；但如果 AI 不可逆地削弱人类作为文明主体继续成立的条件，那么即使人类物种仍然存续，风险也可能具有存在性意义。

因此，本文提出如下扩展定义：

AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的、可能不可逆地毁灭人类物种，永久剥夺人类未来，或不可逆地削弱人类作为文明主体继续成立之基础条件的风险。

这个定义保留了物种层存在性风险的核心地位，同时将风险承受主体从单一生物物种扩展到文明主体。它不要求所有 AI 引发的社会变化都被纳入存在性风险，也不要求每一种文明扰动都被视为存在性损害。它只主张：当 AI 的影响触及人类文明主体继续成立的基础条件，并具有不可逆或难以逆转的结构性的后果时，存在性风险理论就不能只以生物学存续为判断对象。

8.1 为什么需要扩展定义

扩展定义的必要性来自 AI 的特殊位置。许多技术能够改变人类行动能力，但并不直接改变文明基础范畴。AI 的特殊性在于，它正在进入知识、制度、判断、行动和意义结构之中。它不仅可能执行任务，也可能中介人类如何定义问题、如何获得证据、如何形成理由、如何分配责任、如何理解价值和意义。

在这种条件下，传统物种中心定义会遇到一个盲区。若 AI 没有直接杀死人类，也没有立即摧毁人类繁衍能力，但使人类越来越难以验证真实、分配责任、形成判断、维持制度或创造意义，那么这种损害很容易被降格为社会问题、文化变化、适应困难或治理滞后。然而，一旦这些能力是人类作为文明主体继续成立的基础条件，它们的不可逆削弱就不能被简单视为普通社会变化。

扩展定义并不是为了降低存在性风险概念的门槛，而是为了使其承受主体更完整。人类存在性风险之所以重要，不仅因为人类作为生物物种可能消失，也因为人类作为能够认识、负责、判断、创造意义并面向未来行动的文明主体可能被不可逆地削弱。如果后一种损害被排除在存在性风险理论之外，AI 风险分析就会系统性低估那些不以肉体灭绝形式出现的深层风险。

8.2 物种层风险仍然是基础形式

扩展定义并不削弱物种灭绝、永久失能或未来封闭的严肃性。相反，它以这些风险为基础。若人类物种灭绝，文明主体无从延续；若人类永久失去塑造未来的能力，人类文明也失去继续展开的历史空间。因此，物种层风险仍然是人类存在性风险中最直接、最不可替代的形式。

本文所作的修正，并不是把文明主体性风险置于物种风险之上，而是指出二者处于不同层级。物种层风险关注人类是否继续作为生物种群存在；文明主体层风险关注人类是否继续作为能够认识、治理、判断、负责和创造意义的共同主体存在。前者是后者的生物学前提，后者是前者作为“人类未来”而不只是“生物延续”得以具有意义的文明条件。

因此，扩展定义不是替换传统存在性风险，而是补足传统定义在 AI 条件下可能遗漏的风险对象。它保留物种毁灭作为底线，同时指出：只要人类作为文明主体的基础条件可能被不可逆削弱，存在性风险理论就需要将其纳入分析范围。

8.3 文明主体性风险的门槛

为了避免概念泛化，文明主体性风险必须有明确门槛。并不是所有 AI 引发的制度变化、文化变迁、职业替代、技术适应或心理不安，都构成人类存在性风险。一个风险若要进入文明主体层面的存在性风险范围，至少需要满足四个条件。

第一，它必须作用于文明基础条件，而不是局部功能。某个行业被重组、某种职业被替代、某个制度流程被自动化，并不自动构成存在性风险。只有当这些变化系统性影响人类认识真实、分配责任、形成判断、维持制度或创造意义的能力时，它们才可能具有文明主体层面的风险意义。

第二，它必须具有跨领域扩散能力。局部错误、单一事故或孤立误用通常不足以构成存在性风险。只有当某种机制能够跨越教育、科学、法律、媒体、企业、公共治理和日常生活，并在多个系统中反复改变人类判断、责任或意义结构时，它才具有文明主体性风险特征。

第三，它必须可能造成不可逆或难以逆转的结构性损害。存在性风险关心的不只是损失规模，也关心可逆性。若某种技术嵌入方式长期重塑教育、认知习惯、制度程序和主体能力，使若干代人逐渐丧失某些基础能力，那么即使没有发生物理毁灭，它也可能构成深层存在性风险。

在文明尺度上，不可逆性并不总是指绝对无法恢复，而是指恢复成本、代际损耗、制度路径依赖和能力训练断裂达到足以改变未来主体能力的程度。某些能力一旦长期不被训练和传承，其损失未必表现为被剥夺，而可能表现为后代不再把它体验为一种缺失。这样的损害即使并非形而上不可逆，也可能在历史尺度上变得极难逆转。[注 7]

第四，它必须影响人类作为未来主体的能力。存在性风险不是任何重大损害，而是影响人类能否继续作为自身未来主体的风险。如果某种 AI 嵌入方式使人类越来越难以认识真实、共同治理、形成自主判断、承担责任和创造意义，那么它就不只是社会适应问题，而是文明主体条件受到损害的问题。

这四个条件使扩展定义保持边界。它既防止将存在性风险缩减为物种灭绝，也防止将所有社会问题提升为存在性风险。文明主体性风险之所以具有存在性意义，不是因为它听起来重大，而是因为它作用于人类作为文明主体继续成立的基础能力。

8.4 为什么这不是普通社会风险

文明主体性风险与普通社会风险的区别，在于其作用对象、扩散结构和可逆性不同。普通社会风险可能很严重，但通常作用于某个制度、行业、群体、地区或时期。它们可能造成巨大损失，却不一定改变人类作为文明主体继续成立的基础条件。

AI 对文明主体条件的影响并非只能是削弱性的。相关 AI alignment 与 meaningful human control 文献已经显示，AI 系统也可能在价值澄清、责任追踪和人类控制能力扩展方面发挥积极作用（Gabriel, 2020; Santoni de Sio & van den Hoven, 2018）。风险产生于另一种情形：当这种中介作用长期替代而非增强人类的基础能力，并使这些能力的训练、传承和恢复变得困难时，它才进入文明主体性风险的范围。[注 8]

文明主体性风险的关键在于，它作用于文明共同世界的底层能力：认识真实的能力、分配责任的能力、形成判断的能力、维持制度的能力、创造和传承意义的能力。这些能力不是某个部门的功能，而是人类作为文明主体得以持续行动的条件。若它们被系统性削弱，社会仍可能运行，技术仍可能进步，人口仍可能延续，但人类作为自身未来主体的能力会被削弱。

这种风险也不同于一般文化焦虑。文化焦虑常常来自对变化的不安，未必具有存在性意义。文明主体性风险的判断不能基于怀旧、风格偏好或对技术变化的本能抵抗，而必须基于结构条件：某种变化是否削弱人类认识、判断、负责和创造意义的能力；这种削弱是否跨领域扩散；是否难以逆转；是否影响未来主体能力。

因此，文明主体性风险不是把社会变化道德化，也不是把技术适应病理化。它是一个更严格的问题：AI 是否可能改变那些使人类作为文明主体继续成立的基础条件。

8.5 为什么这仍然是存在性风险

一个可能的反对意见是：只要人类没有灭绝，这类风险就不应被称为存在性风险。按照这种观点，真实、责任、主体性或意义的损害再严重，也应被视为社会、伦理或文化风险，而不是存在性风险。

这个反对意见抓住了存在性风险概念的高门槛，但它过度缩窄了“人类存在”的对象。人类存在并不只是生物体的延续。人类作为文明主体的存在，包含认识真实、形成制度、承担责任、进行判断、创造意义并面向未来行动的能力。若这些能力被不可逆削弱，那么受损的不只是某个制度或文化领域，而是人类作为未来主体的存在方式。

存在性风险之所以区别于一般重大风险，不只在于其损害规模，也在于其是否影响人类未来的开放性和主体性。如果人类物种继续存在，但其认识、责任、判断和意义能力被系统性削弱到无法再作为自身未来的主体行动，那么这种状态虽然不同于物种灭绝，却仍然具有深层存在性意义。

因此，文明主体性风险并不是存在性风险概念的任意扩张，而是对“人类存在”这一对象的更完整理解。它要求我们将生物学延续与文明主体延续区分开来，同时承认二者共同构成人类未来的条件。

8.6 对 AI 风险理论的意义

这个扩展定义对 AI 风险理论具有三个直接含义。

第一，它改变了风险承受主体。AI 风险分析不能只问 AI 是否会毁灭人类物种，也必须问 AI 是否会不可逆地削弱人类作为文明主体继续成立的条件。风险对象从生物种群扩展为具身物种、文明共

同世界和哲学内核构成的嵌套主体。

第二，它改变了风险识别方式。某些 AI 风险不一定首先表现为灾难性物理事件，而可能表现为文明基础能力的结构性退化。知识仍然被生产，制度仍然运行，内容仍然生成，选择仍然存在，但真实、责任、主体性和意义这些底层条件可能已经受到压力。风险分析因此需要关注形成过程、结构条件和可逆性，而不能只关注最终灾难后果。

第三，它改变了治理问题的前提。若 AI 风险只被理解为物种层风险，那么治理主要关注避免灾难性失控、物理毁灭和永久失能。若 AI 风险也包括文明主体性风险，那么治理还必须关注真实如何维持，责任如何归因，主体性如何保留，意义如何延续，文明如何保持自我修正能力。治理不再只是约束外部技术系统，也包括保护人类作为文明主体的基础条件。

这些含义并不构成具体风险分类，也不提供具体治理方案。它们只是说明，一旦风险承受主体被重新界定，AI 风险理论的分析范围、识别标准和治理前提都会发生相应变化。

8.7 本节小结

本节提出了 AI 相关人类存在性风险的扩展定义。该定义保留传统物种层风险的基础地位，同时指出，人类也作为文明主体存在。AI 若不可逆地削弱人类作为真实、责任、主体性与意义主体继续成立的文明条件，即使不直接毁灭人类物种，也可能构成一种深层存在性风险。

这一扩展定义并不把所有 AI 引发的社会变化都纳入存在性风险。它通过文明基础条件、跨领域扩散、结构性损害和未来主体能力四个门槛保持概念边界。其核心意义在于：AI 相关人类存在性风险的分析起点，不能只停留在物种生存，而必须进一步纳入人类作为文明主体继续成立的条件。

9 | 结论：从物种生存到文明主体

本文从一个前置问题出发：当我们说 AI 可能对人类构成存在性风险时，处于风险之中的“人类”到底是什么？这个问题之所以重要，是因为风险承受主体的界定，决定了风险分析的范围。若人类只被理解为 *Homo sapiens* 这一生物物种，那么 AI 相关人类存在性风险将主要被理解为物种灭绝、永久失能、生物学未来封闭或决定性失控。这个理解抓住了最基础、最严肃的存在性风险形式，但它并不足以穷尽 AI 时代的人类风险对象。

本文并未否认物种层风险的重要性。相反，本文始终将人类物种视为文明的生物学基底。没有具身的人类生命，没有神经系统、感知能力、繁殖机制、死亡性和代际延续，人类文明无从持续展开。物种存续因此是人类未来的必要条件。本文所要补充的是：必要条件并不等于充分条件。人类可以在生物学意义上继续存在，却在文明意义上失去某些使其作为人类共同世界得以延续的基础能力。

为说明这一点，本文区分了三个嵌套层级。第一，人类物种是文明的生物学承载。第二，人类文明是人类物种在历史中形成的跨代际共同世界，包括语言、知识、制度、责任、公共理性、历史记忆和意义结构。第三，哲学内核是文明定义和修正自身基础范畴的反思性结构，包括真实、证据、责任、主体性、价值和意义等。通过这一结构，人类不只是作为生物种群存续，也作为能够认识、判断、负责、传承和创造意义的文明主体而存在。

本文进一步使用硬件—内核—发行版的功能性类比来澄清这一层级结构。人类物种类似硬件，哲学内核类似 Linux kernel，人类文明则类似 Ubuntu、Debian 或 Red Hat Enterprise Linux 这样

的发行版或完整运行环境。这个类比并不是为了将人类技术化，而是为了说明：硬件仍在，不等于系统运行良好；发行版仍能启动，不等于内核没有损坏；应用仍然繁荣，不等于底层接口稳定。类似地，人类物种仍然存续，不等于人类文明主体仍然完整；制度和技术系统仍然运行，不等于真实、责任、主体性、价值和意义这些基础范畴仍然健康。

在此基础上，本文提出一个扩展定义：AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的、可能不可逆地毁灭人类物种，永久剥夺人类未来，或不可逆地削弱人类作为文明主体继续成立之基础条件的风险。这个定义保留了物种层存在性风险的核心地位，同时将风险承受主体从单一生物物种扩展到文明主体。

这个扩展并不意味着所有 AI 引发的社会变化都构成存在性风险。一个风险若要进入文明主体层面的存在性风险范围，必须作用于文明基础条件，具有跨领域扩散能力，可能造成不可逆或难以逆转的结构性损害，并影响人类作为未来主体的能力。没有这些门槛，严重社会问题仍然可以是重要风险，但不必然是存在性风险。文明主体性风险之所以具有存在性意义，不是因为它听起来重大，而是因为它作用于人类继续作为认识主体、责任主体、行动主体和意义主体存在的基础能力。

这一概念重构对 AI 风险理论具有直接意义。它要求我们在讨论 AI 是否会毁灭人类之前，先澄清“人类”这一对象的层级结构；在讨论 AI 系统是否可靠、可控或合规之前，先追问这些系统是否正在改变人类认识、判断、负责和创造意义的条件。AI 风险不应只被理解为外部技术系统是否造成灾难，也应被理解为 AI 是否可能改变人类作为文明主体继续成立的条件。

在存在性风险语境中，概念澄清不是外在附属工作，而是风险识别的前提。如果人类无法命名自己正在失去的能力，就很难判断何种变化应被治理、保护或限制。AI 时代的一个困难正在于，许多深层损害可能不以灾难形式出现，而以效率、便利、自动化和正常运行的形式进入文明。澄清风险承受主体，正是为了使这些不易被直观看见的损害获得可讨论、可比较和可审查的本体位置。

因此，本文完成的不是一个完整风险分类，也不是一个治理方案，而是一个承受主体的概念重构。它将 AI 相关人类存在性风险的分析起点，从单一的物种生存，推进到人类作为文明主体继续成立的条件。只有在这个基础上，关于 AI 风险的具体类型、发生机制与治理含义，才有可能获得更清楚的本体坐标。

注释

[注 1] 关于 AI 系统参与 AI 自身研发、研究自动化与递归自我改进的讨论，可参见 Favaro and Clark (2026) 代表 Anthropic Institute 发布的相关材料，以及 Anthropic 关于 AI-driven R&D、AI-assisted AI development 与 recursive self-improvement 的讨论。本文引用这一背景，并不主张 AGI 已经实现，也不主张递归自我改进已经完成，而是用以说明：AI 正在进入其自身发展链条，从而使 AI 相关人类存在性风险问题具有新的结构背景。

[注 2] 关于 AI 与人类尊严、人格、责任、共同善和公共伦理的关系，可参见近年 AI ethics、AI governance、human dignity 与公共伦理领域的讨论，也可参见 UNESCO (2022) 关于人工智能伦理的国际性建议，以及 Pope Leo XIV 关于在人工智能时代维护人的位格与人类尊严的相关通谕。本文引用此类材料，不是为了将本文建立在某一宗教或神学前提上，而是为了说明：AI 已经进入人类自我理解、责任与尊严等公共伦理范畴。

[注 3] 关于存在性风险的经典讨论，可参见 Bostrom (2013) 关于 existential risk 的工作、Ord (2020) 关于 existential catastrophe 与人类长期未来的研究。关于 AI x-risk、superintelligence、control problem 与 alignment 的当代讨论，可参见 Bostrom (2014)、Russell (2019)、Center

for AI Safety (2023)、Carlsmith (2022)、Yudkowsky and Soares (2025) 以及 Ngo, Chan, and Mindermann (2022)。相关社群讨论还包括 Christiano (2019) 对渐进式失败图景的分析, 以及 Karnofsky (2021) 关于本世纪技术转折的讨论。本文接受这些讨论对物种灭绝、永久失能、未来封闭和失控风险的基础界定, 并在此基础上进一步追问: 这些风险所指向的“人类”是否只能被理解为生物物种。

[注 4] 本文所说的“文明作为跨代际共同世界”, 与 Arendt (1958) 关于 world、action 与 plurality 的讨论, Cassirer (1944) 关于 symbolic forms 与人类文化的研究, Taylor (2004) 关于 social imaginaries 的理论, 以及 MacIntyre (1981) 关于 tradition 与 practices 的分析存在可对话关系。本文并不将任何一种理论直接等同于“文明主体”概念, 而是借助这些传统说明: 人类文明并非人口、国家、文化或技术体系的简单总和, 而是一个使人类能够继承、判断、负责和更新自身的共同世界。

[注 5] 本文所说的“哲学内核”并不等同于现代学院制度中的哲学学科, 而是指文明定义、澄清和修正自身基础范畴的反思性机制。相关背景可与 conceptual engineering (Chalmers, 2025; Haslanger, 2005)、philosophy of technology (Verbeek, 2011; Vallor, 2016)、philosophical anthropology、social epistemology 以及 philosophy of information (Floridi, 2011) 等研究传统对话。不同文明传统也未必以“哲学”这一现代学科形式显化其基础范畴; 这些范畴也可能以宗教、礼法、宇宙论、伦理传统、公共法理或实践智慧的形式存在。

[注 6] “硬件—内核—发行版”只是功能性类比, 而非字面等同。Linux kernel、Ubuntu、Debian 和 Red Hat Enterprise Linux 的例子用于帮助读者理解硬件、内核、发行版与应用层之间的功能区分。本文并不主张人类文明可以被还原为计算机系统, 也不主张哲学像工程内核一样具有单一维护者。类比的作用只是说明: 物理承载、底层范畴接口与完整历史运行环境之间存在层级差异。

[注 7] 本文所说的“不可逆或难以逆转”, 在文明尺度上不必被理解为绝对无法恢复, 而是指恢复成本、代际损耗、制度路径依赖和能力训练断裂达到足以改变未来主体能力的程度。相关讨论可与 path dependence、institutional persistence、intergenerational transmission、skill formation 和 human capital depreciation 等研究方向对话; 其中, Pierson (2000) 关于制度路径依赖的讨论, 以及 Arthur (1989) 关于技术锁定和递增收益的分析, 为理解“难以逆转”的制度与技术机制提供了重要背景。本文使用这一概念, 是为了避免将文明主体性风险误解为只有在物理上绝对不可逆时才成立。

[注 8] 本文并不预设 AI 对文明主体条件只能产生削弱作用。AI 也可能增强知识整理、错误发现、责任追踪、公共反思和制度审计能力。本文关注的是另一种情形: 当 AI 中介长期替代而非增强人类的基础能力, 并使这些能力的训练、传承和恢复变得困难时, 风险才进入文明主体性风险范围。相关讨论可与 human agency、meaningful human control、human-AI collaboration、AI augmentation 和 responsibility gap 等研究对话; 例如 Matthias (2004) 关于 responsibility gap 的讨论、Santoni de Sio and van den Hoven (2018) 关于 meaningful human control 的分析、Gabriel (2020) 关于 AI alignment 与价值的论述, 以及 Ngo, Chan, and Mindermann (2022) 从深度学习角度对 alignment problem 的讨论。

参考文献

Arendt, H. (1958). *The human condition*. University of Chicago Press.

Arthur, W. B. (1989). Competing technologies, increasing returns, and lock-in by historical events. *The Economic Journal*, 99(394), 116–131. <https://doi.org/10.2307/2234208>

- Bostrom, N. (2013). Existential risk prevention as global priority. *Global Policy*, 4(1), 15–31. <https://doi.org/10.1111/1758-5899.12002>
- Bostrom, N. (2014). *Superintelligence: Paths, dangers, strategies*. Oxford University Press.
- Carlsmith, J. (2022). *Is power-seeking AI an existential risk?* arXiv. <https://doi.org/10.48550/arXiv.2206.13353>
- Cassirer, E. (1944). *An essay on man: An introduction to a philosophy of human culture*. Yale University Press.
- Center for AI Safety. (2023, May 30). *Statement on AI risk*. <https://www.safe.ai/statement-on-ai-risk>
- Chalmers, D. J. (2025). What is conceptual engineering and what should it be? *Inquiry*, 68(9), 2902–2919. <https://doi.org/10.1080/0020174X.2020.1817141>
- Christiano, P. (2019, March 17). *What failure looks like*. AI Alignment Forum. <https://www.alignmentforum.org/posts/HBxe6wdjxK239zajf/what-failure-looks-like>
- Favaro, M., & Clark, J. (2026). *When AI builds itself: Our progress toward recursive self-improvement, and its implications*. Anthropic Institute. <https://www.anthropic.com/institute/recursive-self-improvement>
- Floridi, L. (2011). *The philosophy of information*. Oxford University Press.
- Gabriel, I. (2020). Artificial intelligence, values, and alignment. *Minds and Machines*, 30(3), 411–437. <https://doi.org/10.1007/s11023-020-09539-2>
- Haslanger, S. (2005). What are we talking about? The semantics and politics of social kinds. *Hypatia*, 20(4), 10–26. <https://doi.org/10.1111/j.1527-2001.2005.tb00533.x>
- Karnofsky, H. (2021). *The “most important century” series*. Cold Takes. <https://www.cold-takes.com/most-important-century/>
- Leo XIV. (2026, May 15). *Magnifica humanitas: On safeguarding the human person in the time of artificial intelligence* [Encyclical letter]. The Holy See. <https://www.vatican.va/content/leo-xiv/en/encyclicals/documents/20260515-magnifica-humanitas.html>
- MacIntyre, A. (1981). *After virtue: A study in moral theory*. University of Notre Dame Press.
- Matthias, A. (2004). The responsibility gap: Ascribing responsibility for the actions of learning automata. *Ethics and Information Technology*, 6(3), 175–183. <https://doi.org/10.1007/s10676-004-3422-1>
- Ngo, R., Chan, L., & Mindermann, S. (2022). *The alignment problem from a deep learning perspective*. arXiv. <https://doi.org/10.48550/arXiv.2209.00626>
- Ord, T. (2020). *The precipice: Existential risk and the future of humanity*. Hachette Books.
- Pierson, P. (2000). Increasing returns, path dependence, and the study of politics. *American Political Science Review*, 94(2), 251–267. <https://doi.org/10.2307/2586011>

Russell, S. (2019). *Human compatible: Artificial intelligence and the problem of control*. Viking.

Santoni de Sio, F., & van den Hoven, J. (2018). Meaningful human control over autonomous systems: A philosophical account. *Frontiers in Robotics and AI*, 5, Article 15. <https://doi.org/10.3389/frobt.2018.00015>

Taylor, C. (2004). *Modern social imaginaries*. Duke University Press.

UNESCO. (2022). *Recommendation on the ethics of artificial intelligence*. UNESCO. <https://unesdoc.unesco.org/ark:/48223/pf0000381137>

Vallor, S. (2016). *Technology and the virtues: A philosophical guide to a future worth wanting*. Oxford University Press.

Verbeek, P.-P. (2011). *Moralizing technology: Understanding and designing the morality of things*. University of Chicago Press.

Yudkowsky, E., & Soares, N. (2025). *If anyone builds it, everyone dies: Why superhuman AI would kill us all*. Little, Brown and Company. <https://www.hachettebookgroup.com/titles/eliezer-yudkowsky/if-anyone-builds-it-everyone-dies/9780316595643/>

附录 A：核心概念与术语说明

本附录定义本文使用的核心概念。其目的不是引入新的论证，而是稳定本文概念框架所需的术语。

AI 相关人类存在性风险

AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的风险，这些风险可能不可逆地毁灭人类物种，永久剥夺人类未来，或不可逆地削弱人类继续作为文明主体存在的基础条件。

人类存在性风险

人类存在性风险，是指关涉人类能否继续存在、保有其未来，并继续成为其未来之主体的更广义风险类别。在本文中，它包括但不限于物种灭绝。

风险承受主体

风险承受主体，是指暴露于存在性损害之中的主体或对象。本文主张，AI 相关人类存在性风险的风险承受主体不应只被理解为作为生物物种的 *Homo sapiens*，也应被理解为作为文明主体的人类。

人类物种

人类物种，是指作为生物种群的 *Homo sapiens*。它包括人类身体、神经系统、生殖能力、生理脆弱性、死亡性，以及对生态和物质环境的依赖。

人类文明

人类文明，是人类物种在历史中形成的跨代际共同世界。它包括语言、知识、制度、法律、科学、教育、经济、文化、技术、责任结构、历史记忆和意义结构。

文明主体

文明主体，是指不只作为生物种群被理解，而是作为知识、制度、责任、能动性、价值和意义之跨代际承载者被理解的人类。它是能够跨代际地认识、判断、负责、传承并创造意义的主体。

文明主体性

文明主体性，是指人类能够继续作为文明主体存在和行动的条件。它依赖真实、责任、能动性、价值、意义、制度和共同世界结构的稳定与传承。

文明主体性风险

文明主体性风险，是指那些可能以不可逆或难以逆转的方式削弱人类继续作为文明主体之条件的风险。它不包括所有社会变化，而只包括跨越严格门槛的结构性损害。

跨代际共同世界

跨代际共同世界，是指个体出生并进入其中的共享世界；语言、记忆、知识、制度、责任和意义通过这个世界在代际之间被传递、批判和更新。

哲学内核

哲学内核，是指文明定义、批判和修正其基础范畴的反思性结构。它不等同于作为制度的学院哲学，也不等同于某种固定教义。它是文明自我理解和自我修正的功能层。

基础范畴

基础范畴，是文明系统预设的基本范畴。本文最重要的基础范畴包括真实、证据、责任、能动性、价值和意义。

物种层

物种层，是人类存在的生物学层面。它关涉 *Homo sapiens* 的生存、繁殖、具身性、脆弱性和物质连续性。

文明层

文明层，是跨代际共同世界的层面。它关涉知识、制度、法律、教育、文化、责任和意义的运行。

内核层

内核层，是基础范畴的层面。它关涉文明是否仍能定义、批判和修正真实、责任、能动性、价值和意义等范畴。

硬件—内核—发行版类比

硬件—内核—发行版类比，是本文用来澄清人类物种、哲学内核和人类文明之间关系的功能性类比。人类物种类似硬件；哲学内核类似内核；人类文明类似发行版或完整操作环境。该类比不是字面等同，也没有还原论意图。

应用层

应用层，是指科学、法律、政治、经济、教育、艺术、宗教、媒体和技术等文明功能系统。这些系统执行具体功能，但依赖基础范畴。

文明连续性

文明连续性，是共同世界在代际之间持续传递、理解和更新的过程。它不等同于生物人口连续性。

文明不可逆性

文明不可逆性，并不必然意味着绝对无法恢复。它指的是某些情形中，恢复成本、代际损失、制度路径依赖和能力传递断裂已经深到足以改变人类未来主体性的能力。

路径依赖

路径依赖，是指历史选择、制度、基础设施和习惯会使某些未来路径越来越难以逆转的现象。它有助于解释为什么某些文明损害即使不是物理上不可逆，也可能变得难以撤回。

AI 增强

AI 增强，是指 AI 强化而非替代人类能力的情形，例如知识组织、错误发现、责任追踪、公共反思和制度审计。

有意义的人类控制

有意义的人类控制，是指人类仍然以有意义的方式参与自主系统或 AI 中介系统的控制、授权和问责的条件。它与能动性、责任和治理相关。

责任缺口

责任缺口，是指在没有任何人类行动者完全控制或理解过程的情况下，自动化系统或学习系统所产生的行动或结果难以被归责的情形。