



AI 相关人类存在性风险的承受主体

从物种生存到人类文明条件下的主体性实现

坤元 (KunYuan)

TrantorLabs 创始人与首席研究员

TrantorLabs, Singapore

kunyuan@trantorlabs.sg

ORCID: [0009-0008-7983-875X](https://orcid.org/0009-0008-7983-875X)

TrantorLabs: www.trantorlabs.sg

KunYuan Newsletter: kunyuan.substack.com

V3 公开预印本版本

2026 年 6 月

本版本用于公开传播，未来正式发表版本可能有所不同。

AI 相关人类存在性风险的承受主体：从物种生存到人类文明条件下的主体性实现

摘要

AI 安全、风险与治理正成为全球议程，但治理行动的密集化并不自动带来风险对象的澄清。当不同领域说要保护“人类”时，它们隐含地指向偏好、生命、社会秩序或物种延续——这些概念并不兼容，风险识别在维度间持续滑动。本文是一项关于 AI 相关人类存在性风险之**风险承受主体**的概念工程，同时具有**社会认识论**、技术哲学与 AI 风险治理意义。

本文保留既有框架将“人类”理解为 *Homo sapiens* 之底线，但提出范式扩展：风险承受主体始终是人类这一**具身物种**；本文扩展的不是承受主体，而是同一主体可能受到存在性损害的方式。本文区分两个基本受损层面——**生物存续层面**与**文明条件层面**，并在后者内部标出**哲学内核**，即真实、证据、责任、主体性、价值与意义等基础范畴的**范畴校准机制**。AI 可能通过**替代性剥夺**或**中介性重构**，削弱人类在文明功能系统中的**实质参与**，或使基础范畴失去稳定校准。文明条件层面的主体性实现风险，只有在作用于文明基础条件、具有跨领域、跨文明接口的扩散能力、可能造成不可逆或难以逆转的结构性损害，并使这些损害汇聚为对人类**作为未来主体**之能力的整体性、跨代际损害时，才进入存在性风险范围。

本文提供的不是完整风险分类或治理方案，而是 AI 风险识别所需要的**本体论坐标系**。其关键不是把文明、制度或哲学内核增补为新的风险承受主体，而是说明同一人类主体可能通过文明条件的损坏而遭受存在性损害。

关键词：人工智能；人类存在性风险；风险承受主体；概念工程；主体性实现；范畴校准

1 | 引言：AI 重新打开了人类存在性风险问题

1.1 问题的提出：治理密集化与本体论坐标的空缺

人工智能正在重新打开人类存在性风险问题。本文讨论的风险以 **AGI 时代**〔注 1〕为背景——这里所说的 AGI 时代，是指 AI 系统正在变得更通用、更自主、更具行动能力并更深嵌入制度的历史转变，而非预设某个公认的 AGI 阈值已被跨越。许多本文所讨论的风险机制，已经可能以高级 AI、生成式 AI 与行动型 AI 的形式在当前阶段显现。

模型评估、安全承诺、风险分级、合规框架与国际协调机制不断增加；AI 安全已从少数技术共同体议题，迅速进入政府、国际组织、前沿实验室与企业的共同议程。这些努力说明，人类已意识到 AI 可能重塑知识、制度、经济与安全的基础结构〔注 2〕。然而，治理行动的密集化并不自动带来风险对象的澄清。

不同机构从各自位置理解“需要保护的人类”：企业关注用户安全与产品责任；政府关注国家安全与公共秩序；科研机构关注模型能力与系统可靠性；伦理讨论关注偏见、公平、权利与透明度。这些回应位于应用层、制度层或治理层，它们预设了某种需要被保护的“人类利益”，却未必共享一个关于**人类作为风险承受主体**的本体论坐标。

当 AI 安全、风险分析与治理都说要保护“人类”时，它们并不总是先说明：这里的“人类”究竟是生物物种、偏好集合、用户总体、公民秩序，还是在文明条件中实现主体性的具身物种。如果这一承受主体没有被澄清，治理越是展开，越可能在模型、产品与政策层面不断修补，却仍然缺少判断何种损害触及人类存在根基的概念基础。

1.2 “人类”概念在风险讨论中的滑动

当前关于 AI 风险的讨论隐含了不同的“人类”概念。对齐研究通常默认保护人类偏好；生物安全研究默认保护人类生命；治理研究默认保护社会秩序；哲学讨论默认保护人类价值与尊严；而存在性风险的经典框架，虽然并不只限于物种灭绝，也包含永久失能和未来剥夺等形式，但其风险识别通常仍以人类作为生物物种及其长期未来为基本参照〔注 3〕。在我们看来，这些不同的“人类”概念并不兼容。当它们在同一政策文件或技术路线图中混用时，风险识别就会在维度间持续滑动：某一时刻讨论认识论问题（模型是否输出真实），下一时刻转向生物安全（模型是否被恶意使用），再下一时刻变成经济适应（就业是否被替代）。

若风险承受主体尚未澄清，不同研究将永远缺乏可共享的本体论坐标。

1.3 本文的核心主张与方法论定位

本文的核心主张是：**AI 相关人类存在性风险的风险承受主体始终是人类这一具身物种；本文并不将承受主体扩展为文明、制度、哲学内核或 AI 系统。**本文扩展的是同一主体可能受到存在性损害的方式：从单一生物存续层面上的毁灭、永久失能或未来剥夺，扩展到人类在文明条件中实现其主体性之基础条件的不可逆或难以逆转的削弱。

因此，本文并不否认既有存在性风险框架已经包含“未来剥夺”维度；本文的推进在于指出，AI 时代的未来剥夺不能只被理解为生物灭绝之后的附属结果，也可能表现为人类虽仍存续，却逐渐失去作为未来主体理解、判断、负责和塑造共同世界的文明条件。

为此，本文建立一项**概念工程**〔注 4〕，区分人类这一风险承受主体的两个基本受损层面：生物存续层面与文明条件层面。前者关注人类作为具身物种的存续；后者关注人类在跨代际共同世界中实现认识、判断、责任、制度参与、意义创造和面向未来行动的能力。在文明条件层面内部，本文进一步标出**哲学内核**，即真实、证据、责任、主体性、价值和意义等基础范畴的**范畴校准机制**。哲学内核不是独立实体，而是文明条件内部维持基础范畴可运行性的机制。

本文提供的不是完整风险分类，也不是技术控制方案或政策清单，而是 AI 安全、风险分析与治理在风险识别层面所需要的**本体论坐标系**：在讨论具体风险类型、治理路径或技术方案之前，必须先澄清“人类”这一风险承受主体及其可能受损方式。

1.4 论证安排

第二节给出人类这一具身物种的双维度工作定义。第三节界定人类文明作为主体性实现的跨代际条件，并区分**形式参与**与**实质参与**。第四节论证哲学内核作为范畴校准机制，并建立基础范畴、文明基础条件与主体性能力之间的映射关系。第五节以有限功能类比辅助说明四个层级之间的关系，并在非类比层面重新收束其本体关系。第六节说明 AI 为什么使这些条件成为存在性风险问题，提出两类作用机制、扩展定义与四个门槛。第七节以案例试刀与文献交锋回应反对意见。第八节总结全文。

2 | 人类这一具身物种：双维度工作定义

若“人类”只被理解为 *Homo sapiens* 这一生物物种，那么存在性风险将主要指向物种灭绝、永久失能和未来剥夺。这个理解抓住了最基础的风险形式，但并不足以穷尽 AI 时代的人类风险对象。

2.1 人类的双维度工作定义

在本文中，“人类”首先指 *Homo sapiens* 这一具身生物种群。人类具有身体结构、神经系统、感知能力、生殖机制、生理脆弱性、死亡性，以及对生态和物质环境的依赖。这个生物存续层面构成人类存在的物理前提。

然而，人类并不只以生物存续层面存在。人类这一具身物种还在文明条件中实现其主体性：通过语言、知识、教育、制度、责任结构、公共理性、历史记忆和意义叙事，获得并维持认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的能力。

因此，本文关于“人类”的工作定义具有两个层面。第一，人类是具身生物物种；第二，人类是在文明条件中实现主体性的具身物种。前者说明人类存在的生物承载，后者说明人类为什么不只是生物种群，而是能够认识、判断、负责、传承、创造意义并面向未来行动的历史性存在。

风险承受主体始终是人类这一具身物种；文明、制度、文化、技术体系和哲学内核都不是与人类并列的风险承受主体。本文扩展的不是承受主体本身，而是同一主体可能受到存在性损害的方式。

2.2 物种灭绝作为底线风险

人类物种灭绝是人类存在性风险最直接、最严格的形式。若 *Homo sapiens* 在生物学意义上不复存在，或者人类永久失去繁衍、行动和塑造未来的能力，那么所有关于人类文明和人类未来的可能性都会随之关闭。没有具身的人类生命，就没有人类文明的持续展开，也没有主体性实现的承载者。

物种存续是任何扩展定义都必须保留的底线。它是必要条件，但不是充分条件。人类可以在生物学意义上继续存在，却在文明意义上逐渐失去使其作为认识者、判断者、责任者、制度参与者和意义创造者而继续存在的基础能力。换言之，物种存续回答的是“是否还有人类”，文明条件回答的是“人类是否仍能作为自身未来的主体而存在”。

2.3 具身性：人类不是纯信息结构

强调人类作为具身物种，意味着不能将人类还原为纯粹信息结构、抽象理性主体或可任意迁移的计算模式。人类的认知、情感、判断、学习、关系、责任和意义，都与身体条件密切相关。感知世界依赖身体，语言学习依赖具身经验和社会互动，责任承担依赖行动能力和对后果的承受能力，意义形成也与出生、死亡、时间、痛苦、依赖、关系和有限性有关。

在 AI 语境下，这一点尤其需要被保留。随着 AI 系统越来越多地承担认知任务、生成文本、组织知识、提出方案和参与决策，人类很容易被理解为一种可以被更高效信息处理系统替代的认知实体。然而，人类的存在并不只是信息处理。一个会死亡、会受伤、会承诺、会后悔、会在时间中成长并承担后果的存在，与一个无身体、无死亡、无脆弱性的信息系统，并不处于同一存在结构中。

2.4 物种连续性不等于文明条件连续性

人类物种的连续性，主要通过生物繁殖、代际延续和种群稳定来维持。只要人类仍然能够繁衍、存活并保持基本生物结构，物种层意义上的延续就仍然存在。文明条件的连续性则不同。它依赖语言、记忆、教育、制度、知识、规范、技术、责任结构和意义叙事的传递。它不仅要求下一代人出生，也要求下一代人进入一个可理解、可继承、可批判和可更新的世界。

因此，物种连续性与文明条件连续性之间并不存在自动等价关系。一个社会可以在生物学意义上延续，却发生文明条件的严重断裂。人们仍然出生、劳动、消费和娱乐，但他们所进入的世界可能已经无法稳定维持知识、责任、判断和意义传承。若这种退化不可逆或难以逆转，它就不只是普通社会变化，而可能成为人类主体性实现条件的结构性损害。

3 | 人类文明：主体性实现的跨代际条件

3.1 文明与人类文明：范围限定

本文所说的“文明”均指“人类文明”。所谓人类文明，是指人类这一具身物种在历史中通过语言、知识、制度、法律、教育、责任结构、技术实践和意义叙事形成的**跨代际共同世界**。它由可传递、可修正、可继承的符号—制度—技术结构构成，使个体能够进入大于其生物生命的历史—理解空间。

人类文明不是人类之外的独立承受主体，而是人类主体性实现的**构成性条件**。它不是人口、国家、文化或技术体系的简单总和。

3.2 四个否定

人类文明不是人口总和。大量人类个体的同时存在，并不自动构成文明。人口提供文明的生物承载，但人口本身并不自动产生可传递的知识、制度、责任和意义结构。

人类文明不是国家。国家是政治和法律组织形式，通常具有领土、主权与强制权力。人类文明则是更深、更宽、更长时段的跨代际共同世界。一个文明传统可以跨越多个国家，一个国家也可以承载多个文明传统。

人类文明不是文化的同义词。文化是文明的重要组成部分，表现为语言、习俗、艺术、仪式和生活方式。但文明不仅包括文化，还包括科学、法律、制度、教育、经济、公共理性、基础设施和责任结构。

人类文明不是技术体系。技术是文明的重要组成部分，但文明并不只是工具集合，也不是效率系统。文明还包含价值、规范、责任、公共理性、意义和人类对未来的理解。能力增长并不自动等于文明条件健康。

3.3 多重文明传统与全球文明生态

人类文明应被理解为由多重文明传统、共享制度接口、知识交换、技术基础设施、冲突经验和跨代际传承结构共同构成的总体性文明生态。不同文明传统可以在真实、责任、价值、主体性和意义等问题上给出不同回答，但它们共同构成人类这一具身物种在历史中形成并继承的跨代际共同世界。

现代全球文明生态已经使不同文明传统之间形成前所未有的相互嵌入。现代科学体系、大学制度、国际法、全球贸易、金融网络、互联网协议、数字平台和 AI 基础设施，都不再完全属于某一个文明传统、国家或文化内部。它们构成了跨文明运行的共同接口。因而，本文所说的文明条件风险，并不以某一国家、某一文化或某一制度内部的局部失序为充分条件，而是指可能作用于这些跨文明共同接口的结构性损害。

3.4 文明功能系统与人类参与结构

人类文明通过一组**文明功能系统**具体运行。经济、法律、教育、科学、国家治理、文化、媒体、医疗、行政、宗教和艺术等系统，构成人类实际进入文明条件的主要路径。普通人通常不是直接面对“文明”这一抽象对象，而是通过学校、法院、实验室、市场、媒体、政府机构、平台系统、家庭、公共服务和文化实践进入共同世界。

这些文明功能系统不是文明的外在附属物，而是人类主体性实现的重要承载结构。人类通过教育系统学习如何理解、提问、判断和继承知识；通过科学系统参与知识生产和证据检验；通过法律系统理解权利、义务与责任归因；通过治理系统参与公共决策和制度方向；通过文化与媒体系统表达意义、传承记忆和形成公共想象。

人类主体性并不只在个体内部发生。它也通过这些系统中的**参与结构**被实现。所谓参与结构，是指人类在这些系统中作为学习者、劳动者、判断者、创造者、公民、责任承担者和未来主体参与共同世界运行、维护和更新的方式。

3.5 形式参与与实质参与

为了更精确地分析参与结构，本文区分**形式参与与实质参与**〔注 5〕。

形式参与是指人类在文明功能系统中保留可见位置、程序动作和名义角色的参与方式：点击确认、签署文件、批准建议、选择选项、投票、消费、反馈。形式参与维持着人类在制度中的可识别性，却不保证人类真正理解、判断或塑造过程。

实质参与是指人类作为认识者、判断者、责任承担者、制度维护者、意义创造者和未来主体，对共同世界的运行、方向和更新产生实质性影响。它要求人类能够理解过程、形成判断、承担责任、创造意义，并对制度方向和公共未来产生实质影响。

若人类在文明功能系统中只保留形式性确认，而不再真正理解、判断、负责、创造或塑造方向，那么人类在文明条件中的主体性实现就会受到削弱。

3.6 跨代际共同世界与人类作为未来主体

人类文明是**跨代际共同世界**〔注 6〕。它通过语言、记忆、制度和教育，使过去能够传递给未来，使个体生命能够进入一个大于自身的历史结构。个体生命是有限的。一个人出生时并不从零开始。他进入已经存在的语言，接受已有制度和知识，继承他未曾亲自创造的历史记忆、科学成果、法律结构、伦理规范和意义叙事。

这种跨代际性使文明条件具有与物种连续性不同的脆弱性。物种延续主要依赖生物繁殖；文明条件延续则依赖传承、理解和更新。若下一代人只是生物学地出生，却没有进入能够培养判断、责任、真实和意义的共同世界，那么人类主体性实现条件就会被削弱。

文明条件的真正延续并不只是“有人活着”，而是“有人能够理解、继承、批判和更新一个共同世界”。

至此，需要立定一个关键术语：**人类作为未来主体**。这不是引入新的风险承受主体，而是指主体性实现的时间性与能动性面向：人类不仅当下认识、判断和负责，也能够跨代际过程中理解风险、修正制度、组织行动并塑造未来。

3.7 认识、责任与意义结构

人类文明作为跨代际共同世界，至少包含三种功能性结构：**认识结构、责任结构和意义结构**。

认识结构使人类能够区分事实与传闻、证据与叙述、解释与伪造、知识与意见。责任结构使人类能够识别行动者、追踪后果、分配义务、处理过失并维持信任。意义结构使人类能够理解为什么学习、为什么工作、为什么创造、为什么承担责任、为什么保护未来。

认识结构、责任结构和意义结构共同说明，人类文明不是人口、国家、文化或技术体系的简单加总。它是使人类能够认识、判断、负责、传承和创造意义的共同世界。若这些结构被系统性削弱，人类主体性实现条件就会受到损害。

这些结构之所以能够稳定运行，还依赖更底层的基础范畴及其校准机制。下一节将追问：文明功能系统运行时必须调用哪些基础范畴？这些范畴如何被澄清、维护和调整？

4 | 哲学内核：文明条件内部的范畴校准机制

4.1 哲学内核的定义与范围

本文所说的哲学内核，不是基础范畴本身的集合，而是文明条件内部维持基础范畴可运行性的**范畴校准机制**。它具有元机制属性：这里所谓“元”，并不是指它构成文明条件之外的更高实体，也不是指它成为新的风险承受主体，而是指它所校准的不是某一个文明功能系统内部的局部规则，而是科学、法律、教育、政治、经济、文化等功能系统共同调用的**基础范畴接口**。

这里的“哲学”并不首先指学院制度中的哲学学科，也不只是由专业哲学家写成的理论文本。哲学内核指基础范畴在历史中被显化、检验、澄清、批判、维护和调整的操作机制；真实、证据、责任、主体性、价值和意义等基础范畴，是其校准对象和概念接口。

哲学内核不是文明中的独立实体，也不是与科学、法律、政治、教育、经济、文化和艺术并列的普通部门。风险承受主体始终是人类这一具身物种；文明条件是文明主体性实现的跨代际共同世界；哲学内核则是文明条件内部维持基础范畴可运行性的范畴校准机制。

4.2 基础范畴与现代全球文明生态

基础范畴不是先验适用于一切可能文明的永恒框架，也不是某一文明传统独占的理论词汇。不同文明传统可以用不同语言、宗教、礼法、制度、政治想象和知识传统来组织真实、责任、主体性、价值和意义等问题。但只要一个文明能够区分真伪、积累知识、分配责任、组织行动、评判价值并解释意义，它就已经在调用某种基础范畴配置。

现代全球文明生态使这些范畴具有新的共同性。科学知识、法律责任、技术治理、公共决策、教育传承、数字平台、国际制度和跨国市场已经深度交织。一个国家或文明传统内部的知识制度，往往

依赖全球科研网络、技术标准、数字基础设施和国际制度接口；一个地区的 AI 系统部署，也可能通过平台、供应链、数据生态和公共话语结构影响其他地区。

对真实、证据与知识结构之可校准性的关注，并非仅属传统认识论，而是**社会认识论**（social epistemology）〔注 7〕的核心关切：知识不是个体心灵的私产，而是跨主体、跨制度、跨代际的公共成就。正是在这一语境下，真实、证据、责任、主体性、价值和意义成为 AI 风险分析中不可避免的基础范畴。

这并不意味着不同文明传统对这些范畴有完全一致的理解。真实可以通过不同知识传统被组织，责任可以通过不同法律和伦理体系被分配，主体性可以通过不同人格、家庭、社群和政治观念被理解，价值和意义也可以通过不同宗教、哲学、文化和历史经验被解释。本文的论点并不是要抹平这种多样性，而是指出：无论这些范畴的具体回答如何不同，现代全球文明生态中的知识、制度、技术和治理系统都必须以某种方式调用这些接口。

因此，基础范畴既不是纯粹先验的，也不是任意相对的。它们具有**功能必要性**：若没有真实和证据，知识无法稳定积累；若没有责任，行动无法被归因；若没有主体性，判断、同意、授权和责任承担失去基础；若没有价值，技术优化失去目标；若没有意义，学习、创造、责任和未来承诺失去理由结构。

4.3 六组基础范畴的功能位置

本文重点讨论六组基础范畴：真实、证据、责任、主体性、价值和意义。它们不是人类文明的全部基础概念，也不声称穷尽所有可能的文明核心范畴。本文选择它们，是因为它们构成 AI 风险识别自身的最低条件：没有真实与证据，风险无法被认识；没有责任与主体性，行动无法被归因；没有价值与意义，风险治理无法说明其保护目标与未来理由。

真实范畴使文明能够区分真实与虚假、事实与叙述、知识与意见、解释与伪造。没有真实范畴，知识生产会变成内容生产，公共讨论会失去共同指向。

证据范畴回答什么可以支持某个判断，什么可以反驳某个判断，什么可以进入公共理由交换。没有证据范畴，科学、法律、教育、媒体和公共治理都难以稳定区分可靠与不可靠。

责任范畴将行动、主体、授权、意图、过失、后果和义务连接起来。没有责任范畴，社会仍可能产生结果和后果，但越来越难以追问谁行动、谁授权、谁知情、谁能够阻止、谁应当承担后果。

主体性范畴回答谁能够判断、同意、拒绝、授权、行动、担责和代表自身。没有主体性范畴，法律、政治、教育、伦理和制度参与都会失去基础。

价值范畴使文明能够在安全、自由、效率、真实、尊严、正义、创新、稳定、繁荣和意义之间进行排序。没有价值范畴，技术系统可以持续优化，但文明将难以说明优化究竟服务于什么。

意义范畴回答为什么学习、为什么创造、为什么承担责任、为什么保护未来、为什么人类仍然重要。没有意义范畴，社会可以继续生产、消费、娱乐和优化，但人类行动、责任和未来承诺将越来越难以获得共同解释。

这六组基础范畴共同构成文明功能系统运行时必须调用的底层接口。它们并不是彼此孤立的词语，而是相互支撑的**范畴网络**。真实需要证据来校准，责任需要主体性来承载，价值需要意义来解释，意义也需要真实、责任和价值来避免滑向任意叙事。若多组基础范畴同时失准，它们之间的相互支撑关系就可能发生联动性的**整体漂移**。哲学内核的功能，正是维持这些范畴之间的可区分性、可连接性和可修正性。

4.4 范畴校准机制如何工作

所谓范畴校准机制，是指基础范畴在历史中被显化、检验、批判、维护和调整的过程。它并不意味着有一个单一中心能够统一管理所有范畴，也不意味着某一学科可以垄断范畴解释权。它指的是：在文明条件中，基础范畴能够通过哲学、科学、法律、公共讨论、教育、制度改革、文化实践和历史经验不断被澄清和修正，从而避免功能系统长期运行在失准的范畴之上。

范畴校准不同于局部纠错。局部纠错可以处理某个模型错误、某个法律漏洞、某个政策失败或某个教育问题。范畴校准处理的是更基础的问题：什么算作错误，什么算作证据，谁能够承担责任，什么构成判断，什么值得优化，什么仍然有意义。若这些问题无法被提出和处理，文明功能系统可能仍然继续运行，但其运行将越来越依赖惯性、效率和自动化，而不是理解、判断和责任。

因此，哲学内核不是抽象观念的储藏室，而是文明条件内部维持基础范畴可运行性的**动态机制**。它既存在于理论反思中，也存在于法律程序、科学规范、教育训练、公共争论、制度改革和文化实践中。它的作用不是让文明停留在某个固定答案上，而是使文明在面对新技术、新制度和新风险时，仍然能够重新澄清自己所调用的基本概念。

若基础范畴的校准机制失效，文明功能系统即使继续运行，也可能逐渐失去其可解释、可追责和可修正的基础。

4.5 基础范畴、文明基础条件与主体性能力的映射关系

为了避免概念漂移，必须区分三套相关但不相同的清单：**基础范畴**、**文明基础条件**和**主体性能力**。

第一，**基础范畴**是文明功能系统运行时必须调用的概念接口。本文重点讨论真实、证据、责任、主体性、价值和意义。

第二，**文明基础条件**是这些基础范畴在文明功能系统中维持可运行性的条件。本文重点关注五类：1. 真实与证据的**可校准性**；2. 责任与授权的可**归因性**；3. 主体性与判断的可**维持性**；4. 价值排序的可**反思性**；5. 意义传承的可**理解性**与**可延续性**。

六组基础范畴在文明基础条件层面可归纳为五类运行条件：真实与证据共同构成认识论基础的**可校准性**；责任与授权、主体性与判断分别构成实践理性的可归因性与可维持性——后两者中的“授权”与“判断”并非新增基础范畴，而是责任范畴与主体性范畴在制度实践中的关键接口。

第三，**主体性能力**是人类在文明条件中实际行使的能力。本文重点关注六类：1. 认识真实；2. 形成判断；3. 承担责任；4. 参与并维持制度；5. 传承并创造意义；6. 面向未来行动。

这三套清单并不是彼此独立的并列列表。更准确地说，**基础范畴为文明基础条件提供概念接口；文明基础条件又支撑人类主体性能力的实际行使**。若真实与证据无法被校准，人类就难以认识真实和形成判断；若责任与授权无法被归因，人类就难以承担责任和维持制度；若主体性与判断无法被维持，人类就难以作为行动者和未来主体参与共同世界；若价值排序无法被反思，技术和制度优化就可能脱离人类目的；若意义传承无法被理解和延续，人类就会失去学习、创造、负责和保护未来的理由结构。

这个映射关系也说明，本文并不是简单列举抽象概念，而是在说明人类主体性实现的条件结构。

4.6 “主体性范畴”与“主体性实现”的消歧

本文多次使用“主体性”一词，因此必须明确它在两个层次上的不同含义。

作为**基础范畴的主体性**，指关于谁能够判断、同意、授权、行动、负责和代表自身的概念结构。它属于范畴校准机制的一部分。法律系统、政治系统、教育系统、伦理关系和公共治理都必须依赖某种主体性范畴，才能决定谁可以签署、谁可以负责、谁可以被授权、谁可以同意或拒绝、谁具有行动能力和责任能力。

作为**人类主体性实现中的主体性**，则指人类实际行使认识、判断、责任、制度参与、意义创造和将来塑造等能力。它不是一个抽象概念，而是人类在文明条件中展开自身存在方式的实际能力。

这两个层次不能混淆。作为基础范畴的主体性，是人类主体性实现的范畴条件；作为实际能力的主体性实现，则是这些范畴条件在人类文明中的实际展开。前者不是后者的重复说法，而是后者得以被理解、制度化和维护的概念前提。

这一消歧对于 AI 风险分析非常重要。AI 既可能削弱人类主体性实现的实际能力，也可能使主体性范畴本身变得模糊。前者属于主体性能力的削弱，后者属于主体性范畴的失准。二者相互关联，但不能混为一谈。

5 | 硬件—内核—发行版—应用层：理解结构关系的功能性类比

前文已经分别说明人类物种、人类文明、哲学内核和文明功能系统的地位。为了更清楚地把这些关系放在同一结构中，本文引入一个有限的功能性类比〔注 8〕：**人类物种可以类比为硬件，哲学内核可以类比为内核，人类文明可以类比为发行版，文明功能系统可以类比为应用层。**

这个类比的基本意思是：人类物种提供生物承载；哲学内核维持基础范畴接口；人类文明构成完整的跨代际运行环境；文明功能系统则是人类实际进入共同世界的主要界面。本文使用这一类比，不是为了把人类理解为机器，也不是为了把哲学理解为代码，更不是为了把文明理解为软件。它只是一个有限的功能性类比，用来说明四个层级之间的承载、接口、运行环境 and 应用界面的关系。

5.1 类比的有限用途与边界

这一类比服务于四个目的。

第一，它说明人类文明需要具身生物承载。就像计算系统不能脱离物理硬件而运行，人类文明也不能脱离身体、大脑、神经系统、感知能力、生殖机制、死亡性和生态依赖而持续展开。没有具身的人类生命，语言学习、教育传承、情感关系、责任承担和意义形成都失去承载者。

第二，它说明文明功能系统需要基础范畴接口。就像应用程序不能直接脱离底层系统接口而运行，科学、法律、教育、政治、经济、文化、媒体和行政等系统也不能脱离真实、证据、责任、主体性、价值和意义等基础范畴而稳定运行。它们之所以能够判断、归因、解释、授权、评价和传承，依赖这些基础范畴仍然可解释、可追责和可修正。

第三，它说明人类实际生活在完整的文明运行环境中，而不是直接生活在抽象范畴中。普通人进入共同世界，通常不是通过直接面对“真实”“责任”“意义”等概念本身，而是通过家庭、学校、法院、市场、媒体、科学共同体、工作组织、技术平台和公共制度进入文明条件。

第四，它说明文明功能系统是人类主体性实现的实际界面。人类通过教育学习理解和判断，通过科学参与知识生产，通过法律理解权利与责任，通过治理参与公共方向，通过文化、宗教和艺术表达意义，通过经济和劳动参与共同世界的维持与更新。

这个类比有助于避免两个误读。第一个误读，是以为人类物种存续就等于人类主体性实现条件完整。第二个误读，是以为文明功能系统仍然运行，就说明底层范畴仍然健康。事实上，一个系统可以在外观上持续运行，甚至运行得更快、更高效、更自动化，但其底层接口已经变得不可解释、不可追责或不可校准。

因此，本章所有类比都必须服从一个限定：它们只解释功能关系，不决定本体关系。

5.2 四层关系的功能性说明

第一，人类物种作为硬件。在人类存在的结构关系中，人类物种提供最基础的生物承载。若以计算系统作类比，它类似于硬件。没有具身的人类生命，就没有人类文明、主体性实现和未来承诺。物种存续由此构成存在性风险分析的底线：若人类物种灭绝，或永久失去延续和行动能力，那么文明条件、范畴校准机制和功能系统都将失去承载者。

但硬件不等于完整运行环境。人类作为生物物种存在，并不自动产生科学、法律、教育、制度、责任结构、历史记忆和意义叙事。物种存续是必要条件，但不是充分条件。

第二，哲学内核作为内核。哲学内核可以被有限地类比为内核。这里的“内核”不是指某套固定哲学理论支配文明，也不是指学院哲学在制度上高于科学、法律、政治、教育、经济或文化。它指的是文明条件内部维持基础范畴可运行性的校准机制。

科学需要真实和证据的接口，法律需要责任、主体和归因的接口，政治需要合法性和公共性的接口，教育需要知识、成长和目的的接口，经济需要价值、偏好和分配正当性的接口，文化与艺术需要意义、表达和共同经验的接口。哲学内核并不生产所有文明内容，却影响文明功能系统能否稳定调用这些基础范畴。

若真实与证据的接口失准，科学和教育仍可继续生产内容，但知识与现实之间的连接会变得脆弱。若责任与授权的接口失准，法律和行政仍可继续运行程序，但行动与后果之间的归因会变得不稳定。哲学内核不是代码，也不是一个可单独安装、替换或重启的模块；它之所以被称为“内核”，只是因为它在功能上承担基础范畴接口的校准作用。

第三，人类文明作为发行版。人类文明可以被有限地类比为发行版。发行版不是硬件本身，也不是内核本身，而是围绕底层接口组织出一个可实际进入、可持续维护、可被用户使用的完整运行环境。对应到本文，人类文明不是基础范畴本身，也不是某一制度或某一技术系统，而是由语言、知识、法律、教育、经济、政治、文化、技术、责任结构、历史记忆和意义叙事共同构成的跨代际共同世界。

人类个体进入文明，不是直接进入抽象范畴，而是进入家庭、学校、法律、媒体、科学共同体、工作组织、文化传统、技术平台和公共制度构成的具体环境。文明作为完整运行环境，使人类能够在大于个体生命的历史结构中学习、判断、负责、创造和传承。

发行版类比还说明，运行环境可以看似完整，却在底层接口上出现失准。一个社会可能仍然有学校、法院、媒体、市场、政府和文化生产，甚至这些系统运行得更高效，但如果真实、证据、责任、主体性、价值和意义等基础接口失准，人类主体性实现条件仍可能受到结构性削弱。

第四，文明功能系统作为应用层。文明功能系统可以粗略类比为应用层。科学、法律、教育、经济、政治、文化、媒体、行政、医疗、宗教和艺术等系统，是人类日常进入共同世界的主要界面。应用层直接处理具体任务：生产知识、裁决争议、组织权力、培养下一代、分配资源、表达意义、治疗疾病、传播信息、维持仪式和解释生活。

应用层的特点是可见、可评估、可优化。一个系统是否运行，任务是否完成，流程是否加快，用户

是否满意，效率是否提高，这些都比较容易观察。现代 AI 也最容易在这一层显示其价值：提高生产率、降低成本、辅助写作、自动分析、加速流程、个性化服务、降低知识门槛。

但是，应用层繁荣并不等于系统整体健康。一个社会可以产生更多报告、更多图像、更多分析、更多建议、更多评价和更多决策，却同时越来越难以确认这些输出与真实、责任、判断和意义之间的关系。一个文明功能系统也可以继续运行，甚至更高效运行，但如果它逐渐不再需要人类理解、判断、劳动、创造、公共参与和责任承担，那么人类在其中的主体性实现条件就会被削弱。

因此，文明功能系统作为应用层的类比，为后文的 AI 风险分析提供了中间桥梁。人类并不只是文明功能系统的用户、消费者或被服务对象，还应当是劳动者、学习者、判断者、创造者、公民、责任承担者和未来主体。

5.3 非类比地说明结构关系

类比到此为止。真正具有论证效力的，是以下非类比的说明。

人类物种、人类文明、哲学内核和文明功能系统，不是四个并列实体，也不是四个风险承受主体。它们分别说明同一风险承受主体——人类这一具身物种——得以存在和实现主体性的不同条件。

人类物种提供生物承载。没有具身的人类生命，就没有人类文明、主体性实现或未来承诺。人类文明提供主体性实现的跨代际共同世界。没有语言、知识、制度、责任结构、历史记忆和意义叙事，人类就难以作为认识者、判断者、责任者、制度参与者和意义创造者而存在。哲学内核作为文明条件内部的范畴校准机制，维持真实、证据、责任、主体性、价值和意义等基础范畴的可解释、可追责和可修正。文明功能系统则是人类实际参与这些条件的运行界面，使人类通过科学、法律、教育、经济、文化、治理和公共服务进入共同世界。

因此，AI 相关人类存在性风险不能只被理解为某个技术系统是否伤害人类身体，也不能只被理解为某个社会应用是否带来局部问题。AI 可能作用于生物承载，可能改变文明运行环境，可能削弱人类在功能系统中的实质参与，也可能扰动基础范畴的校准机制。所有这些风险最终都必须回到同一个问题：人类这一具身物种是否仍能在文明条件中实现其主体性。

以上是非类比的说明。以下将说明：AI 的发展、部署与嵌入，为什么可能作用于这些条件，使之进入存在性风险范围。

6 | AI 为什么使这些条件成为存在性风险问题

6.1 AI 与生物存续层面

首先，AI 可能作用于人类生物存续层面。这是既有 AI 存在性风险讨论最熟悉的部分，也是本文始终保留的底线风险形式。若 AI 系统通过失控、误用、竞争压力、武器化、高后果技术链条或关键基础设施风险，导致人类物种灭绝、永久失能或人类未来被不可逆封闭，那么它直接构成人类存在性风险。

这种风险可能通过多种路径出现。足够强大的 AI 系统可能辅助危险生物技术研发，增强网络攻击能力，影响能源、通信、金融、交通和供应链等关键基础设施，参与自动化武器系统，或在复杂社会系统中放大人类难以及时理解和控制的连锁后果。

生物存续层面的重要性还在于，它是所有其他层面与机制的承载前提。没有具身的人类生命，没有身体、神经系统、死亡性、生殖机制和代际延续，人类文明、哲学内核、责任结构和意义叙事都无

从持续。

更进一步，文明条件和范畴校准机制本身也影响人类处理物种层风险的能力。一个无法稳定区分真实与虚假、证据与叙述的社会，难以可靠评估高后果技术风险；一个责任结构不清的社会，难以治理危险行动链条；一个主体判断能力弱化的社会，难以形成长期公共行动；一个意义结构贫乏的社会，可能缺乏保护未来世代的理由。因此，物种层风险与主体性实现条件风险不是竞争关系，而是相互依赖关系。前者提供底线，后者说明底线之上的人类未来何以仍然是人类的未来。

6.2 AI 作为文明中介

AI 的特殊性在于，它并不只作为外部危险源出现，也正在作为**文明中介**进入人类知识生产、制度流程、判断形成、责任分配和意义组织之中。它不是简单地站在人类文明之外，像自然灾害或外部敌人一样施加破坏；它越来越多地嵌入文明功能系统内部，参与这些系统的运行、加速、排序、过滤、评估和生成。

当 AI 进入教育系统时，它影响的不只是学习效率，也可能影响人类如何形成理解、提问和判断的能力。当 AI 进入科学和知识系统时，它影响的不只是信息处理速度，也可能影响证据如何被组织、解释和接受。当 AI 进入法律和治理系统时，它影响的不只是行政效率，也可能影响责任如何被分配、理由如何被生成、程序如何被理解。当 AI 进入文化和媒体系统时，它影响的不只是内容生产，也可能影响意义、记忆、共同经验和公共想象的形成。

因此，AI 的风险意义不只在它可能造成外部灾难，也在于它可能改变人类如何认识真实、形成判断、承担责任、参与制度和创造意义。若 AI 只是在某个局部功能中提供可逆、可理解、可纠正的工具支持，那么它仍主要属于普通社会风险或社会适应问题〔注 9〕。但若 AI 系统开始系统性地重组人类进入知识、制度和意义结构的方式，并进一步影响主体性实现的基础条件，问题就可能上升到文明条件层面的存在性风险。

这里的关键，不是 AI 是否“参与文明”。文字、工具、机器、互联网、平台系统和自动化技术都曾参与文明运行。真正关键的问题是：AI 的参与是否削弱了人类作为共同世界的实质参与者、判断者、责任承担者和方向塑造者的地位。

6.3 替代性剥夺

AI 对文明条件层面的影响，不只表现为某个工具更高效，也不只表现为某个行业被自动化。更深的问题在于，AI 正在进入文明功能系统，改变人类参与共同世界的方式。

如第 3 章和第 5 章所述，经济、法律、教育、科学、国家治理、文化、媒体、行政和公共服务等系统，是人类主体性实现的重要承载层。人类通过这些系统学习、劳动、判断、创造、负责、治理和面向未来行动。AI 作为更高效、更可复制、更可规模化的替代者，可能逐渐取代人类在这些系统中的劳动、认知、创造、治理和判断角色，使人类被系统挤出或边缘化。本文将这一机制称为**替代性剥夺**〔注 10〕。

经济系统可能越来越少依赖人类劳动和专业判断；文化系统可能越来越少依赖人类创作和解释；治理系统可能越来越少依赖人类公共判断和政治参与；教育与科研系统也可能越来越多地依赖自动生成、自动评估和自动筛选。此时，文明功能系统仍然运行，甚至可能运行得更高效，但人类作为系统参与者和方向塑造者的地位被削弱。

这种风险并不必然表现为人类立即失去所有权利或资源。更常见的形式可能是**相对失权**：人类仍然消费、投票、确认和被服务，但越来越少真正影响资源分配、制度方向、知识生产和文化叙事。人

类仍然在系统中，却不再是系统运行所必需的参与者。若这种趋势跨越经济、文化、国家治理、教育和媒体等多个功能系统，并通过相互反馈不断强化，它就可能削弱人类作为未来主体塑造共同世界的能力。

替代性剥夺的核心问题是：人类是否仍然能够作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体，**实质性地**参与共同世界的形成与更新？若答案逐渐变成否定，那么 AI 对文明条件的影响就不只是社会适应问题，而可能触及人类主体性实现的基础条件。

替代性剥夺首先侵蚀的是**实质参与**。人类可能仍保留形式参与——点击、签署、投票、选择、消费——但越来越少对共同世界的方向产生实质性影响。若这种侵蚀跨越多个关键系统并呈现不可逆或难以逆转趋势，它就可能进入存在性风险问题，但仍需经过第 6.6 节四个门槛的进一步筛选。替代性剥夺的危险不在于某一岗位、职业或行业消失，而在于人类逐渐不再是共同世界运行和更新所必需的主体。

6.4 中介性重构

AI 对文明条件的影响，并不只表现为人类被文明功能系统逐渐替代或挤出。另一种更隐蔽的机制，是人类仍然留在系统之中，仍然保留选择、审批、签署、学习、创作和参与等形式，但这些活动的前提条件已经被 AI 深度中介。本文将这一机制称为**中介性重构**。

中介性重构首先发生在文明功能系统中。教育系统仍然培养学生，但学习路径、问题生成、答案评估和知识组织越来越多地由 AI 中介；法律和行政系统仍然保留程序，但证据筛选、文本生成、风险排序和决策建议越来越多地由 AI 参与；科学和知识生产系统仍然发表研究、生成解释和组织文献，但假设提出、材料筛选、论证写作和可信度判断越来越多地依赖模型输出〔注 11〕；文化和媒体系统仍然生产意义、叙事和公共想象，但表达形式、注意力分配和意义评价越来越多地被生成式系统塑形。

在这些情形中，人类并未被完全排除在系统之外。人类仍然阅读、确认、投票、签署、学习、创作、管理和承担责任。但问题在于，人类参与的结构已经发生改变。人类仍在获取信息，但信息入口、摘要结构和解释框架可能由系统预先组织；人类仍在作出决策，但可见选项、风险排序和理由生成可能由 AI 塑形〔注 12〕；人类仍在承担责任，但判断形成过程越来越难以理解和追踪；人类仍在学习和创造，但学习过程、创作标准和意义评价越来越依赖系统输出。

中介性重构与替代性剥夺的关键区别在于：替代性剥夺使人类逐渐失去在系统中的位置（实质参与被削弱）；中介性重构则保留甚至强化人类在系统中的形式位置，却抽空其背后的实质参与。人类仍像是在判断，但判断所依赖的信息已经被预先过滤；人类仍像是在选择，但可见选项已经被预先排序；人类仍像是在负责，但责任所需的理解和可追踪性已经被削弱。

中介性重构还可能进一步扰动哲学内核。若真实越来越通过系统生成的摘要、推荐和合成内容被接触，真实与伪造的区分就可能发生漂移。若证据越来越由系统筛选、排序和解释，证据的公共可检验性就可能被削弱。若责任越来越被分配给名义上的人类批准者，而判断形成过程却由系统深度塑形，责任范畴就可能变得空洞。若主体性越来越表现为在系统提供的选项中选择，而不是理解、质疑和塑造选项本身，主体性范畴也会被重写。

中介性重构的更深层后果，是文明功能系统调用基础范畴的方式发生变化。它可以从五类范畴接口压力来理解。以下对应 4.5 所界定的文明基础条件展开：真实与证据的可校准性、责任与授权的可归因性、主体性与判断的可维持性、价值排序的可反思性、意义传承的可理解性与可延续性。其中，真实与证据共同构成认识论接口，责任与授权、主体性与判断分别构成实践理性接口。

就真实与证据而言。生成式系统能够产生流畅、连贯、表面可信的内容，但流畅性不等于真实性，解释性不等于证据性，相关性不等于可靠性。若人类越来越以生成内容作为认识起点，而不是以来源、证据和验证过程作为认识基础，那么真实与证据之间的校准关系就会变得脆弱。问题不只是某个模型偶尔出错，而是人类共同体维持可验证知识结构的条件可能被改变。

就责任与授权而言。当 AI 参与建议生成、证据筛选、风险评估、方案比较和行动触发时，人类签署最终文件，并不必然意味着人类理解了判断形成过程；制度保留审批和审计流程，也不必然意味着它能够追踪行动如何形成。责任结构因此不能只依赖形式化签字、流程节点或日志记录，而必须重新澄清行动、授权、理解、过失和归因之间的关系。这里的“授权”不是新增的基础范畴，而是责任范畴在制度实践中的关键接口。

就主体性与判断而言。主体性不能被简单等同于最后一次点击、确认或选择。若 AI 系统预先组织问题、筛选信息、生成理由、排序选项并推荐行动，人类即使保留选择形式，也可能越来越少参与判断形成的核心过程。这里的“判断”不是新增的基础范畴，而是主体性在实践中的核心能力。问题不在于人类是否还在使用工具，而在于工具是否开始替代人类形成理由、理解问题并承担判断责任。

就价值排序而言。AI 往往以优化问题的形式运行，但优化本身并不说明目标是否正当，也不说明被优化的指标是否真正代表人类价值。一个系统可以优化参与度，却削弱公共理性；优化生产率，却损害主体性；优化便利性，却降低判断能力；优化满意度，却掩盖意义贫乏。若文明功能系统越来越依赖可度量指标来组织行动，价值排序就可能被技术指标替代，价值反思则可能被优化逻辑压缩。

就意义生成而言。AI 可以生成作品、陪伴、研究、设计和方案，使人类重新追问创造、学习、劳动、尊严、贡献和意义的基础。若文明条件无法重新说明人类为何仍应学习、创造、承担责任和保护未来，那么主体性实现就会失去重要的意义支撑。风险不是 AI 能否生成有价值的内容，而是人类是否仍能在生成内容大量存在的条件下，理解自身创造、责任和未来承诺的意义。

这些接口压力并不是彼此孤立的。真实需要证据来校准，责任需要主体性来承载，主体性需要判断能力来实现，价值需要意义来解释，意义也需要真实、责任和价值来避免滑向任意叙事。当 AI 同时改变多类范畴接口的实践条件时，文明功能系统可能仍然继续运行，甚至更高效运行，但其运行将越来越依赖自动化、预测、排序和优化，而不是理解、判断、责任和意义。问题不是 AI 偶尔污染某个判断，而是真实、证据、责任、主体性、价值和意义之间的相互校准关系被系统重写。本文将这种多接口联动的后果称为**范畴网络的整体漂移**。

替代性剥夺与中介性重构并不互相排斥。人类可能在某些文明功能系统中被逐渐替代，在另一些系统中仍然参与但被深度中介。前者削弱的是人类作为共同世界参与者的地位，后者削弱的是人类在参与过程中的理解、判断、责任和意义创造能力。二者共同指向同一个问题：人类是否仍能在文明条件中实现其主体性。

6.5 扩展定义及其必要性

基于上述分析，本文提出如下扩展定义：

AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的，可能不可逆地毁灭人类物种；或使人类永久失能，或以其他方式永久剥夺人类未来；或不可逆或难以逆转地削弱人类这一具身物种在文明中实现其主体性之基础条件的风险。

这三个选言项不是互斥分类，而是按“何者存续”组织的覆盖结构。第一项指承受主体本身的生物性终结；第二项指承受主体仍然存续，但其未来被永久封闭；第三项指承受主体与名义上的未来仍

然存续，但其在文明中实现主体性的基础条件被不可逆或难以逆转地削弱。选言项之间允许蕴含与重叠，因为本定义追求的是对人类可能受损方式的联合覆盖，而不是形式上的互斥划分。

这个定义保留了物种层存在性风险的核心地位，同时将风险分析从单一生物存续层面扩展到文明条件中的主体性实现。它不要求所有 AI 引发的社会变化都被纳入存在性风险，也不要求每一种文明扰动都被视为存在性损害。它只主张：当 AI 的影响触及人类在文明中实现主体性继续成立的基础条件，并具有不可逆或难以逆转的结构性后果时，存在性风险理论就不能只以生物学存续为判断对象。

这种风险不一定表现为突然崩溃。它可能表现为正常运行中的能力转移：人类仍然获得信息，却越来越少验证来源；仍然作出选择，却越来越少参与问题定义；仍然承担责任，却越来越少理解判断形成过程；仍然生产内容，却越来越难维持真实与证据之间的关系；仍然拥有制度，却越来越难追踪行动和后果之间的责任链条。此时，社会可能更高效、更便利、更自动化，但人类主体性实现条件却可能被逐步削弱。

因此，如果 AI 存在性风险识别在实践中只关注生物毁灭路径，就会错过一种 AI 时代特有的风险形态：人类物种仍然存续，但其作为认识者、判断者、责任者、制度参与者和意义创造者继续存在的文明条件被系统性弱化。本文的扩展定义正是为了给这种风险提供概念位置。

6.6 人类主体性实现风险的四个门槛

一个风险若要进入人类主体性实现层面的存在性风险范围，至少应满足四个条件：

第一，它必须作用于文明基础条件，而不是局部功能。某个职业被替代、某个行业被重组、某个制度流程被自动化，并不自动构成存在性风险。只有当这些变化系统性影响真实与证据的可校准性、责任与授权的可归因性、主体性与判断的可维持性、价值排序的可反思性、意义传承的可理解性与可延续性时，它们才可能进入人类主体性实现层面的存在性风险范围。

第二，它必须具有跨领域并跨文明接口的扩散能力。〔注 13〕局部错误、单一事故、孤立误用，乃至单一国家或单一制度内部的自动化重组，通常不足以构成人类存在性风险。只有当某种机制能够通过全球科研网络、教育体系、数字平台、法律—治理接口、供应链和公共话语结构，跨越多个文明功能系统并反复改变人类判断、责任、参与或意义结构时，它才具有人类主体性实现层面的存在性风险特征。

第三，它必须可能造成不可逆或难以逆转的结构性损害。〔注 14〕存在性风险关心的不只是规模，也关心可逆性。在文明条件层，不可逆或难以逆转主要指历史、制度和认知意义上的难以恢复。例如，长期制度路径依赖可能使某些自动化流程成为默认结构；代际能力训练断裂可能使后代不再掌握某些判断、验证和责任承担能力；认知习惯的深层重塑可能使人们不再将某些能力的缺失识别为损失。这种文明条件层的难以逆转不同于物种灭绝的物理不可恢复，但在历史尺度上可能足以改变人类继续作为未来主体的能力。这里的“难以逆转”并不指治理成本高、恢复周期长或制度改革困难，而是指在跨代际历史尺度上，相关能力、制度路径和范畴校准机制已经退化到缺乏现实修复主体与修复路径的状态。

第四，它必须使前三项损害汇聚为对人类未来主体能力的整体性、跨代际损害。存在性风险不是任何重大损失，而是影响人类能否继续作为自身未来主体的风险。第四门槛并不重复第一门槛，而是检验前三项是否共同汇聚为整体性、跨代际的未来能力损害：如果某种 AI 嵌入方式不仅作用于文明基础条件、具有跨领域并跨文明接口的扩散能力，并造成不可逆或难以逆转的结构性损害，而且使人类越来越难以理解风险、修正制度、组织行动并塑造未来，那么它就不只是社会适应问题，而是人类主体性实现的基础条件受到损害的问题。

“人类作为未来主体”并不引入新的风险承受主体，也不是独立于主体性实现之外的新概念。它指的是主体性实现的时间性和能动性面向：人类不仅当下认识、判断和负责，也能够跨代际过程中理解风险、修正制度、组织行动并塑造未来。因此，第四门槛是前三项门槛之后的聚合判据，检验局部能力受损是否已经汇聚为对人类整体未来指向性的损害。

这四个门槛共同限制了扩展定义的范围。它们确保本文不会把所有 AI 社会影响都升级为存在性风险，也不会把普通技术变迁误读为文明级损害。而不满足这些门槛的 AI 相关社会影响，本文称为普通社会风险：它可作用于局部功能、制度过程或行业结构，具有相对明确的修复路径，可以是重要风险，但不必然是存在性风险。

7 | 反对意见、边界与范式扩展

前文已经提出，AI 相关人类存在性风险不应只被理解为物种灭绝、永久失能或未来剥夺，也应包括人类这一具身物种在文明条件中实现主体性之基础条件的不可逆或难以逆转的削弱。本节以**案例试刀与文献交锋**回应反对意见，并划定范式扩展的边界。

7.1 门槛的试刀：两个案例

反对意见一：本文可能把就业替代、信息污染、教育依赖或制度自动化等普通社会问题，过度升级为存在性风险。

本文明确拒绝这种泛化。AI 相关普通社会风险并不等同于 AI 相关人类存在性风险。普通社会风险可以非常严重，可以造成广泛伤害，也可以需要强有力的治理回应；但它通常作用于某一局部社会功能、制度过程、行业结构或技术应用，并具有相对明确的治理对象和修复路径。

以下以两个案例演示四门槛的筛选功能。

案例 A（排除）：假设某国 80% 的制造业岗位被 AI 自动化替代，但教育系统仍在培养新一代工程师，法律系统仍由人类法官主导证据审查与责任归因，科学共同体仍独立提出假设、验证证据和追踪误差。制造业劳动者可以通过再培训进入其他领域，制度方向仍由人类公共判断塑造。这属于**普通社会风险**：它主要作用于局部功能（经济系统的劳动结构），尚未作用于文明基础条件，也不具有跨领域并跨文明接口的扩散能力，且可通过教育调整、制度修复和代际再培训逆转。它不通过四门槛。

案例 B（通过）：假设全球科学出版系统在未来二十年内全面依赖 AI 生成文献综述、实验设计、统计显著性筛选和同行评审辅助，导致新一代研究者不再具备独立提出假设、验证证据和追踪误差的能力；同时法律系统全面采用 AI 生成判决理由与风险排序，使“责任归因”退化为形式签字；教育系统以 AI 个性化学习深度组织学习路径、问题生成和评价标准，使公共讨论、批判性质疑和跨主体论证训练逐渐退居边缘。此案例主要体现为**中介性重构**而非替代性剥夺：人类仍保留科学家、法官、学习者的形式位置，但判断形成、证据检验与意义理解的前提已被 AI 深度重组。

这作用于**文明基础条件**（真实与证据的可校准性、责任与授权的可归因性、主体性与判断的可维持性、价值排序的可反思性、意义传承的可理解性与可延续性），**跨领域并跨文明接口扩散**（全球科学出版、法律—治理接口与教育训练同时被重构，并通过数字平台、科研网络和制度标准跨地区传播），**难以逆转**（代际能力断裂使独立研究、批判判断和责任归因成为稀缺技能），并**汇聚为未来主**

体能力的整体性损害（人类不再能独立修正知识、承担责任、面向未来行动）。因此，它通过四门槛，进入存在性风险范围。

这两个案例的对照说明：四门槛不是装饰性清单，而是可操作的筛选机制。它们确保本文不会把所有 AI 社会影响都升级为存在性风险，也不会把存在性风险缩减为单一物种灭绝问题。

7.2 文明或哲学内核是否被实体化？

反对意见二：本文在讨论文明条件、哲学内核和范畴校准机制时，似乎把文明或哲学内核变成了新的风险承受主体。

这一误解必须被排除。本文的核心主张恰恰是：AI 相关人类存在性风险的风险承受主体始终是人类这一具身物种。文明、制度、文化、技术系统和哲学内核都不是与人类并列的风险承受主体。文明条件之所以重要，不是因为文明本身成为一个独立主体，而是因为人类这一具身物种需要通过文明条件实现主体性。哲学内核同样不是实体：它不是学院哲学学科，不是某个文明系统的最高部门，也不是隐藏在文明背后的神秘原则。它指的是文明条件内部维持基础范畴可运行性的范畴校准机制。

任何把文明、制度或哲学内核当作独立承受主体的理解，都偏离了本文的核心框架。

7.3 这是否只是 AI disempowerment 或 autonomy degradation 的另一种说法？

反对意见三：本文似乎只是用新的语言重新描述已有讨论，例如 AI disempowerment、autonomy degradation、over-reliance、deskilling 或人类能动性的衰退。

本文承认，这些讨论与本文有重要交叉。AI 可能削弱人类能力、增加依赖、转移权力、改变决策结构、降低人的判断训练，这些都是理解 AI 风险的重要线索。

但本文的任务并不是简单重复这些讨论，而是把它们放回一个更前置的风险识别框架之中。能力衰退、过度依赖、权力转移或自主性削弱，通常描述的是某些具体能力、制度关系或行动位置的变化。本文追问的是更根本的问题：这些变化在什么条件下不只是局部能力退化，而是触及人类作为风险承受主体的存在性损害？

具体而言，Kulveit 等人（2025）所描述的“gradual disempowerment”与本文的“替代性剥夺”在现象层面相邻，但前者定位于权力转移的社会动力学，而本文追问的是：这种转移在什么条件下作用于文明基础条件、具有跨领域并跨文明接口的扩散能力、难以逆转，并汇聚为未来主体能力的整体性损害？Prunkl（2022）与 Krook（2025）关于自主性衰退和技能退化的分析〔注 15〕，与本文的“中介性重构”在症状层面交叉，但本文进一步追问：当自主性衰退不是个体选择的结果，而是文明功能系统中范畴校准机制的整体漂移时，它是否触及人类主体性实现的基础条件？

因此，本文与这些讨论的区别不在于否认它们，而在于改变分析层级。本文不是从某一具体能力或制度关系出发，而是从风险承受主体及其受损层面出发。在这一框架下，disempowerment、autonomy degradation、over-reliance 和 deskilling 可以被重新定位为可能的机制或症状，而不是本文的最终概念中心。本文的概念中心不是某一种能力下降，而是判断这些能力下降何时上升为人类这一风险承受主体的存在性损害。

8 | 结论：在保护人类之前，先澄清人类是什么

本文从一个前置问题出发：当我们说 AI 可能威胁“人类”时，处于风险之中的“人类”究竟是什么？

本文建立了一项**概念工程**，区分风险承受主体的两个基本受损层面：生物存续层面与文明条件层面；同时，在文明条件层面内部，本文单独标出哲学内核，即真实、证据、责任、主体性、价值和意义等基础范畴的范畴校准机制。生物存续层面说明人类作为具身物种是否继续存在；文明条件层面说明人类是否仍能通过跨代际共同世界实现主体性；哲学内核则说明这些基础范畴是否仍能被澄清、维护和调整。

风险承受主体始终是人类这一具身物种。本文并不将承受主体扩展为文明、制度、哲学内核或 AI 系统。本文扩展的是同一主体可能受到存在性损害的方式：从单一生物存续层面上的毁灭、永久失能或未来剥夺，扩展到人类在文明条件中实现其主体性之基础条件的不可逆或难以逆转的削弱。

本文分析了 AI 作用于文明条件层面的两种机制：**替代性剥夺与中介性重构**。替代性剥夺使人类逐渐失去在文明功能系统中的实质参与，保留形式参与却抽空方向性影响；中介性重构则保留人类的形式位置，却使信息入口、理由生成、选项排序和责任追踪被 AI 深度预先组织。二者共同指向同一个问题：人类是否仍能在文明条件中实现其主体性。

据此，本文将 AI 相关人类存在性风险理解为三类受损方式的联合覆盖：人类物种的生物性终结、人类未来的永久封闭，以及人类在文明中实现主体性的基础条件被不可逆或难以逆转地削弱。

本文提供的不是完整风险分类，不是技术控制方案，也不是政策清单，而是 AI 安全、风险分析与治理在风险识别层面所需要的**本体论坐标系**。这个坐标系使不同研究在讨论具体技术或政策之前，先回答一个更前置的问题：我们究竟在保护什么？

在保护人类之前，我们必须先澄清人类是什么；在治理 AI 风险之前，我们必须先说明哪些损害真正触及人类作为未来主体继续成立的基础条件。**否则，人类可能在一个运行更高效的文明中，却失去作为自身未来主体而存在的基础。**

在这个意义上，存在性风险的关键问题不是 AI 是否改变社会，而是这种改变是否使人类越来越不能作为自身未来的作者。

附录 A | 核心概念词典

本附录汇总并定义本文使用的核心概念。其功能不是重复正文论证，而是为正文中的概念工程提供稳定的术语边界。每个概念均尽量说明其定义、边界和在本文论证中的作用。除非特别说明，本附录中的概念均服务于本文关于 AI 相关人类存在性风险之风险承受主体的分析。

一、本体核心概念

A.1 概念工程

概念工程，是指对某一概念的使用方式、边界条件、隐含前提和理论功能进行显化、评估、修正和重构的工作。它并不只是解释一个概念在既有语言中的通常含义，而是追问该概念在特定理论与实践场景中是否足够清楚、是否造成误导、是否需要被重新划界。

在本文中，概念工程的对象是 AI 相关人类存在性风险中的“人类”这一风险承受主体。本文并不试图重新定义所有 AI 风险，也不直接提出治理方案，而是追问：当我们说 AI 可能威胁“人类”时，这里的“人类”是否只能被理解为生物物种，还是也应包括人类这一具身物种在文明条件中实现主体性的基础条件。

本文的概念工程功能，是把“人类”从未经澄清的背景词，转化为 AI 风险识别中的核心分析对象。

A.2 AI 相关人类存在性风险

AI 相关人类存在性风险，是指由 AI 系统的发展、部署、嵌入或失控所引发的，可能不可逆地毁灭人类物种；或使人类永久失能，或以其他方式永久剥夺人类未来；或不可逆或难以逆转地削弱人类这一具身物种在文明中实现其主体性之基础条件的风险。

这个定义包含三类受损方式。第一，人类作为生物物种被不可逆毁灭。第二，人类虽未灭绝，但永久失能，或以其他方式永久失去开放未来。第三，人类物种与名义上的未来仍然存续，但其在文明条件中实现主体性的基础条件被不可逆或难以逆转地削弱。

这三类受损方式不是互斥分类，而是覆盖结构。物种灭绝通常也意味着未来剥夺；永久失能是未来剥夺的核心形式之一；主体性实现条件的不可逆削弱则说明，即使人类仍然生物学地存在，也可能失去作为未来主体继续成立的文明条件。

A.3 风险承受主体

风险承受主体，是指在某一风险分析中，被视为可能遭受根本性、不可逆或难以逆转损害的对象。它回答的是：风险最终落在谁或什么之上。

在本文中，AI 相关人类存在性风险的风险承受主体始终是人类这一具身物种。文明、国家、文化、制度、技术系统、哲学内核和 AI 系统，都可能成为风险发生、传导、放大或中介的结构，但它们不是本文中的风险承受主体。

这个概念用于防止一种常见混淆：把风险发生的系统误认为风险承受主体。AI 可能作用于经济系统、法律制度、教育结构、知识系统或范畴校准机制，但这些作用最终之所以具有存在性风险意义，是因为它们可能损害人类这一具身物种的生物存续，或损害其在文明中实现主体性的基础条件。

A.4 人类

本文所说的人类，首先指 *Homo sapiens* 这一具身生物种群。人类具有身体结构、神经系统、感知能力、生殖机制、生理脆弱性、死亡性，以及对生态和物质环境的依赖。

但人类并不只以生物存续层面存在。人类这一具身物种还在文明条件中实现主体性，即通过语言、知识、教育、制度、责任结构、公共理性、历史记忆、意义叙事和文明功能系统，获得并维持认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动的能力。

因此，本文中的“人类”具有两个基本分析层面：生物存续层面与文明条件中的主体性实现层面。前者说明人类作为具身物种的存在承载，后者说明人类为何不只是生物种群，而是能够成为认识者、判断者、责任者、制度参与者、意义创造者和未来主体的历史性存在。

A.5 具身物种

具身物种，是指人类不是纯粹信息结构、抽象理性主体或可任意迁移的计算模式，而是由身体、神经系统、感知、情感、脆弱性、死亡性、依赖关系和代际延续所构成的生物种群。

具身性不是人类主体性的外在附加属性，而是人类文明、责任、意义和未来承诺得以承载的生物前提。人类的判断、学习、责任承担和意义形成，都与身体、有限性、时间性和对后果的承受能力有关。

在 AI 风险分析中，具身物种概念用于抵抗一种还原倾向：把人类理解为可被更高效信息处理系统替代的认知模式。本文认为，即使 AI 能够执行大量认知任务，人类仍不能被还原为信息处理结构，因为人类作为责任者、行动者和意义创造者的存在，依赖其具身有限性。

A.6 生物存续层面

生物存续层面，是指人类作为 *Homo sapiens* 这一具身生物种群的存续状态，包括身体结构、神经系统、感知能力、生殖能力、生理脆弱性、死亡性和生态依赖。

生物存续层面构成人类存在的物理承载。若人类物种灭绝，或永久失去繁衍、行动和塑造未来的能力，则人类文明、责任结构、意义叙事和主体性实现都将失去承载者。

在本文中，生物存续层面对应传统存在性风险中的底线风险形式，包括物种灭绝、永久失能和人类未来的永久封闭。本文扩展存在性风险概念，并不是削弱生物存续层面的核心地位，而是在其基础上进一步分析文明条件层面的受损方式。

A.7 文明条件层面

文明条件层面，是指人类这一具身物种在文明中实现主体性所依赖的结构性条件。它包括语言、知识系统、教育结构、法律制度、责任机制、公共理性、科学共同体、历史记忆、技术实践、意义叙事和文明功能系统等。

文明条件层面不是与人类并列的主体，也不是独立于人类之外的风险承受者。它是人类主体性实现的构成性条件。若这些条件受到不可逆或难以逆转的削弱，受损的不是“文明本身”作为主体，而是人类这一具身物种在文明中实现其主体性的能力。

该概念用于说明：人类存在性风险并不只表现为身体毁灭或物种灭绝，也可能表现为人类继续活着，却逐渐失去认识真实、形成判断、承担责任、参与制度、传承意义和面向未来行动的条件。

A.8 人类文明

人类文明，是人类这一具身物种在历史中通过语言、知识、制度、法律、教育、责任结构、技术实践、文明功能系统和意义叙事形成的跨代际共同世界。

人类文明不是人口总和，不等同于国家，不只是文化，也不能被还原为技术体系。人口提供生物承载，国家提供政治法律组织，文化提供意义表达和生活界面，技术提供行动能力；但人类文明是这些要素在跨代际传递、制度化组织、知识积累和意义生成中形成的共同世界。

本文不提出一般文明理论。除非特别说明，正文中所说的“文明”均指人类文明。人类文明之所以是“人类”的，不在于其中没有非人技术成分，而在于它以人类这一具身物种为风险承受主体，并以人类主体性实现为规范性焦点。

A.9 跨代际共同世界

跨代际共同世界，是指通过语言、记忆、教育、制度、知识、责任结构和意义叙事，使过去能够传递给未来，使个体生命能够进入大于自身的历史—理解空间的共同世界。

跨代际共同世界不是人口在时间中的简单延续，也不是文化材料的机械保存。它要求后代不仅被生物学地生出，而且能够进入一个可理解、可继承、可批判、可修正和可更新的共同世界。

在本文中，跨代际共同世界是人类文明的核心定义特征。它使“人类文明”区别于人口总量、国家组织、文化习俗和技术系统，也为“人类作为未来主体”提供时间性基础。文明条件的真正延续，不只是“有人活着”，而是“有人能够理解、继承、批判和更新一个共同世界”。

A.10 现代全球文明生态

现代全球文明生态，是指当代人类社会由多重文明传统、科学体系、技术基础设施、法律制度、市场、国家、国际组织、数字平台、教育系统、媒体系统和公共理性共同构成的高度互联文明环境。

该概念强调两点。第一，人类文明整体不是某一种文明传统的普遍化，也不是某一国家或文化的扩大版。第二，现代全球文明已经形成若干共享接口，例如科学体系、国际法、公共卫生系统、互联网协议、金融网络、数字平台和 AI 基础设施。

在本文中，现代全球文明生态用于说明 AI 风险并不只作用于局部国家、文化或平台，而可能作用于多重文明传统共同依赖的知识、制度、技术和意义接口。它也是判断文明条件层面风险是否达到人类尺度的重要背景。

二、文明条件与主体性实现概念

A.11 构成性条件

构成性条件，是指某种能力、身份或存在方式得以成立的必要条件，而不是外在、可替换的辅助工具。

工具性条件帮助主体完成某项任务；构成性条件则参与形成主体能够完成该任务的能力本身。例如，语言不只是表达思想的工具，也是复杂思维、理由交换和规范承诺得以展开的条件。类似地，教育、责任结构、公共理性、文明功能系统和意义叙事，也不只是人类主体性的外部辅助，而是人类作为认识者、判断者、责任者、制度参与者和意义创造者而存在的构成性条件。

本文使用该概念，是为了说明文明条件不是人类主体性之外的装饰，而是人类主体性实现本身的组成条件。文明条件一旦受到结构性削弱，受损的不是外部环境而已，而是人类主体性实现的成立条件。

A.12 文明功能系统

文明功能系统，是指人类文明中具体承载知识生产、制度行动、责任分配、教育传承、经济组织、文化表达、公共治理、医疗照护、媒体传播和意义创造的功能性系统。

典型文明功能系统包括经济系统、国家与治理系统、法律系统、教育系统、科学与知识生产系统、文化与媒体系统、医疗系统、行政系统、基础设施系统、宗教系统和艺术系统等。

文明功能系统是连接抽象文明条件与具体社会机制的中间承载层。人类通常不是直接面对“文明”这一抽象整体，而是通过学校、法院、实验室、市场、媒体、政府机构、平台系统、家庭、宗教传统、艺术实践和公共服务进入文明条件。

文明功能系统不是风险承受主体，但它是 AI 作用于人类主体性实现条件的关键通道。AI 对文明条件层面的影响，往往首先表现为对这些功能系统中人类参与方式的重组。

A.13 人类参与结构

人类参与结构，是指人类在文明功能系统中作为劳动者、学习者、判断者、创造者、公民、责任承担者和未来主体，参与共同世界运行、维护和更新的方式。

人类参与结构并不只是形式上的在场。它要求人类能够理解过程、形成判断、承担责任、创造意义，并对制度方向和公共未来产生实质影响。若人类在文明功能系统中只保留形式性确认，而不再真正理解、判断、负责、创造或塑造方向，那么人类在文明条件中的主体性实现就会受到削弱。

该概念为“替代性剥夺”和“中介性重构”提供基础。替代性剥夺削弱人类在系统中的参与位置；中介性重构保留人类参与形式，却改变判断、理解、责任和意义创造的前提条件。

A.14 形式参与与实质参与

形式参与与实质参与，是一组用于区分人类在文明功能系统中不同参与状态的对偶概念。

形式参与，是指人类在文明功能系统中保留可见位置、程序动作和名义角色的参与方式，例如点击确认、签署文件、批准建议、选择选项、投票、消费和反馈。形式参与维持着人类在制度中的可识别性，但不保证人类真正理解、判断、负责或塑造过程。

实质参与，是指人类作为认识者、判断者、责任承担者、制度维护者、意义创造者和未来主体，对共同世界的运行、方向和更新产生实际影响。它要求人类能够理解过程、形成判断、承担责任、创造意义，并对制度方向和公共未来产生实质影响。

该区分是本文分析 AI 风险的关键接口。替代性剥夺通常侵蚀人类的实质参与，使人类逐渐不再是共同世界运行和更新所必需的主体；中介性重构则可能保留甚至强化形式参与，却抽空形式参与背后的理解、判断、责任和意义创造。

A.15 主体性实现 / 人类在文明中的主体性实现

主体性实现，是指人类这一具身物种在文明条件中实际获得并维持认识真实、形成判断、承担责任、参与并维持制度、传承并创造意义、面向未来行动等能力的过程和状态。

主体性实现既不是人类物种的单纯生物属性，也不是文明本身的独立属性，而是人类主体性在文明条件中的实际展开。人类之所以不只是生物种群，正是因为人类能够在文明中进入知识、责任、制度、意义和未来行动的结构。

在本文中，主体性实现是文明条件层面风险的核心对象。AI 若系统性削弱这些能力，并造成不可逆或难以逆转的结构性后果，就可能构成人类主体性实现层面的存在性风险。

A.16 主体性能力

主体性能力，是指人类在文明条件中作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体而实际行使的能力集合。

本文重点关注六项主体性能力：

1. 认识真实；
2. 形成判断；
3. 承担责任；
4. 参与并维持制度；
5. 传承并创造意义；
6. 面向未来行动。

这六项能力并非互相孤立。认识真实支撑判断，判断支撑责任，责任与制度参与相互依赖，意义为学习、创造和未来承诺提供理由结构。主体性能力的系统性削弱，是本文扩展存在性风险分析的核心对象。

A.17 文明基础条件

文明基础条件，是指人类在文明中实现主体性时不可缺少的最低限度运行条件。它们不是人类文明的全部内容，而是使人类能够作为未来主体继续存在的基础接口。

本文重点关注五类文明基础条件：

1. 真实与证据的可校准性；
2. 责任与授权的可归因性；
3. 主体性与判断的可维持性；
4. 价值排序的可反思性；
5. 意义传承的可理解性与可延续性。

这些条件用于判断文明条件层面的风险是否触及主体性实现基础。若这些条件被系统性削弱，人类可能仍然生活在高度运行的社会中，却越来越难以认识真实、形成判断、承担责任、参与制度、传承意义和塑造未来。

三、范畴校准概念

A.18 基础范畴

基础范畴，是文明功能系统运行时必须共享和调用的基本概念接口。它们使文明能够区分真实与虚假、证据与叙述、责任与免责、主体与工具、价值与指标、意义与任意表达。

本文重点讨论六组基础范畴：

1. 真实；
2. 证据；
3. 责任；
4. 主体性；
5. 价值；
6. 意义。

基础范畴不是某一文明传统独占的理论词汇，也不声称穷尽所有可能的文明核心范畴。本文选择这六组基础范畴，是因为它们构成 AI 风险识别自身的最低条件：没有真实与证据，风险无法被认识；没有责任与主体性，行动无法被归因；没有价值与意义，风险治理无法说明其保护目标与未来理由。

不同文明传统可以对这些范畴给出不同理解，但只要文明系统需要知识、制度、责任、行动和意义，它就必须以某种方式调用这些范畴。

A.19 哲学内核

哲学内核，是指文明条件内部维持基础范畴可运行性的范畴校准机制。它不是基础范畴本身的集合，而是基础范畴被显化、检验、澄清、批判、维护和调整的机制。

哲学内核具有元机制属性。这里所谓“元”，并不是指它构成文明条件之外的更高实体，也不是指它成为新的风险承受主体，而是指它校准的不是某一个文明功能系统内部的局部规则，而是科学、法律、教育、政治、经济、文化等功能系统共同调用的基础范畴接口。

哲学内核不是学院哲学学科本身，不是文明中的独立实体，也不是与人类文明并列的风险承受主体。它也不是可被单独安装、替换或重启的模块。它之所以被称为“内核”，是因为它在功能上承担基础范畴接口的校准作用。

在本文中，哲学内核用于说明：文明功能系统即使继续运行，也可能因为底层范畴失准而失去可解释性、可追责性和可修正性。

A.20 范畴校准机制

范畴校准机制，是指基础范畴在历史中被显化、检验、批判、维护和调整的过程。它不是某一单一机构的功能，而是分散在哲学、科学、法律、教育、公共讨论、制度改革、文化实践和历史经验中的持续校准过程。

范畴校准机制关注的问题包括：什么算作真实，什么算作证据，谁能够承担责任，什么构成主体，什么值得优化，什么仍然有意义。

当范畴校准机制失效时，现实中表现为：科学、法律、教育、治理、媒体和文化等系统仍可能继续运行，但越来越难以稳定区分真实与伪造、证据与叙述、责任与免责、主体判断与形式确认、价值目标与优化指标、意义创造与内容生成。

A.21 主体性范畴

主体性范畴，是关于谁能够判断、同意、拒绝、授权、行动、负责和代表自身的概念结构。它属于基础范畴之一，服务于法律、政治、教育、伦理和公共治理等文明功能系统。

主体性范畴不同于主体性实现。主体性范畴是理解和制度化主体能力的概念接口；主体性实现则是人类实际行使认识、判断、责任、制度参与、意义创造和未来塑造等能力的过程。

该区分用于避免循环：主体性实现的条件之一是主体性范畴的清晰，而不是说“主体性依赖主体性”这一同义反复。AI 既可能削弱人类主体性实现的实际能力，也可能使主体性范畴本身变得模糊；二者相互关联，但不能混为一谈。

A.22 范畴网络

范畴网络，是指真实、证据、责任、主体性、价值和意义等基础范畴之间的相互支撑关系。

真实需要证据来校准，责任需要主体性来承载，主体性需要判断能力来实现，价值需要意义来解释，意义也需要真实、责任和价值来避免滑向任意叙事。任何一组基础范畴的失准，都可能牵动其他范畴的理解和运行。

范畴网络概念用于说明：AI 对基础范畴的影响往往不是单点扰动，而可能表现为多类范畴接口之间的联动性漂移。

A.23 范畴网络的整体漂移

范畴网络的整体漂移，是指当 AI 或其他结构性力量同时改变多类范畴接口的实践条件时，真实、证据、责任、主体性、价值和意义之间的关系发生联动性失准。

在这种情况下，文明功能系统可能仍然运行，甚至更高效运行，但其运行越来越依赖自动化、预测、排序和优化，而不是理解、判断、责任和意义。

该概念用于描述中介性重构的深层后果。风险不只是某个系统出错，也不只是某个模型污染某个判断，而是文明功能系统调用基础范畴的方式整体发生漂移。

A.24 基础范畴、文明基础条件与主体性能力的映射关系

基础范畴、文明基础条件与主体性能力的映射关系，是指本文中三个层级之间的功能连接：

1. 基础范畴提供概念接口；
2. 文明基础条件提供运行条件；
3. 主体性能力是人类在文明中的实际行使。

这个映射关系可简化为：基础范畴支撑文明基础条件，文明基础条件支撑主体性能力。

该概念用于防止三套清单彼此漂移。它说明本文不是随意列举抽象概念，而是在构建一个从概念接口到文明运行条件，再到人类实际能力的层级关系。

四、AI 风险机制与判定概念

A.25 AI 作为文明中介

AI 作为文明中介，是指 AI 不只是外部工具，而是可能进入人类文明的知识、证据、责任、判断、制度和意义结构，成为影响人类主体性实现条件的中介力量。

AI 可以成为人类文明中的工具、平台、基础设施或中介结构，但不因此成为本文中的风险承受主体。AI 的风险意义不只在于它可能造成外部灾难，也在于它可能改变人类如何认识真实、形成判断、承担责任、参与制度和创造意义。

该概念用于说明 AI 风险的特殊性：AI 并不只是站在人类文明之外造成伤害，也可能嵌入文明功能系统内部，改变人类进入知识、制度、责任和意义结构的方式。

A.26 替代性剥夺

替代性剥夺，是指 AI 作为更高效、更可复制、更可规模化的替代者，逐渐取代人类在文明功能系统中的劳动、认知、创造、治理和判断角色，使人类被共同世界的关键功能系统边缘化或挤出。

替代性剥夺主要削弱的是人类作为共同世界参与者和方向塑造者的地位。其典型形式不是人类立即消失，而是人类仍然消费、确认、投票或被服务，却越来越少实质性地影响资源分配、制度方向、知识生产和文化叙事。

替代性剥夺的危险不在于某一岗位、职业或行业消失，而在于人类逐渐不再是共同世界运行和更新所必需的主体。该概念对应文明条件层面中人类参与结构和实质参与的受损。

A.27 中介性重构

中介性重构，是指人类仍然留在文明功能系统之中，仍然保留选择、审批、签署、学习、创作和参与等形式，但这些活动的前提条件已经被 AI 深度中介。

在中介性重构中，人类仍在获取信息，但信息入口、摘要结构和解释框架可能由系统预先组织；人类仍在作出决策，但可见选项、风险排序和理由生成可能由 AI 塑形；人类仍在承担责任，但判断形成过程越来越难以理解和追踪；人类仍在学习和创造，但学习过程、创作标准和意义评价越来越依赖系统输出。

中介性重构主要削弱的是人类在参与过程中的理解、判断、责任和意义创造能力，并可能进一步扰动基础范畴的校准机制。它与替代性剥夺不同：替代性剥夺使人类逐渐失去系统中的关键位置；中介性重构则保留人类的形式位置，却改变这些位置背后的判断、责任和意义结构。

A.28 不可逆或难以逆转

不可逆或难以逆转，是本文用于区分存在性风险与普通重大风险的关键时间性标准。

在生物存续层面，不可逆主要指物种灭绝、繁殖链断裂或永久失能等物理 / 生物学意义上的绝对不可恢复。

在文明条件层面，不可逆或难以逆转主要指历史、制度和认知意义上的难以恢复，例如制度路径依赖、代际能力训练断裂、关键判断能力消退，以及相关能力的缺失不再被社会识别为损失。

这里的“难以逆转”并不指治理成本高、恢复周期长或制度改革困难，而是指在跨代际历史尺度上，相关能力、制度路径和范畴校准机制已经退化到缺乏现实修复主体与修复路径的状态。本文不把“难以逆转”量化为固定年限或单一指标；它是概念识别标准，具体操作化仍需后续实证研究和治理研究进一步展开。

A.29 人类作为未来主体

人类作为未来主体，是指人类不仅被动地进入未来，而且能够在跨代际过程中理解风险、形成判断、承担责任、组织行动、修正制度并塑造未来。

它不是新的风险承受主体，也不是独立于主体性实现之外的新概念，而是主体性实现的时间性和能动性面向。换言之，人类作为未来主体，意味着人类能够把认识、判断、责任、制度参与和意义创造投向未来，并据此保护或更新共同世界。

该概念用于第四个存在性风险门槛：风险必须使前三项损害汇聚为对人类未来主体能力的整体性、跨代际损害，才具有存在性风险意义。

A.30 四个门槛 / 存在性风险门槛

四个门槛，是指本文用于判断文明条件层面的人类主体性实现风险是否达到存在性风险级别的四项标准。

一个风险若要进入本文所说的人类主体性实现层面的存在性风险范围，至少应满足：

1. 作用于文明基础条件，而不是局部功能；
2. 具有跨领域并跨文明接口的扩散能力，而不是孤立事故、单一误用或单一制度内部的局部重组；
3. 可能造成不可逆或难以逆转的结构性损害；
4. 使前三项损害汇聚为对人类作为未来主体之能力的整体性、跨代际损害。

这些门槛主要适用于文明条件层面的主体性实现风险。物种灭绝、永久失能或人类未来的永久封闭，依其自身性质直接构成存在性风险，不需要适用这四个门槛。

四个门槛的功能，是防止概念泛化。它们确保本文不会把所有 AI 社会影响都升级为存在性风险，也不会把普通技术变迁误读为文明级损害。

A.31 跨领域并跨文明接口的扩散能力

跨领域并跨文明接口的扩散能力，是指某种 AI 风险机制不只在单一领域、单一行业、单一国家或单一制度内部扩散，而是能够通过现代全球文明生态中的共同接口，跨越多个文明功能系统，并影响多重文明传统共同依赖的知识、制度、技术和意义结构。

这里的“跨领域”，是指风险机制能够跨越教育、科学、法律、媒体、企业、公共治理、文化生产和日常生活等多个文明功能系统。这里的“跨文明接口”，是指风险机制能够通过全球科研网络、教育体系、数字平台、法律—治理接口、供应链、技术标准和公共话语结构，在不同国家、文化和文明传统之间传播并发生结构性影响。

该概念是本文区分人类存在性风险与局部社会风险的关键尺度阀门。一个风险即使在单一国家或单一制度内部非常严重，也不必然构成人类存在性风险；只有当它具有跨领域并跨文明接口的扩散能力，并进一步满足其他门槛时，才可能进入人类主体性实现层面的存在性风险范围。

A.32 普通社会风险

普通社会风险，是指影响某一局部社会功能、制度过程、行业结构或技术应用的风险。它可以非常严重，但通常具有相对明确的治理对象和修复路径。

例如，某个职业被替代、某个行业被重组、某个制度流程被自动化、某个信息系统产生错误，都可能构成严重社会风险，但不必然构成人类存在性风险。

普通社会风险与人类主体性实现风险的区别，不在于严重程度本身，而在于它是否作用于人类作为未来主体继续成立的文明基础条件，是否具有跨领域并跨文明接口的扩散能力，是否造成不可逆或难以逆转的结构性损害，并是否汇聚为对人类未来主体能力的整体性、跨代际损害。

A.33 人类主体性实现风险

人类主体性实现风险，是指作用于人类在文明条件中实现认识、判断、责任、制度参与、意义创造和未来行动之基础条件的风险。

它不同于普通社会风险。普通社会风险通常作用于局部功能、制度过程、行业结构或技术应用；人类主体性实现风险则作用于更基础的文明条件，可能影响人类是否仍能作为认识者、判断者、责任者、制度参与者、意义创造者和未来主体而存在。

当这种风险作用于文明基础条件，并具有跨领域并跨文明接口的扩散能力，可能造成不可逆或难以逆转的结构性损害，且使这些损害汇聚为对人类未来主体能力的整体性、跨代际损害时，它可能进入 AI 相关人类存在性风险的范围。

A.34 范式扩展

范式扩展，是指在保留既有存在性风险框架核心地位的基础上，扩展风险识别的对象范围或受损方式。

本文的范式扩展不是范式替代。它不否定物种灭绝、永久失能和未来剥夺作为存在性风险的底线形式，而是进一步主张：AI 也可能通过不可逆或难以逆转地削弱人类在文明中实现主体性的基础条件，构成人类存在性风险。

该概念用于说明本文与既有存在性风险理论之间的关系。本文并不否认既有框架已经包含未来剥夺维度；本文的推进在于指出，AI 时代的未来剥夺不能只被理解为生物灭绝之后的附属结果，也可能表现为人类虽仍存续，却逐渐失去作为未来主体理解、判断、负责和塑造共同世界的文明条件。

A.35 风险识别框架

风险识别框架，是指在具体风险分类、治理方案或技术控制之前，用来确定风险对象、受损方式、判断门槛和概念边界的分析框架。

本文提供的是风险识别框架，不是完整风险分类，也不是技术治理方案。它回答的是更前置的问题：AI 风险分析究竟在保护什么？本文的回答是：不仅要保护人类作为生物物种的存续，也要保护人类在文明条件中实现主体性继续成立的基础条件。

风险识别框架的作用，是为不同 AI 风险讨论提供可比较、可连接、可批判的概念位置。它不替代实证研究、技术治理和政策设计，而是为这些工作提供前置的本体论坐标。

A.36 AGI 时代

AGI 时代，在本文中并不指真正意义上的 AGI 已经实现，也不依赖某个普遍接受的 AGI 阈值已经被跨越。

它指的是一个正在展开的历史转变：AI 系统正在变得更通用、更自主、更具行动能力，并越来越深入地嵌入知识生产、制度流程、判断形成、技术研发、公共治理和意义生成之中。

本文使用该概念，是为了标示一种历史条件：即使在真正 AGI 尚未出现之前，AI 也已经开始改变人类主体性实现的文明条件。因此，本文所讨论的许多风险机制，并不需要等待某个严格定义的 AGI 阈值被跨越之后才具有分析意义。

A.37 本体论坐标系

本体论坐标系，是指本文为 AI 相关人类存在性风险提供的风险识别框架。它通过澄清风险承受主体、受损层面、范畴校准机制、文明功能系统、人类参与结构、AI 作用机制和风险门槛，为不同 AI 风险讨论提供一个可比较、可连接、可批判的位置结构。

在本文中，本体论坐标系包括：

1. 一个风险承受主体：人类这一具身物种；
2. 两个基本受损层面：生物存续层面与文明条件层面；
3. 一个内部机制：范畴校准机制；
4. 一个中间承载层：文明功能系统与人类参与结构；
5. 两类 AI 作用机制：替代性剥夺与中介性重构；
6. 一组存在性风险门槛，其中包括跨领域并跨文明接口的扩散能力这一尺度阀门。

该概念用于说明本文与风险分类、技术治理和政策方案的关系：本文不直接替代这些工作，而是为它们提供前置的概念坐标。本文提供的不是完整风险清单，而是判断何种 AI 损害触及人类存在根基的本体论坐标系。

五、结构说明与方法性概念

A.38 功能性类比：硬件—内核—发行版—应用层

功能性类比：硬件—内核—发行版—应用层，是指本文用于辅助说明人类物种、哲学内核、人类文明和文明功能系统之间结构关系的有限类比。

在这一类比中，人类物种可以类比为硬件，因为它提供最基础的生物承载；哲学内核可以类比为内核，因为它在功能上维持基础范畴接口的校准；人类文明可以类比为发行版，因为它构成完整的跨代际运行环境；文明功能系统可以类比为应用层，因为它们是人类日常进入共同世界的主要界面。

该类比只解释功能关系，不决定本体关系。它不是为了把人类理解为机器，不是为了把哲学理解为代码，也不是为了把文明理解为软件。它的作用是帮助读者理解承载、接口、运行环境 and 应用界面之间的关系，同时避免两个误读：一是以为人类物种存续就等于主体性实现条件完整；二是以为文明功能系统仍然运行，就说明底层范畴仍然健康。

该概念在附录中单列，是为了锁定类比的边界，防止类比反客为主。真正具有论证效力的，仍是本文关于人类物种、人类文明、哲学内核和文明功能系统之间关系的非类比结构说明。

注释

[注 1]

本文所说的“AGI 时代”并不预设真正意义上的 AGI 已经实现，也不依赖某个普遍接受的 AGI 阈值已经被跨越。它指的是一个正在展开的历史转变：AI 系统正在变得更通用、更自主、更具行动能力，并越来越深地嵌入知识生产、制度流程、判断形成、技术研发、公共治理和意义生成之中。本文讨论的若干风险机制，在真正 AGI 出现之前，已经可能以高级 AI、生成式 AI、行动型 AI 和自动化系统的形式出现。

[注 2]

本文将 AI 视为可能重组人类知识、行动、责任和意义结构的文明中介，这一问题意识与技术哲学和后现象学中的技术中介传统相邻。相关背景可参见 Heidegger (1977)、Ihde (1990)、Winner (1980)、Verbeek (2011)、Rosenberger 与 Verbeek (2015) 以及 Pezzano 与 Pavanini (2025)；关于共同世界、行动和未来责任的更深问题背景，也可与 Arendt (1958) 和 Jonas (1984) 相互参照。

[注 3]

既有存在性风险和 AI 风险讨论已经涵盖物种灭绝、永久失能、未来剥夺、失控、控制问题和长期未来潜能的不可逆损失，可参见 Bostrom (2002, 2013, 2014)、Ord (2020)、Russell (2019) 与 Carlsmith (2022)。近期哲学和法律学术也开始系统整理 AI 存在性风险，可参见 Cappelen、Goldstein 与 Hawthorne (2025) 以及 Tokson 与 Arbel (2026)。本文与这些研究相邻，但不提出新的风险类型学或监管方案，而是更前置地澄清这些风险中的“人类”这一承受主体及其可能受损方式。

[注 4]

本文的“概念工程”取向，可参见 Cappelen (2018)、Chalmers (2025) 与 Haslanger (2000) 对概念修正、概念设计和规范性概念分析的相关讨论。本文借用概念工程的问题意识，但具体对象不是语言哲学内部争论，而是 AI 风险理论中的风险承受主体问题：当我们说 AI 威胁“人类”时，这里的“人类”究竟是什么。

[注 5]

本文区分形式参与与实质参与，并不是否认程序性参与的重要性，而是指出，保留程序位置、最终签字或形式化 human-in-the-loop，并不必然意味着人类仍然理解判断形成过程、承担实质责任或塑造制度方向。本文所说的实质参与，强调的是人类作为认识者、判断者、责任承担者、制度维护者、意义创造者和未来主体，对共同世界的运行与更新产生实际影响。关于复杂自动化系统中责任被错误压到控制能力有限的人类行动者身上的问题，可参见 Elish (2019) 关于 moral crumple zones 的讨论；关于学习型自动系统中的责任缺口，可参见 Matthias (2004) 关于 responsibility gap 的经典分析。

[注 6]

本文所说“跨代际共同世界”并不直接等同于任何单一政治哲学或现象学概念，但与 Arendt 关于共同世界、行动和人的条件的讨论，以及 Jonas 关于技术时代责任与未来世代的讨论具有问题关联。本文借用的是一种问题意识：人类文明不是人口在时间中的简单延续，而是使过去能够传递给未来、使人类能够理解、判断、负责并塑造共同世界的历史性条件。

[注 7]

本文关于真实、证据、知识共同体、公共判断和信息生态的讨论，与社会认识论传统具有问题关联。相关背景可参见 Goldman (1999)、Longino (1990)、Fricker (2007)、O'Connor 与 Weatherall (2019) 以及 Nguyen (2020)。更直接地，Ortmann (2025) 讨论了科学中对 AI 的认识依赖，并主张 AI 工具的不透明性并不必然给社会认识论带来全新问题。本文与这一讨论相邻，但问题层级不同：本文关注的不是 AI 不透明性是否构成社会认识论中的新问题，而是当 AI 深度进入文明功能系统并改变真实、证据、责任、主体性、价值与意义等范畴接口时，这种中介性重构是否可能触及人类主体性实现的基础条件。

[注 8]

“硬件—内核—发行版—应用层”类比仅作为功能性说明使用，不是本体模型。它不意味着人类文明可以像计算机系统那样被模块化拆解、替换、重装或迁移，也不意味着哲学内核是一个可单独安装、替换或重启的实体模块。该类比只用于说明四种功能关系：人类物种提供生物承载，哲学内核校准基础范畴接口，人类文明提供完整的跨代际运行环境，文明功能系统提供人类实际进入共同世界的应用层界面。

[注 9]

本文并不主张 AI 必然削弱人类主体性实现条件。AI 也可能增强教育、科学研究、公共服务、医疗诊断、无障碍支持、知识获取、制度透明度和公共协作。本文关注的是另一类可能性：当 AI 的嵌入方式作用于文明基础条件，具有跨领域并跨文明接口的扩散能力，可能造成不可逆或难以逆转的结构性损害，并汇聚为对人类未来主体能力的整体性、跨代际损害时，它才进入本文所说的人类主体性实现层面的存在性风险范围。

[注 10]

关于 AI 风险可能通过渐进式削弱人类对经济、文化和国家等大规模社会系统的影响力而发生，可参见 Kulveit 等人（2025）的“Gradual Disempowerment: Systemic Existential Risks from Incremental AI Development”。在本文坐标系中，这类研究可安置于文明条件层面中的文明功能系统与人类参与结构问题，尤其接近本文所说的替代性剥夺。本文吸收其关于渐进失权和权力转移的风险直觉，但不以“权力转移”本身作为最终概念中心。

[注 11]

关于生成式 AI 使用与批判性思维、认知努力和任务监管方式之间的关系，可参见 Lee 等人（2025）对知识工作者的调查研究。关于学生对 AI 对话系统过度依赖及其对认知能力影响的系统综述，可参见 Zhai、Wibowo 与 Li（2024）。这些研究不能直接证明存在性风险，但为本文所说的中介性重构提供经验背景：当生成式 AI 或 AI 对话系统被嵌入知识工作与学习流程时，人类批判性思维实践、认知努力、判断负担和任务监管方式可能发生重新分配。

[注 12]

扩展心智的经典表述可参见 Clark 与 Chalmers（1998）；关于大语言模型是否可被理解为扩展心智的一部分，可参见 Smart、Clowes 与 Clark（2025）关于 LLM 与 extended mind 的讨论。本文与这一讨论相邻，但并不以“LLM 是否构成扩展心智”为中心问题；本文关注的是，当 AI 系统组织信息入口、理由生成、选项排序和判断环境时，人类是否仍然保有形成判断、承担责任和实现主体性的实质条件。

[注 13]

本文所说“跨领域并跨文明接口的扩散能力”，不是指风险必须在同一时间、同一方式影响所有国家或文明传统，而是指其传播通道已经进入现代全球文明生态的共同接口，例如全球科研网络、教育体系、数字平台、法律—治理接口、供应链、技术标准和公共话语结构。该门槛的作用，是防止将单一国家、单一行业或单一制度内部的严重社会风险，直接升级为人类存在性风险。

[注 14]

本文所说“不可逆或难以逆转”，在文明条件层面主要指历史、制度和认知意义上的难以恢复，而不是单一物理不可逆。相关讨论可与路径依赖、制度持续和能力形成研究对话，例如 Arthur (1989) 关于技术锁定和递增收益的研究，Pierson (2000) 关于政治中的路径依赖，North (1990) 关于制度变迁，以及 Cunha 与 Heckman (2007) 关于技能形成技术的研究。本文不把“难以逆转”量化为固定年限或单一指标；它不是指治理成本高或恢复周期长，而是指在跨代际历史尺度上，相关能力、制度路径和范畴校准机制已经退化到缺乏现实修复主体与修复路径的状态。

[注 15]

关于 AI 可能通过削弱人类自主性、决策能力和技能实践而带来深层风险，可参见 Prunkl (2022) 关于 AI 时代人类自主性的讨论，以及 Krook (2025) 关于自主性衰退和技能退化的存在性风险分析。在本文坐标系中，这类讨论可安置于文明条件层面中的主体性能力弱化问题，并与替代性剥夺和中介性重构均有交叉。本文的主轴不是自主性理论本身，也不是某一种技能退化，而是判断这些能力下降何时上升为人类这一风险承受主体的存在性损害。

参考文献

- Arendt, Hannah. 1958. *The Human Condition*. Chicago: University of Chicago Press.
- Arthur, W. Brian. 1989. “Competing Technologies, Increasing Returns, and Lock-In by Historical Events.” *The Economic Journal* 99 (394): 116–131. doi:10.2307/2234208.
- Bostrom, Nick. 2002. “Existential Risks: Analyzing Human Extinction Scenarios and Related Hazards.” *Journal of Evolution and Technology* 9.
- Bostrom, Nick. 2013. “Existential Risk Prevention as Global Priority.” *Global Policy* 4 (1): 15–31. doi:10.1111/1758-5899.12002.
- Bostrom, Nick. 2014. *Superintelligence: Paths, Dangers, Strategies*. Oxford: Oxford University Press.
- Cappelen, Herman. 2018. *Fixing Language: An Essay on Conceptual Engineering*. Oxford: Oxford University Press.
- Cappelen, Herman, Simon Goldstein, and John Hawthorne. 2025. “AI Survival Stories: A Taxonomic Analysis of AI Existential Risk.” *Philosophy of AI* 1: 1–19.

doi:10.18716/ojs/phai/2025.2801.

Carlsmith, Joseph. 2022. “Is Power-Seeking AI an Existential Risk?” arXiv:2206.13353.

Chalmers, David J. 2025. “What Is Conceptual Engineering and What Should It Be?” *Inquiry: An Interdisciplinary Journal of Philosophy* 68 (9): 2902–2919. doi:10.1080/0020174X.2020.1817141.

Clark, Andy, and David J. Chalmers. 1998. “The Extended Mind.” *Analysis* 58 (1): 7–19. doi:10.1093/analys/58.1.7.

Cunha, Flavio, and James J. Heckman. 2007. “The Technology of Skill Formation.” *American Economic Review* 97 (2): 31–47. doi:10.1257/aer.97.2.31.

Elish, Madeleine Clare. 2019. “Moral Crumple Zones: Cautionary Tales in Human-Robot Interaction.” *Engaging Science, Technology, and Society* 5: 40–60. doi:10.17351/ests2019.260.

Fricker, Miranda. 2007. *Epistemic Injustice: Power and the Ethics of Knowing*. Oxford: Oxford University Press.

Goldman, Alvin I. 1999. *Knowledge in a Social World*. Oxford: Oxford University Press.

Haslanger, Sally. 2000. “Gender and Race: (What) Are They? (What) Do We Want Them To Be?” *Noûs* 34 (1): 31–55. doi:10.1111/0029-4624.00201.

Heidegger, Martin. 1977. “The Question Concerning Technology.” In *The Question Concerning Technology and Other Essays*, translated by William Lovitt, 3–35. New York: Harper & Row.

Ihde, Don. 1990. *Technology and the Lifeworld: From Garden to Earth*. Bloomington: Indiana University Press.

Jonas, Hans. 1984. *The Imperative of Responsibility: In Search of an Ethics for the Technological Age*. Chicago: University of Chicago Press.

Krook, Joshua. 2025. “When Autonomy Breaks: The Hidden Existential Risk of AI.” *AI & Society* 40 (8): 6011–6024. doi:10.1007/s00146-025-02397-5.

Kulveit, Jan, Raymond Douglas, Nora Ammann, Deger Turan, David Krueger, and David Duvenaud. 2025. “Gradual Disempowerment: Systemic Existential Risks from Incremental AI Development.” arXiv:2501.16946. doi:10.48550/arXiv.2501.16946.

Lee, Hao-Ping (Hank), Advait Sarkar, Lev Tankelevitch, Ian Drosos, Sean Rintel, Richard Banks, and Nicholas Wilson. 2025. “The Impact of Generative AI on Critical Thinking: Self-Reported Reductions in Cognitive Effort and Confidence Effects From a Survey of Knowledge Workers.” In *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems* (CHI ’25), Article 1121, 1–22. New York: Association for Computing Machinery. doi:10.1145/3706598.3713778.

Longino, Helen E. 1990. *Science as Social Knowledge: Values and Objectivity in Scientific Inquiry*. Princeton: Princeton University Press.

- Matthias, Andreas. 2004. "The Responsibility Gap: Ascribing Responsibility for the Actions of Learning Automata." *Ethics and Information Technology* 6 (3): 175–183. doi:10.1007/s10676-004-3422-1.
- Nguyen, C. Thi. 2020. "Echo Chambers and Epistemic Bubbles." *Episteme* 17 (2): 141–161. doi:10.1017/epi.2018.32.
- North, Douglass C. 1990. *Institutions, Institutional Change and Economic Performance*. Cambridge: Cambridge University Press.
- O'Connor, Cailin, and James Owen Weatherall. 2019. *The Misinformation Age: How False Beliefs Spread*. New Haven: Yale University Press.
- Ord, Toby. 2020. *The Precipice: Existential Risk and the Future of Humanity*. New York: Hachette Books.
- Ortmann, Jakob. 2025. "Of Opaque Oracles: Epistemic Dependence on AI in Science Poses No Novel Problems for Social Epistemology." *Synthese* 205: Article 80. doi:10.1007/s11229-025-04930-x.
- Pezzano, Giacomo, and Marco Pavanini. 2025. "Understanding Philosophical Media: From Philosophy of Technology to 'Technologies of Philosophy.'" *Philosophy & Technology* 38: Article 107. doi:10.1007/s13347-025-00937-x.
- Pierson, Paul. 2000. "Increasing Returns, Path Dependence, and the Study of Politics." *American Political Science Review* 94 (2): 251–267. doi:10.2307/2586011.
- Prunkl, Carina. 2022. "Human Autonomy in the Age of Artificial Intelligence." *Nature Machine Intelligence* 4 (2): 99–101. doi:10.1038/s42256-022-00449-9.
- Rosenberger, Robert, and Peter-Paul Verbeek, eds. 2015. *Postphenomenological Investigations: Essays on Human–Technology Relations*. Lanham, MD: Lexington Books.
- Russell, Stuart. 2019. *Human Compatible: Artificial Intelligence and the Problem of Control*. New York: Viking.
- Smart, Paul, Robert Clowes, and Andy Clark. 2025. "ChatGPT, Extended: Large Language Models and the Extended Mind." *Synthese* 205: Article 242. doi:10.1007/s11229-025-05046-y.
- Tokson, Matthew J., and Yonathan A. Arbel. 2026. "Artificial Intelligence and Existential Risk." SSRN Working Paper. Forthcoming in *Connecticut Law Review* 59 (2027). doi:10.2139/ssrn.6288138.
- Verbeek, Peter-Paul. 2011. *Moralizing Technology: Understanding and Designing the Morality of Things*. Chicago: University of Chicago Press.
- Winner, Langdon. 1980. "Do Artifacts Have Politics?" *Daedalus* 109 (1): 121–136.
- Zhai, Chunpeng, Santoso Wibowo, and Lily D. Li. 2024. "The Effects of Over-Reliance on AI Dialogue Systems on Students' Cognitive Abilities: A Systematic Review." *Smart Learning Environments* 11: Article 28. doi:10.1186/s40561-024-00316-7.